




UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería de la Salud



INGENIERÍA
DE LA SALUD

**TFG del Grado en Ingeniería de la
Salud**

**Redes GAN para la
Generación y Ampliación de
Datos ECG en Conjuntos
Desequilibrados**

Presentado por Paula Cuesta Asín
en Universidad de Burgos

8 de julio de 2025

Tutores: Olga Valencia García – Jaime Andrés Rincón
Arango



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería de la Salud



D. Olga Valencia García, profesora del departamento de Matemáticas y Computación, área de Estadística e Investigación Operativa.

D. Jaime Andrés Rincón Arango, profesor del departamento de Digitalización, área de Computer Science and Artificial Intelligence.

Expone:

Que el alumno D. Paula Cuesta Asín, con DNI 71795586M, ha realizado el Trabajo final de Grado en Ingeniería de la Salud titulado "Redes GAN para la Generación y Ampliación de Datos ECG en Conjuntos Desequilibrados".

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 8 de julio de 2025

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Olga Valencia García

D. Jaime Andrés Rincón Arango

Resumen

Este Trabajo de Fin de Grado aborda el problema del desequilibrio de clases en conjuntos de datos clínicos, concretamente en señales de electrocardiograma (ECG), que afecta negativamente el rendimiento de los modelos de aprendizaje automático para la detección de patologías cardíacas. Para solucionarlo, se diseña e implementa una arquitectura basada en redes generativas adversariales condicionales con penalización de gradiente (cWGAN-GP), capaz de sintetizar señales ECG artificiales que mantienen una alta similitud con las reales. Se utiliza el dataset PhysioNet / Computing in Cardiology Challenge 2017 como referencia para la generación y evaluación de estas señales sintéticas. Los resultados obtenidos contribuyen a mejorar el balance de clases y, en consecuencia, el desempeño de los modelos de clasificación, aportando valor tanto en la investigación como en aplicaciones clínicas relacionadas con la cardiología computacional.

Descriptores

Generación sintética de datos, Redes generativas adversariales, Electrocardiograma (ECG), Desequilibrio de clases, Aprendizaje automático profundo, Salud digital, Cardiología computacional, Señales biomédicas . . .

Abstract

This Final Degree Project investigates the problem of class imbalance in clinical datasets, specifically in electrocardiogram (ECG) signals, which negatively impacts the performance of machine learning models for cardiac pathology detection. To overcome this challenge, a conditional Wasserstein Generative Adversarial Network with gradient penalty (cWGAN-GP) architecture is designed and implemented to synthesize artificial ECG signals that are highly similar to real ones. The PhysioNet / Computing in Cardiology Challenge 2017 dataset is used as a reference for generating and evaluating these synthetic signals. The results contribute to improving class balance and, consequently, the classification models' performance, providing value in both research and clinical applications related to computational cardiology.

Keywords

Synthetic data generation, Generative adversarial networks, Electrocardiogram (ECG), Class imbalance, Deep machine learning, Digital health (e-health), Computational cardiology, Biomedical signals
...

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vii
Introducción	1
Objetivos	3
2.1. Objetivos específicos del proyecto	4
Conceptos teóricos	11
3.1. Fundamentos de la anatomía y función cardíaca	11
3.2. Fundamentos de la señal electrocardiográfica (ECG)	34
3.3. Fundamentos del aprendizaje automático aplicado a señales biomédicas	45
3.4. Estado del arte y trabajos relacionados.	60
Metodología	65
4.1. Descripción de los datos	68
4.2. Técnicas y Herramientas	77
Resultados	83
5.1. Evaluación del preprocesamiento y depurado de los datos . .	85
5.2. Evaluación del funcionamiento del modelo generativo (cWGAN- GP)	90
5.3. Evaluación del balanceo de las clases	96
5.4. Análisis y Discusión Final	98

Conclusiones	99
6.1. Logros y resultados principales	99
6.2. Limitaciones del trabajo	101
Lineas de trabajo futuras	103
7.1. Capacidad de cómputo	103
7.2. Implementación de un clasificador	105
7.3. Exploración y experimentación de distintas arquitecturas . .	105
7.4. Validación multidisciplinar	106
7.5. Generalización a otros tipos de señales	106
7.6. Robustez del sistema	106
7.7. Desarrollo de una plataforma de fácil manejo	107
7.8. Generalización a registros con mayor número de derivaciones	107
Bibliografía	109

Índice de figuras

3.1. Ubicación esquemática del corazón en el mediastino. Fuente: [Saturno Chiu, 2017]	14
3.2. Visión anterior y posterior del corazón. Fuente: [H et al., 2019]	14
3.3. Visión del corazón desde la mitad lateral izquierda del mediastino. Fuente: [H et al., 2019]	16
3.4. Principales cavidades cardíacas. Fuente: [Saturno Chiu, 2017]	17
3.5. Principales vasos sanguíneos del corazón. Fuente: [Vélez et al., 2010]	18
3.6. Válvulas principales del corazón. Fuente: [Texas Heart Institute,]	26
3.7. Sucesión de fases del ciclo cardíaco. Fuente: [Saturno Chiu, 2017]	26
3.8. Capas que conforman el pericardio. Fuente: [Quinn, Matt,]	28
3.9. Ciclo cardíaco, onda de ECG y estructuras del sistema de conducción eléctrica. <i>Elaboración propia</i>	31
3.10. Gráfico que recoge la forma de registro habitual de la señal ECG. Fuente: <i>Elaboración propia</i>	35
3.11. Morfología de las señales de ECG y ondas y complejos de estas. Fuente: [Rosas, 2022]	36
3.12. Comparación del patrón de una señal de ECG con distintas frecuencias de muestreo. <i>Elaboración propia</i>	39
3.13. Flujo de explicación de conceptos. <i>Elaboración propia</i>	46
3.14. Aplicaciones de los modelos de ML cuando se aplican sobre señales de ECG. <i>Elaboración propia</i>	48
3.15. Relación entre las distintas disciplinas basadas en Inteligencia Artificial. <i>Elaboración propia</i>	49
3.16. Características principales de los distintos tipos de aprendizaje automático <i>Elaboración propia</i>	50
3.17. Flujo de trabajo del aprendizaje automático aplicado a señales de ECG. <i>Elaboración propia</i>	51

3.18. Etapas que sigue el proceso de aprendizaje automático supervisado. <i>Elaboración propia</i>	52
4.1. Diagrama de flujo que representa la metodología seguida en el proyecto. <i>Elaboración propia</i>	66
4.2. Diagrama de bloques que representa la importancia del conjunto de datos escogido. <i>Elaboración propia</i>	69
4.3. Aparato de registro de señales de ECG de Alivecor. Ejemplo de funcionamiento [AliveCor,].	72
5.1. Tabla que representa el desbalanceo de clases del conjunto de datos PhysioNet / Computing in Cardiology Challenge . [Clifford et al., 2017]	84
5.2. Figura que representa la variabilidad entre las señales originales del dataset, tanto en amplitud como en duración. <i>Elaboración propia</i>	86
5.3. Comparación de la señal en el dominio del tiempo y su espectro de magnitud antes y después de aplicar un filtro pasabanda. <i>Elaboración propia</i>	88
5.4. Comparación de escalas entre la señal original y la señal normalizada. <i>Elaboración propia</i>	88
5.5. Representación en forma de cruces rojas de los picos a través de los que se va a realizar la segmentación de la señal. <i>Elaboración propia</i>	89
5.6. Ventanas en que se divide la señal. Cada una de ellas corresponde a un latido cardíaco individual. <i>Elaboración propia</i>	89
5.7. Captura de pantalla que representa la fluctuación de los valores de pérdida del generador y del generador, ya que estos compiten entre ellos. <i>Elaboración propia</i>	91
5.8. Señales de cada una de las clases del dataset generadas artificialmente.	92
5.9. Representación de la distribución de las muestras del dataset en función de su clase, haciendo patente el desbalanceo. <i>Elaboración propia</i>	97

Índice de tablas

3.1. Principales características morfológicas del corazón. <i>Elaboración propia.</i>	13
3.2. Resumen de las cuatro cavidades cardíacas y sus estructuras asociadas (entrada, salida y válvulas). <i>Elaboración propia.</i>	18
3.3. Principales características de los tabiques cardíacos. <i>Elaboración propia.</i>	19
3.4. Fases del ciclo cardíaco y estado de las válvulas implicadas. <i>Elaboración propia.</i>	22
3.5. Relación de las válvulas cardíacas con las fases del ciclo cardíaco. <i>Elaboración propia.</i>	22
3.6. Composición y localización de las capas del pericardio. <i>Elaboración propia</i>	27
3.7. Características técnicas habituales de las señales electrocardiográficas	38
3.8. Comparación entre métodos tradicionales y técnicas basadas en aprendizaje automático en el ámbito de las señales biomédicas. <i>Elaboración propia.</i>	48
4.1. Fases en que se divide la metodología del proyecto y herramientas utilizadas. <i>Elaboración propia</i>	68
4.2. Características principales del conjunto de datos CinC Challenge 2017. <i>Elaboración propia</i>	70
5.1. Distribución de los registros de ECG del dataset en función de su categoría clínica. <i>Elaboración propia.</i>	96

Introducción

En las últimas décadas, el campo de la inteligencia artificial (IA) ha experimentado un crecimiento exponencial, revolucionando la forma de procesamiento y análisis de los datos en múltiples disciplinas, tanto científicas como tecnológicas. Dentro del ámbito de la salud, la IA ha transformado por completo la forma en que se abordan el diagnóstico, la monitorización y el tratamiento de enfermedades, permitiendo el desarrollo de sistemas automatizados capaces de asistir a los profesionales médicos con mayor precisión y rapidez.

Uno de los elementos más importantes dentro de este campo es la adquisición y análisis de señales fisiológicas, como el electrocardiograma (ECG). El ECG registra la actividad eléctrica del corazón y es una herramienta fundamental para la detección y seguimiento de diversas patologías cardiovasculares, que constituyen una de las principales causas de mortalidad a nivel mundial. La correcta interpretación de estas señales es crucial para la prevención de trastornos y la mejora de la calidad de vida de los pacientes con alguna patología de este tipo.

El análisis tradicional de señales ECG depende en gran medida de la experiencia del profesional de la salud y, en muchos casos, se enfrenta a limitaciones debido a la complejidad y variabilidad intrínseca de las señales. En este contexto, las técnicas de aprendizaje automático y, más recientemente, las redes neuronales profundas han mostrado un gran potencial para automatizar y optimizar la detección de patrones anómalos en estas señales.

No obstante, uno de los desafíos más significativos en el desarrollo de modelos de aprendizaje automático para aplicaciones médicas es la disponibilidad y calidad de los datos en la actualidad. En particular, los conjuntos de datos utilizados con este propósito presentan un marcado

desequilibrio de clases, donde la mayoría de las muestras corresponden a condiciones normales, mientras que las clases que representan anomalías o patologías están poco representadas. Este desequilibrio provoca que los algoritmos aprendan principalmente a reconocer patrones mayoritarios, dificultando la detección de casos minoritarios y reduciendo la eficacia clínica de los sistemas.

Para abordar esta problemática, se propone la utilización de redes generativas adversariales condicionales con penalización de gradiente (cWGAN-GP), una arquitectura avanzada de redes neuronales que permite generar muestras sintéticas realistas condicionadas a una clase específica. De esta manera, se puede ampliar y balancear el conjunto de datos original, mejorando la capacidad de los modelos de aprendizaje automático para identificar patologías en las señales de ECG.

El dataset utilizado proviene del **PhysioNet / Computing in Cardiology Challenge 2017**, una conferencia con elevado reconocimiento entre los miembros de la comunidad científica por su rigor y calidad en la investigación biomédica. Este contiene registros ECG etiquetados en múltiples clases en función de su morfología, tanto normal como patológica.

La generación de datos sintéticos mediante el uso de una red cWGAN-GP no solo contribuye a mitigar el desequilibrio de clases, sino que también ayuda a preservar la privacidad y confidencialidad de los datos reales, un aspecto de creciente importancia en la investigación biomédica.

Este proyecto combina conocimientos de procesamiento de señales, inteligencia artificial y programación científica para desarrollar una solución innovadora que pueda ser integrada en futuras herramientas clínicas, apoyando la labor diagnóstica y mejorando la precisión en la detección automática de anomalías cardíacas.

Objetivos

El presente trabajo surge de una necesidad técnica observada a lo largo de los cuatro años de duración del grado en Ingeniería de la Salud.

La utilización de conjuntos de datos clínicos ha sido una práctica común en diversas asignaturas y proyectos de la titulación, especialmente en aquellas materias vinculadas al aprendizaje automático. No obstante, en la mayoría de los casos, estos conjuntos se encontraban desbalanceados, una situación más frecuente de lo deseado en contextos biomédicos reales, donde los patrones de datos normales (pacientes sanos) predominan sobre los patológicos.

Esta distribución desigual de clases, desde el punto de vista del desarrollo de software, representa un desafío especialmente reseñable en tareas de clasificación. Los sistemas desarrollados, habitualmente, priorizan las clases mayoritarias (sobreaprendizaje), subestimando a las minoritarias (subaprendizaje), hecho que compromete y perjudica el desarrollo y entrenamiento de modelos robustos.

Frente a esta necesidad, surge la idea del presente proyecto: cubrir la problemática de los conjuntos desequilibrados mediante la exploración de técnicas de generación sintética de datos clínicos, con el objetivo de utilizarlos para su balanceo.

En concreto, se propone el diseño e implementación de una arquitectura basada en redes neuronales generativas que permita el balanceo de las clases del dataset **PhysioNet / Computing in Cardiology Challenge 2017**. [Clifford et al., 2017] Para ello, la red elegida ha sido una cWGAN (conditional Wasserstein Generative Adversarial Network) capaz de sintetizar señales de electrocardiograma (ECG) artificiales, pero que mantienen una alta similitud con las reales.

Dicha elección busca mejorar el rendimiento, la calidad y la equidad de los modelos de aprendizaje automático implementados en el ámbito de la Cardiología, a la vez que contribuye a facilitar la detección automática de patrones de comportamiento anómalo en señales representativas de la función cardíaca, hecho que contribuye a una mejora de la labor de los profesionales de la salud.

2.1. Objetivos específicos del proyecto

A lo largo de esta sección se detallan los objetivos específicos que contribuyen al logro del objetivo principal del desarrollo, previamente mencionado.

A su vez, este desglose del objetivo mayor en multitud de objetivos más sencillos de alcanzar favorece la evaluación de los hitos conseguidos, ya que es mucho más tangible valorar el proyecto en pequeñas porciones que en su totalidad.

Estos se organizan en distintos bloques en función de su naturaleza: objetivos derivados de los requisitos del análisis y preprocesamiento de los datos del problema, metas de tipo técnico y de calidad del sistema y, por último, objetivos relacionados con el aprendizaje personal y técnico adquirido durante el desarrollo del proyecto.

Objetivos de análisis

Los objetivos planteados en este bloque están relacionados con las tres primeras etapas del flujo de trabajo seguido en un proceso estándar de aprendizaje automático, tal y como se puede observar en la imagen 3.17 de la página 51.

Cabe destacar que el cumplimiento de estos resulta clave para el correcto desempeño del modelo de aprendizaje desarrollado, puesto que la calidad y organización de los datos de entrada condicionan directamente su funcionamiento. Por lo tanto, constituyen una base fundamental para el éxito del sistema propuesto.

En concreto, las metas que se abordan en este bloque se centran en las tareas de obtención, comprensión, limpieza, procesamiento y estructuración de los datos que se emplean a lo largo de las distintas fases posteriores del proyecto.

Los objetivos más importantes derivados del análisis y preprocesamiento de los datos son los siguientes:

- **Investigación de la bibliografía disponible:** Realizar un proceso de análisis e investigación acerca del estado del arte en técnicas de generación sintética de datos biomédicos y redes GAN aplicadas a señales ECG para fundamentar la propuesta técnica es algo muy importante, ya que va a conceder una idea general acerca de la situación de este tipo de técnicas en la sociedad actual, así como de los retos que se presentan y que aún se encuentran sin resolver.
- **Comprensión y organización del dataset:** La comprensión y el análisis de la metodología elegida para la organización del conjunto de datos es esencial, ya que va a influir directamente sobre el diseño de las etapas posteriores de tratamiento de datos. Algunos de los parámetros clave que se deben identificar y tener en cuenta son: la frecuencia de muestreo, la duración de las señales, el origen de los registros, el formato de almacenamiento o la distribución de clases.
- **Evaluación del desequilibrio de clases:** Cuantificar el grado de desbalance existente en el conjunto de datos, identificando las clases minoritarias, así como su representación porcentual con respecto al resto de las clases. Este análisis es crucial para el objetivo general del proyecto, puesto que va a permitir justificar la necesidad de aplicación de técnicas de generación sintética de datos, las cuales van a favorecer el equilibrio de clases buscado.
- **Proceso de limpieza de los datos:** Es necesario llevar a cabo un adecuado proceso de limpieza sobre los datos, con el objetivo de mejorar el desempeño del sistema. Entre las tareas destinadas a ello se encuentra el filtrado, que va a eliminar la línea de ruido base, o los artefactos de la señal que puedan perjudicar el aprendizaje posterior del modelo. Asimismo, también se debe llevar la eliminación bien de los registros o de los segmentos de la señal que estén incompletos o corruptos.
- **Preprocesamiento de los registros:** Llevar a cabo una etapa de procesamiento inicial de los datos es esencial para su correcta aplicación al sistema. Las estrategias de modificación escogidas van a depender de la naturaleza del proyecto, que en este caso van a ser la normalización y segmentación de los datos en ventanas de tamaño fijo en función de los picos QRS de la señal.

- **Modularización del proceso:** Se busca crear un flujo de trabajo reproducible para su posterior utilización con otros conjuntos de datos, así como su reutilización en futuros desarrollos sobre el mismo conjunto de datos, tales como procesos de entrenamiento o validación de modelos de clasificación.

El cumplimiento de los objetivos aquí detallados facilita un mejor funcionamiento posterior, ya que la correcta estructuración va a ser una base sólida para las fases posteriores. Unos datos representativos y adecuados van a afectar a procesos tales como la generación de señales sintéticas, así como a la evaluación de su impacto.

Objetivos técnicos

Por otro lado, en este apartado se detallan los objetivos técnicos que guían el desarrollo del proyecto, abarcando aspectos relacionados con el hardware, el software y la calidad del sistema. Estos objetivos son esenciales para garantizar un funcionamiento correcto, eficiente y reproducible del sistema implementado, y orientan la evaluación y optimización del proceso de generación sintética de señales ECG, que constituye el principal propósito del proyecto.

Entre los objetivos técnicos más relevantes se encuentran:

1. **Selección y configuración del entorno de hardware:** En trabajos de este tipo, en el que se abordan procesos de aprendizaje continuo se vuelve fundamental la utilización de recursos computacionales adecuados, como unidades GPU y capacidad de memoria, las cuales sean capaces de soportar el entrenamiento intensivo de este tipo de redes neuronales profundas. Para ello, es imprescindible incluir una correcta gestión de la infraestructura y los recursos disponibles, con el objetivo de asegurar un rendimiento óptimo y evitar cuellos de botella.
2. **Desarrollo de software modular y escalable:** La modularización y organización del código en forma de funciones se vuelve fundamental para que la ejecución sea lo más eficiente y flexible posible a lo largo de las diferentes etapas del proyecto. Puesto que las funciones implementadas van a llevar a cabo distintos procesos, que abarcan desde la carga y preprocesamiento de los datos hasta la generación y evaluación de señales sintéticas. Por lo tanto, la modularidad de dichas funciones

facilitará la reutilización, mantenimiento y posible extensión futura del sistema.

3. **Optimización del proceso de entrenamiento:** A la hora de entrenar el modelo desarrollado es necesario tener en cuenta los hiperparámetro y las variables definidas a tal efecto. Algunos de estos son la tasa de aprendizaje o *learning - rate*, el tamaño de lote o *batch size* o la implementación que calcula la penalización por gradiente. Esto es de especial importancia, ya que dichos parámetros van a influir directamente sobre la estabilidad de la red una vez entrenada y, por consiguiente, en la calidad de las distintas señales generadas. Además, a través de una correcta definición de los parámetros se tiende a evitar problemas típicos en este tipo de modelos de aprendizaje, como el colapso o el sobreajuste durante el aprendizaje.
4. **Desarrollo de métricas y controles de calidad:** Otro de los objetivos técnicos que presenta el trabajo, es el establecimiento de un sistema de evaluación de la calidad de las señales obtenidas y de los resultados desarrollados. Para ello, es necesario aplicar métodos cuantitativos y cualitativos que se encarguen de llevar a cabo dicha evaluación. Los aspectos más importantes a tener en cuenta durante dicho proceso son la fidelidad y diversidad de las señales generadas frente a las señales originales que componían el dataset, así como las técnicas que analizan el impacto del balanceo de las clases en la mejora del desempeño del modelo. El desarrollo de este sistema de control de calidad, a su vez, asegura la robustez y validez del sistema.
5. **Documentación técnica exhaustiva:** Otro de los objetivos que se pretende alcanzar con el desarrollo del presente trabajo es la redacción de una documentación detallada y exhaustiva del trabajo realizado. Para ello, esta debe incluir descripciones acerca de la arquitectura, la configuración del hardware seleccionada, los parámetros utilizados y los procedimientos llevados a cabo durante este. De esta documentación va a depender en gran medida el grado de reproducibilidad y la transferencia de conocimiento que exhibe el proyecto.

El cumplimiento riguroso de estos objetivos técnicos permitirá desarrollar una solución sólida y confiable que aborde eficazmente el desequilibrio presente en los conjuntos de datos clínicos, aportando valor tanto en el ámbito académico como en el práctico dentro del contexto de la cardiología computacional.

Objetivos de aprendizaje

En este apartado se describen los objetivos relacionados con el crecimiento y la formación tanto a nivel personal como profesional, que se pretenden alcanzar a lo largo del desarrollo de este proyecto.

Para ello, estos objetivos se centran en la adquisición de competencias, habilidades y conocimientos fundamentales que complementan el trabajo técnico y científico, así como la formación recibida durante los cuatro años de duración del grado en Ingeniería de la Salud. Por lo que, aportan un valor añadido al perfil del investigador y profesional en el presente ámbito.

Los principales objetivos de aprendizaje que se han perseguido con el desarrollo del presente trabajo son los siguientes:

- **Adquisición de un conocimiento profundo acerca de redes GAN:** A través del desarrollo de este TFG se busca familiarizarse con la teoría, arquitectura y funcionamiento de las redes GAN muy utilizadas en las Ciencias Computacionales de la Salud. En particular, este aprendizaje está centrado en la variante cWGAN-GP, y se enfoca en su aplicación para la generación sintética de señales biomédicas como el electrocardiograma. Además, dicho proceso de aprendizaje incluye la comprensión de la importancia de aspectos tales como el entrenamiento estable, la penalización de gradiente o la generación condicional de datos para poder llevar a cabo estas tareas generativas.
- **Desarrollo de competencias en materia de señales fisiológicas:** Con el proceso de análisis y documentación llevado a cabo de forma previa al comienzo del trabajo, se busca realizar las tareas de pre-procesamiento, limpieza y segmentación de las señales de una forma adecuada. De hecho, se ha buscado integrar los aspectos más relevantes tanto a nivel teórico como práctico de este tipo de señales a la hora de su aplicación, con el objetivo de asegurar la calidad y la validez de los datos utilizados en el modelado.
- **Mejora de las habilidades en materia de programación y de IA:** Uno de los objetivos para la elección del trabajo ha sido la voluntad de adquirir una destreza avanzada en el uso de lenguajes de programación como Python, así como la familiarización con nuevas bibliotecas como PyTorch, pickle o funcionalidades de otra ya utilizadas como NumPy (findpeaks). A su vez, con la implementación por primera vez de una arquitectura de red GAN, se busca un incremento del conocimiento en herramientas aplicadas en el ámbito de la Inteligencia Artificial.

- **Capacidad de gestión y documentación científica:** Se busca desarrollar habilidades para organizar, documentar y comunicar de forma clara y rigurosa los procedimientos, resultados y conclusiones del proyecto, fomentando una comunicación efectiva dirigida tanto a audiencias técnicas como no especializadas.
- **Promoción de la investigación y la resolución de problemas:** Uno de los objetivos del trabajo abarca promover la independencia en la búsqueda bibliográfica, el análisis crítico y la aplicación de soluciones innovadoras a los retos técnicos y metodológicos que surgidos durante el desarrollo del trabajo, consolidando un perfil profesional orientado a la investigación en el ámbito biomédico.
- **Implementación de buenas prácticas:** Con el presente trabajo se busca la incorporación de buenas prácticas en el ámbito del desarrollo de proyectos de inteligencia artificial. Para ello, se llevan a cabo tareas como la adopción de metodologías y criterios orientados a la reproducibilidad, la calidad del software y la ética en el manejo de datos clínicos, contribuyendo a un ejercicio profesional responsable y alineado con los estándares actuales del sector.

El cumplimiento de estos objetivos de aprendizaje contribuirá a la formación de un perfil profesional en el ámbito de la ingeniería sólido y versátil, capaz de integrar conocimientos técnicos, científicos y éticos, y de aplicar tecnologías avanzadas en el ámbito de la salud con un enfoque innovador y riguroso.

Conceptos teóricos

3.1. Fundamentos de la anatomía y función cardíaca

Los datos empleados a lo largo de este proyecto corresponden a registros de electrocardiogramas (ECGs), una prueba diagnóstica ampliamente utilizada en el ámbito de la Cardiología, la cual permite representar de forma gráfica la actividad eléctrica del corazón. [Hall, 2021] La señal eléctrica registrada por el electrocardiógrafo es un reflejo directo de los procesos tanto eléctricos, encargados de regular la contracción del miocardio, como de los eventos mecánicos asociados al ciclo cardíaco. [Dalley II and Agur, 2022]

Esta es la razón principal por la que dicho registro constituye una herramienta indispensable tanto para el diagnóstico como para el seguimiento de diversas enfermedades cardíacas, ya que permite detectar cualquier alteración en el funcionamiento de este órgano vital, encargado del bombeo de la sangre en el interior del organismo.

Además, el desarrollo reciente en el campo de la Inteligencia Artificial ha potenciado la capacidad diagnóstica del ECG. La integración de algoritmos de aprendizaje automático en el análisis de este tipo de señales permite una mayor eficiencia y precisión diagnóstica, facilitando la detección temprana de patologías cardíacas y respaldando la toma de decisiones clínicas. [Palermi et al., 2025]

Por este motivo, el análisis y utilización de estos registros con fines diagnósticos y terapéuticos requiere de un nivel profundo de conocimiento, tanto de la anatomía como de la fisiología cardíaca. [Surawicz and Knilans, 2008] [Silverthorn, 2019]

En particular, resulta imprescindible la realización de un estudio previo y detallado de la estructura del corazón (incluyendo sus cavidades y válvulas, así como su sistema de conducción eléctrica) con el objetivo de comprender correctamente el tipo de gráficas obtenidas, así como interpretar adecuadamente las ondas, segmentos y complejos que las conforman. [Bayés de Luna, 2012]

Por lo tanto, antes de abordar el análisis técnico de este tipo de señales, en este apartado se describirá detalladamente la anatomía funcional del corazón, así como la base fisiológica que subyace a la generación y propagación de su señal eléctrica. Esta fundamentación teórica proporcionará los conocimientos necesarios para comprender posteriormente los aspectos técnicos y clínicos del ECG abordados en este trabajo.

Anatomía cardíaca

El corazón es un órgano muscular esencial para la vida, cuya función principal es impulsar la sangre hacia y desde todos los tejidos del organismo, a través de los circuitos pulmonar y sistémico. Esto garantiza el suministro del oxígeno y de los nutrientes necesarios para el metabolismo celular, al tiempo que recolecta el dióxido de carbono y otros productos de desecho metabólico para su posterior eliminación. De esta forma, el corazón constituye el núcleo central del sistema circulatorio, asegurando la homeostasis del medio interno. [Hall, 2021]

Anatómicamente, se encuentra ubicado en la cavidad torácica, más específicamente en la región inferior del mediastino medio, situado por detrás del hueso esternón, entre la segunda y la sexta costilla aproximadamente. Esto se puede observar en la figura 3.1, que aparece en la página 14. A pesar de presentar una posición central, entre los pulmones derecho e izquierdo, se encuentra ligeramente desplazado hacia la izquierda del tórax, por lo que el vértice o ápex del corazón apunta en esta dirección. Por su parte, la base se encuentra orientada hacia la derecha y arriba. [Dalley II and Agur, 2022]

Podemos encontrar una visión general de la localización concreta del corazón, junto a las principales estructuras que lo integran en la vista anteroposterior del mismo de la figura 3.2 y en la vista lateral izquierda de la figura 3.3, las cuales se encuentran en las páginas 14 y 16, respectivamente.

Su tamaño es ligeramente superior al de un puño cerrado, midiendo unos 12 centímetros de largo, 9 cm de ancho y 6 cm de grosor aproximadamente. Su peso oscila entre 250 y 450 gramos en adultos (puesto que se trata de un

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA13

Propiedad	Descripción
Ubicación	Cavidad torácica (mediastino medio), entre los pulmones y detrás del esternón.
Tamaño	12 cm de largo, 9 cm de ancho y 6 cm de grosor aprox.
Peso	Entre 250 y 450 gramos en adultos, dependiendo del sexo y del estado físico.
Forma	Órgano hueco, con el vértice hacia abajo y la izquierda y la base hacia arriba y la derecha.
Estructura externa	Presenta surcos que delimitan las cámaras internas (tabique interventricular, tabique auriculoventricular, etc.).
Tejido principal	Músculo cardíaco o miocardio, recubierto externamente por el pericardio e internamente por el endocardio.
Irrigación	Arterias coronarias izquierda y derecha, que nacen de la base de la aorta.
Inervación	Inervado por el sistema nervioso autónomo (simpático y parasimpático) a través del plexo cardíaco.

Tabla 3.1: Principales características morfológicas del corazón. *Elaboración propia.*

órgano hueco en su interior), siendo generalmente mayor en los hombres o personas deportistas. [Tortora and Derrickson, 2018]

Estas características, junto con otras que se explican más adelante, se encuentran recogidas en la tabla 3.1, localizada en la página 13.

En conjunto, la ubicación, orientación y dimensiones del corazón reflejan su adaptación funcional como bomba central del sistema cardiovascular.

Anatomía macroscópica. Estructuras y cavidades cardíacas

A nivel interno, el corazón se encuentra dividido en cuatro cavidades principales, dispuestas en dos mitades funcionales, derecha e izquierda. Cada mitad consta de una aurícula en la zona superior y un ventrículo en el área inferior, dando lugar a las siguientes estructuras: aurícula derecha, aurícula izquierda, ventrículo derecho y ventrículo izquierdo. [Dalley II and Agur, 2022] [Hall, 2021]

Estos compartimentos se encuentran separados por tabiques musculares (el tabique interauricular y el tabique interventricular) y establecen comuni-

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA15

cación entre ellos a través de válvulas cardíacas especializadas (tricúspide, mitral, pulmonar y aórtica), cuya función principal es asegurar una circulación de la sangre unidireccional, previniendo así la mezcla de la sangre arterial (oxigenada) y venosa (desoxigenada), así como el reflujo a lo largo del ciclo cardíaco. [Dalley II and Agur, 2022] [Tortora and Derrickson, 2018] [Hall, 2021]

Gracias a su estructura hueca y compartimentada, el corazón permite establecer un flujo sanguíneo eficiente que se organiza en dos circuitos bien diferenciados. Esta doble circulación es clave para mantener la homeostasis y la eficiencia del sistema cardiovascular. [Hall, 2021] [Silverthorn, 2019]

El más corto de los dos, el circuito pulmonar o menor, transporta la sangre desoxigenada desde el corazón (ventrículo derecho) hasta los pulmones y de vuelta a este, una vez realizado el intercambio gaseoso. Por su parte, el circuito sistémico o mayor, se encarga de hacer llegar la sangre oxigenada al resto de estructuras corporales y recoger los correspondientes deshechos metabólicos producidos en estas. [Dalley II and Agur, 2022]

Cavidades cardíacas A continuación, se describen detalladamente las principales cavidades cardíacas, junto a las estructuras anatómicas clave para el correcto funcionamiento del sistema circulatorio. La tabla 3.2 situada en la página 18 resume estas cavidades junto a sus estructuras asociadas.

Estas se pueden ubicar visualmente en la página 17, concretamente en la figura 3.4, junto a los grandes vasos que entran y salen desde ellas, figura 3.5 de la página 18.

- **Aurícula derecha:** Esta cavidad con forma de cámara, es la receptora de la sangre venosa procedente de las distintas ubicaciones del organismo, a través de dos vasos principales: las venas cavas. La vena cava superior recoge la sangre en la parte alta del organismo, mientras que la vena cava inferior se encarga de la región baja. Esta sangre se encuentra desoxigenada, es decir, se caracteriza por presentar una baja concentración de oxígeno y alta en dióxido de carbono. [Hall, 2021][Tortora and Derrickson, 2018]

Cabe destacar que en su interior podemos encontrar lo que se conoce como "marcapasos natural del corazón". Este es el nodo sinoauricular, que se encarga de iniciar el impulso eléctrico, suceso que actúa como regulador de la contracción cardíaca. [Marieb, 2008]

- **Ventrículo derecho:** Esta cámara recibe la sangre desoxigenada desde la aurícula derecha a través de la válvula tricúspide. Su función




Figura 3.3: Visión del corazón desde la mitad lateral izquierda del mediastino.
Fuente: [H et al., 2019]

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA17




Figura 2-6. Tabiques del corazón.

Figura 3.4: Principales cavidades cardíacas. Fuente: [Saturno Chiu, 2017]

principal es oxigenar esta sangre. Para ello, el ventrículo bombea esta a través de la arteria pulmonar (a la cual accede por la válvula pulmonar) hasta los pulmones, donde se producirá el correspondiente intercambio gaseoso. [Dalley II and Agur, 2022] [Tortora and Derrickson, 2018]

La pared muscular de este ventrículo presenta un menor grosor que la del ventrículo izquierdo. Esto se debe a que el derecho impulsa la sangre a través del circuito menor o pulmonar, el cual requiere de una menor presión de bombeo, como consecuencia de la proximidad y de la baja resistencia vascular de los pulmones. [Hall, 2021]

- **Aurícula izquierda:** Esta cavidad recibe la sangre que viene desde los pulmones a través de las cuatro venas pulmonares (dos procedentes de cada pulmón). Esta se encuentra ya oxigenada, es decir, presenta una elevada concentración de oxígeno tras el intercambio gaseoso que ha tenido lugar en el interior de los alvéolos pulmonares. Por lo tanto, ya se encuentra lista para ser enviada al resto del cuerpo. [Tortora and Derrickson, 2018] [Hall, 2021] [Standring, 2020]
- **Ventrículo izquierdo:** Esta cámara se encarga de bombear la sangre oxigenada desde el corazón hacia el resto del cuerpo. Para ello, la sangre oxigenada llega al ventrículo desde la aurícula izquierda a través de la válvula mitral o bicúspide y lo abandona, posteriormente, a través de la válvula aórtica para alcanzar la arteria aorta, distribuyéndose así por el organismo e irrigando los diferentes órganos y tejidos. [Dalley II and Agur, 2022] [Klabunde, 2012]

En este caso, al formar parte del circuito sistémico, las paredes del ventrículo izquierdo presentan un mayor grosor con respecto al derecho y a




Figura 3.5: Principales vasos sanguíneos del corazón. Fuente: [Vélez et al., 2010]

Cavidad	Sangre	Entrada	Salida	Válvula
AD	Desoxigenada	Venas cavas	Ventrículo Derecho	Tricúspide
VD	Desoxigenada	Aurícula derecha	Arteria pulmonar	Pulmonar
AI	Oxigenada	Venas pulmonares	Ventrículo Izquierdo	Mitral
VI	Oxigenada	Aurícula izquierda	Arteria Aorta	Aórtica

Tabla 3.2: Resumen de las cuatro cavidades cardíacas y sus estructuras asociadas (entrada, salidad y válvulas). *Elaboración propia.*

ambas aurículas. Esto es necesario para alcanzar las elevadas presiones de bombeo y demandas hemodinámicas de las que requiere, venciendo así la resistencia vascular de este circuito sistémico, que abarca la totalidad del organismo. [Hall, 2021] [Tortora and Derrickson, 2018]

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA19

Características	Tabique Interauricular	Tabique Interventricular
Localización	Entre las dos aurículas	Entre los dos ventrículos
Composición	Tejido fibroso (principalmente) y muscular	Tejido muscular (mayoritariamente y membranoso (poco))
Función principal	Evitar la mezcla de sangre arterial y venosa	Soportar la presión sistólica y evitar la mezcla sanguínea
Patologías asociadas	Foramen oval permeable	Defectos del tabique interventricular (DVI)
Relevancia clínica	Accidentes cerebrovasculares	Insuficiencias cardíacas o hipertensión pulmonar

Tabla 3.3: Principales características de los tabiques cardíacos. *Elaboración propia.*

Tabiques del corazón Las cavidades cardíacas descritas anteriormente se encuentran delimitadas por paredes musculares conocidas como tabiques cardíacos, las cuales permiten la división del corazón en dos mitades funcionales: derecha e izquierda. [Hall, 2021] [Boron and Boulpaep, 2016] Estos se pueden observar en la imagen 3.4 de la página 17.

La función principal de estas estructuras reside en delimitar y separar las distintas cavidades en las que se compartimenta el corazón. El objetivo principal de esta delimitación interna es evitar la mezcla de la sangre entre las dos mitades funcionales, la derecha, que alberga la sangre desoxigenada o venosa y, la izquierda, que alberga sangre oxigenada o arterial. [Braunwald et al., 2014]

A su vez, esta separación es fundamental para asegurar una circulación sanguínea unidireccional y eficiente, tanto en el interior de este órgano como en el resto de las localizaciones anatómicas. [Klabunde, 2012]

A continuación, se va a detallar la anatomía y características de cada uno de los dos tabiques principales que separan las mitades funcionales del corazón, destacando su gran importancia para el correcto funcionamiento del sistema circulatorio. La tabla 3.3 de la página 19 muestra estas características de forma visual.

- **Tabique o septo interauricular:** Este tabique, formado principalmente por tejido fibroso y muscular, se localiza en la mitad superior del corazón, separando la aurícula derecha de la aurícula izquierda. [Boron and Boulpaep, 2016] [Hall, 2021]

Durante su formación, en el desarrollo fetal, este tabique no aísla el espacio existente entre las dos aurículas por completo, sino

que se establece una comunicación entre ambas a través de la estructura conocida como foramen oval. [Boron and Boulpaep, 2016] [Braunwald et al., 2014] Esta permite el flujo sanguíneo entre las dos aurículas, sin necesidad de que la sangre recorra el sistema pulmonar, que en esta etapa no se encuentra aún preparado para el intercambio gaseoso. [Hall, 2021]

En condiciones normales, esta apertura entre ambas, se sella tras el nacimiento, con la primera respiración y el comienzo del funcionamiento pulmonar. Este hecho acarrea un aumento de presión en la aurícula izquierda, que termina por cerrar el foramen oval. [Braunwald et al., 2014] Este cierre suele ser completo, dando lugar a una depresión visible en la pared interna de la aurícula derecha, conocida como fosa oval. [Boron and Boulpaep, 2016] Sin embargo, en algunos casos, este cierre no es total, y nos encontramos con la condición denominada foramen oval permeable, la cual puede implicar consecuencias de relevancia clínica, como aumento del riesgo de sufrir un accidente cerebrovascular. [Braunwald et al., 2014] [Hall, 2021]

- **Tabique o septo interventricular:** Este tabique se localiza entre ambos ventrículos, derecho e izquierdo. Por este motivo, su pared está compuesta principalmente por tejido muscular, ya que debe ser una estructura muy gruesa y robusta. Esto es necesario puesto que tiene que ser capaz de soportar las elevadas condiciones de presión que se generan en la cavidad ventricular durante la contracción (sístole), a la vez que debe mantener completamente separados de manera efectiva ambos circuitos sanguíneos, pulmonar y sistémico. [Boron and Boulpaep, 2016] [Hall, 2021]

Al igual que el tabique interauricular, este tabique no solo cumple una función estructural, sino que también presenta una gran importancia clínica. Al participar de forma activa en la circulación sanguínea, los posibles defectos o malformaciones congénitas en él, como el defecto del tabique interventricular (DVI), pueden provocar alteraciones graves en la dinámica circulatoria por una comunicación no debida entre los ventrículos (mezcla de sangre oxigenada y desoxigenada). Se pueden llegar a dar incluso complicaciones severas, con episodios de insuficiencia cardíaca o hipertensión pulmonar. [Braunwald et al., 2014]

Este tabique se puede separar anatómicamente en dos porciones:

1. **Porción muscular:** Esta porción es la más abundante y gruesa de las dos. Se encuentra formada por músculo cardíaco, que

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA 21

proporciona la robustez y resistencia necesaria para soportar el aumento de presión durante la fase de sístole. [Boron and Boulpaep, 2016]

2. **Porción membranosa:** Esta porción se localiza en la parte superior del tabique, cerca de las válvulas cardíacas y el sistema de conducción eléctrica, por lo que presenta un menor grosor y una naturaleza fibrosa.

Sin embargo, es de vital importancia en el funcionamiento del corazón, ya que presenta un papel fundamental en la transmisión del impulso eléctrico a través del haz de His. [Braunwald et al., 2014]

Como conclusión, podemos destacar la gran importancia de estos tabiques, tanto a nivel de aislamiento funcional de las mitades derecha e izquierda del corazón, como a nivel de desarrollo embrionario o a nivel de propagación del impulso eléctrico. Por lo tanto, podemos sentenciar que su integridad es fundamental para el correcto funcionamiento del sistema cardiovascular. [Hall, 2021]

Válvulas cardíacas La circulación sanguínea en el interior del corazón no depende únicamente de la anatomía de las cuatro cavidades que actúan como cámaras de bombeo y de los tabiques que separan estas, sino que también se ve afectada por la forma de comunicación entre estas, y con el exterior. La correcta comunicación entre ellas se debe en gran medida a un funcionamiento apropiado de las válvulas cardíacas. [Tortora and Derrickson, 2018] [Hall, 2021]

La función principal de estas reside en regular el flujo sanguíneo para que sea óptimo entre las aurículas y ventrículos, así como entre los ventrículos y las arterias principales. Esto se debe a los procesos de sístole y diástole, evitando así el reflujo o retroceso, y con ello, la mezcla de la sangre oxigenada y desoxigenada, garantizando que la circulación sanguínea sea unidireccional y la eficiencia hemodinámica a lo largo del ciclo cardíaco. [Mohrman and Heller, 2024] [Koeppen and Stanton, 2018]

En el apartado que se encuentra a continuación se describen detalladamente, junto a su mecanismo de acción.

Sin embargo, en la tabla 3.4, que se encuentra en la página 22 podemos encontrar un resumen gráfico acerca de las fases del ciclo cardíaco y las implicaciones de estas válvulas en este.

Mientras tanto, en la tabla 3.5, situada en la página 22 podemos observar cómo se relaciona la apertura y cierre de las distintas válvulas con las

Fase	Estado de la cavidad	Válvula/s implicadas	Movimiento de sangre
Diástole auricular	Aurículas relajadas	-	Llenado pasivo de las aurículas (venas cavas y pulmonares)
Diástole ventricular	Ventrículos relajados	Tricúspide y mitral	Llenado pasivo de los ventrículos ($\approx 80\%$)
Sístole auricular	Aurículas contraídas	Tricúspide y mitral	Llenado activo de los ventrículos ($\approx 20\%$)
Sístole ventricular	Ventrículos contraídos	Pulmonar y aórtica	Expulsión de sangre (arterias pulmonares y aorta)

Tabla 3.4: Fases del ciclo cardíaco y estado de las válvulas implicadas. *Elaboración propia.*

Válvula	Ubicación	Tipo	Fase de apertura	Fase de cierre
Tricúspide	Aurícula derecha → Ventrículo derecho	Auriculoventricular	Diástole ventricular	Sístole auricular
Pulmonar	Ventrículo derecho → Arteria pulmonar	Semilunar	Sístole ventricular	Diástole ventricular
Mitral o bicúspide	Aurícula izquierda → Ventrículo izquierdo	Auriculoventricular	Diástole ventricular	Sístole ventricular
Aórtica	Ventrículo izquierdo → Aorta	Semilunar	Sístole ventricular	Diástole ventricular

Tabla 3.5: Relación de las válvulas cardíacas con las fases del ciclo cardíaco. *Elaboración propia.*

distintas fases del ciclo cardíaco, así como con el paso de la sangre entre las distintas cavidades en el interior del corazón.

1. **Válvula tricúspide:** Esta válvula se encuentra situada entre la aurícula y el ventrículo derecho, regulando el flujo de la sangre venosa (desoxigenada) entre estas dos cavidades. Esto lo hace con el objetivo de evitar el reflujo de la sangre durante el proceso de contracción ventricular (sístole). Figura 3.4 de la página 17[Marieb, 2008]

Este proceso se divide en dos etapas, las cuales se corresponden con dos fases principales del ciclo cardíaco, las cuales se van a explicar más en profundidad en el apartado 'Fisiología del corazón':

- **Diástole ventricular:** Durante esta fase, el ventrículo derecho se encuentra relajado y la válvula tricúspide permanece abierta. Debido a esta conformación, se establece una diferencia de presión entre la aurícula y el ventrículo, que hace que la sangre fluya en esta dirección. Durante el tiempo que dura esta condición,

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA 23

se desplaza aproximadamente un 80 % del volumen de sangre total que ha entrado al corazón a lo largo de la fase anterior. [Silverthorn, 2019] [Mohrman and Heller, 2024]

- **Sístole auricular:** Durante los últimos instantes que dura la diástole ventricular comienza la sístole auricular. En este momento, la aurícula derecha se contrae, ejerciendo una presión que hace que la sangre restante en esta cavidad (aproximadamente el 20 %) pase al ventrículo. Esto tiene lugar durante la preparación para la contracción o sístole ventricular, antes de que se produzca el cierre de la válvula auriculoventricular tricúspide, hecho que evita el paso inverso de la sangre hacia la aurícula nuevamente. [Silverthorn, 2019] [Barret et al., 2019]

2. **Válvula pulmonar:** Esta válvula semilunar se localiza entre el ventrículo derecho y la arteria pulmonar. Su función principal es permitir el paso de la sangre entre este ventrículo y la arteria pulmonar. Figura 3.4 de la página 17 [Mohrman and Heller, 2024]

Este flujo permite que la sangre alcance la arteria pulmonar, que la va a conducir hasta los alvéolos pulmonares, donde se producirá el intercambio gaseoso, y la correspondiente oxigenación sanguínea. [Widmaier et al., 2018]

La apertura de esta válvula tiene lugar durante el proceso de sístole ventricular, en el que el ventrículo derecho se contrae. Esto ocurre tras el llenado de la cavidad ventricular en la fase anterior del ciclo. La creciente presión a medida que aumenta el volumen sanguíneo en la cavidad, hace que se cierre en un primer momento la válvula tricúspide. Este hecho hace que aumente aún más la presión interna del ventrículo, hasta alcanzar el valor que produce la apertura de la válvula pulmonar. [Hall, 2021]

Al finalizar este proceso de contracción y disminuir la presión en su interior, la válvula se cierra, controlando que no se produzca un episodio de reflujo una vez que la sangre ha sido expulsada del corazón.

3. **Válvula mitral:** Esta válvula, también conocida como válvula bicúspide, se sitúa en la mitad funcional izquierda del miocardio, concretamente entre la aurícula y el ventrículo izquierdo. Por lo tanto, como consecuencia de su posición, se encarga de regular el flujo de la sangre oxigenada (arterial) entre la aurícula izquierda y el ventrículo izquierdo. [Marieb, 2008]

La función correcta de esta estructura es de gran importancia, ya que de ella depende que se mantenga la presión adecuada y que la circulación sistémica sea eficiente. Alguna disfunción de la misma, como la insuficiencia o la estenosis mitral puede conllevar consecuencias importantes, tales como patologías cardíacas debido a un trastorno de su funcionamiento o, incluso, puede llegar a comprometer la hemodinámica general del organismo. [Braunwald et al., 2014]

Al igual que ocurría con el paso de la sangre desde la aurícula al ventrículo derecho, este proceso se divide en dos partes:

- **Díastole ventricular (relajación):** Durante la etapa de díastole auricular (relajación), esta válvula permanece cerrada mientras se va llenando dicha cavidad. Sin embargo, una vez que alcanza una cierta presión y se cierra la válvula que regula la entrada de la sangre en la aurícula, la válvula mitral se abre, permitiendo la entrada de la sangre al ventrículo izquierdo. [Klabunde, 2012]

Este hecho marca el comienzo de la etapa conocida como díastole ventricular, ya que esta cavidad se va llenando de sangre por una diferencia de presiones que se establece entre la aurícula y el ventrículo. Es decir, este llenado se produce de forma pasiva, y corresponde aproximadamente al 80 % del volumen sanguíneo que se encontraba en la aurícula previamente. [Hall, 2021]

- **Sístole auricular (contracción):** Una vez que se ha casi completado el llenado del ventrículo izquierdo (70 - 80 % aproximadamente), comienza la fase de sístole auricular.

Esta fase conlleva la contracción de la aurícula, haciendo que el volumen sanguíneo restante en la cavidad auricular (20 % aproximadamente) pase al ventrículo, completando el llenado de este. [Hall, 2021]

Una vez que este ventrículo se llena por completo, dicha válvula se cierra como paso previo a la sístole ventricular. Esto ocurre con el objetivo de evitar el reflujo sanguíneo, evitando que la sangre vuelva nuevamente a pasar a la aurícula izquierda. Por ello, esta válvula es necesaria para garantizar la unidireccionalidad de la circulación sanguínea. [Boron and Boulpaep, 2016]

4. **Válvula aórtica:** Esta última válvula se sitúa en la mitad funcional izquierda del corazón, concretamente entre la cavidad ventricular izquierda y la arteria aorta. [Boron and Boulpaep, 2016]

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA 25

La función de esta válvula es invaluable, ya que de ella depende la circulación sanguínea a nivel sistémico. Su correcto funcionamiento asegura que la sangre alcance la arteria aorta, la cual se va a ir ramificando hasta alcanzar los distintos órganos y tejidos del organismo, irrigándolos, asegurando así una presión arterial adecuada y un flujo unidireccional. [Braunwald et al., 2014]

Esta válvula permanece cerrada durante el llenado del ventrículo izquierdo, proceso de diástole ventricular. Esto evita que la sangre retorne hacia la aurícula, asegurando así un flujo sanguíneo unidireccional. Sin embargo, una vez que el ventrículo izquierdo ha alcanzado su volumen máximo, la válvula mitral se cierra. Esto hace que la presión en el interior de esta cavidad aumente, provocando la apertura de la válvula aórtica. Esto da lugar al paso de la sangre a la arteria aorta, y a la distribución de la misma, oxigenada, a todas las localizaciones del organismo. [Tortora and Derrickson, 2018] [Hall, 2021]

Una vez que esto ocurre, la válvula se cierra nuevamente hasta el siguiente ciclo cardíaco. Este proceso de cierre constituye el segundo ruido cardíaco, también conocido como 'duplo' o segundo tono. Este evento es de gran importancia para la evaluación del funcionamiento del corazón, tal y como se explica más adelante. [Hall, 2021] [Boron and Boulpaep, 2016]

El funcionamiento de estas válvulas y su implicación en el ciclo cardíaco, controlando el llenado y vaciado de las distintas cavidades cardíacas, así como su mecanismo de acción y funcionalidad se puede ver en las imágenes 3.6, ubicadas en la página 26 y 3.7, página 26.

Pericardio Una vez descritas en profundidad las estructuras internas y cavidades en que se divide el corazón, es conveniente ampliar el enfoque anatómico y abordar el estudio del pericardio. Esta estructura se asemeja en gran medida a un saco membranoso de naturaleza fibrosa y presenta una gran influencia sobre el correcto funcionamiento del corazón, núcleo del sistema circulatorio. [Mohrman and Heller, 2024]

Por este motivo, resulta fundamental exponer su anatomía, estructura y funcionalidad, con el fin de poder comprender su relevancia tanto en condiciones fisiológicas como en contextos clínicos y así adquirir una visión integral y profundidad acerca del entorno en que el corazón lleva a cabo su actividad habitual.




Figura 3.6: Válvulas principales del corazón. Fuente: [Texas Heart Institute,]




Figura 3.7: Sucesión de fases del ciclo cardíaco. Fuente: [Saturno Chiu, 2017]

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA 27

Capa del pericardio	Localización	Tipo de tejido
Pericardio fibroso	Capa externa y resistente	Tejido conectivo denso no especializado
Pericardio seroso parietal	Capa interna del pericardio fibroso	Epitelio plano simple (mesotelio)
Cavidad pericárdica	Espacio entre la hoja parietal y visceral del pericardio seroso	Entre 15 y 50 ml de líquido pericárdico
Pericardio seroso visceral (epicardio)	Capa más interna, en contacto directo con el miocardio	Epitelio plano simple y tejido conectivo subyacente

Tabla 3.6: Composición y localización de las capas del pericardio. *Elaboración propia*

Anatómicamente, esta membrana fibrosa que recubre al corazón se encuentra formada por una superposición de dos capas, formadas por dos tejidos distintos. Estas son:

1. **Pericardio fibroso:** Esta es la capa pericárdica externa, por lo que se trata de la más resistente de las dos. Está formada por tejido conectivo denso no especializado. [Wineski, 2018]
2. **Pericardio seroso:** Esta capa se encuentra en una posición más interna y se divide a su vez en otras dos hojas o capas: parietal (por debajo de la hoja fibrosa, formada por mesotelio, que es un tipo de epitelio plano simple) y visceral o epicardio (recubre el corazón y se encuentra formado por epitelio plano simple y por tejido conectivo). [Saturno Chiu, 2017] El espacio que se dispone entre ambas constituye la cavidad pericárdica, y se encuentra lleno de líquido pericárdico. [Young et al., 2013]

Esta conformación del pericardio en forma de capas le proporciona al corazón la capacidad de moverse libremente en el interior del mediastino, una cavidad cerrada y lubricada, sin peligro de comprometer su eficiencia mecánica. Estas se pueden visualizar en la imagen 3.8 de la página 28, a la vez que se visualizan sus detalles en la tabla 3.6 de la página 27

Desde el punto de vista fisiológico, el pericardio cumple diversas funciones esenciales. Se trata de una de las estructuras encargadas de proporcionar soporte, protección y estabilidad al corazón. Concretamente, se encarga de proteger al mismo, envolviéndolo y actuando como barrera mecánica frente a las posibles agresiones externas o traumatismos, a la vez que




Figura 3.8: Capas que conforman el pericardio. Fuente: [Quinn, Matt,]

lo fija y estabiliza dentro de una posición concreta dentro del tórax, la cavidad cardíaca. [Mohrman and Heller, 2024] [Wineski, 2018] Asimismo, también reduce la fricción que genera dicho órgano con su constante actividad contráctil durante el bombeo sanguíneo, evitando la distensión en exceso en situaciones de sobrecarga, a la vez que regula el volumen sanguíneo que entra y sale de su interior a lo largo del ciclo cardíaco. [Young et al., 2013]

Anatomía microscópica. Histología del corazón

Tras el análisis detallado de la anatomía macroscópica del corazón, resulta fundamental profundizar en su organización microscópica. Este enfoque permite comprender con mayor precisión no solo el funcionamiento mecánico del órgano, sino también sus propiedades bioeléctricas, contráctiles y adaptativas, esenciales para su papel como bomba impulsora de la sangre. [Dalley II and Agur, 2022] [Hall, 2021]

Desde el punto de vista histológico, la pared cardíaca está constituida por tres capas superpuestas: el endocardio, el miocardio y el epicardio. Estas estructuras, junto con el pericardio que envuelve externamente al corazón, conforman un sistema integrado tanto estructural como funcionalmente.

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA 29

[[Standring, 2020](#)] Además, se consideran otras componentes esenciales como el sistema de conducción, de gran relevancia para mantener la actividad cardíaca normal. [[Boron and Boulpaep, 2016](#)] [[Tortora and Derrickson, 2018](#)]

Endocardio El endocardio es la capa más interna de la pared cardíaca. Está formado por un epitelio plano simple, conocido como endotelio, y un tejido conectivo subendotelial. Esta capa recubre las cavidades internas del corazón y se continúa de forma directa con el revestimiento endotelial de los vasos sanguíneos. Además, recubre las válvulas cardíacas, las cuales están formadas por tejido conjuntivo denso cubierto también por endotelio. [[Dalley II and Agur, 2022](#)] [[Young et al., 2013](#)]

Entre las funciones principales de esta estructura encontramos las siguientes:

1. Facilitar el flujo laminar de la sangre reduciendo la fricción sobre las paredes internas.
2. Proteger las estructuras subyacentes gracias a sus propiedades anti-coagulantes y antiadhesivas.
3. Servir como barrera selectiva entre la sangre y el miocardio. [[Hall, 2021](#)]

Miocardio El miocardio es la capa media y la más gruesa de la pared cardíaca. Está constituido por músculo cardíaco estriado, cuyas células especializadas, los cardiomiocitos, presentan una estructura alargada y ramificada, con estriaciones transversales y núcleos centrales. [[Dalley II and Agur, 2022](#)] Estas células están conectadas entre sí por discos intercalares, estructuras especializadas que permiten la unión mecánica y eléctrica entre células adyacentes, asegurando una contracción coordinada. [[Tortora and Derrickson, 2018](#)]

El grosor del miocardio varía entre las distintas cavidades del corazón, siendo especialmente robusto en el ventrículo izquierdo, debido a la necesidad de generar mayor presión para impulsar la sangre a través de la circulación sistémica. [[Hall, 2021](#)] Además, este tejido está dotado de un sistema de irrigación propio, compuesto por las arterias coronarias, que aseguran el suministro constante de oxígeno y nutrientes. [[Standring, 2020](#)]

Epicardio El epicardio, o capa visceral del pericardio seroso, es la capa más externa de la pared cardíaca. Está formado por tejido conectivo laxo,

vasos sanguíneos, nervios y una capa superficial de células mesoteliales. [Tortora and Derrickson, 2018] Su función principal es proteger al corazón y permitir su movimiento sin fricción dentro del saco pericárdico, gracias a la secreción de líquido pericárdico. [Dalley II and Agur, 2022]

Además de su función protectora, el epicardio contiene elementos del sistema vascular y nervioso que participan en la nutrición y regulación del miocardio. [Hall, 2021]

Tejido de conducción Distribuido dentro del miocardio se encuentra el sistema de conducción cardíaco, formado por células musculares especializadas no contráctiles. Estas células generan y transmiten impulsos eléctricos que regulan el ritmo de contracción cardíaca. El sistema incluye el nódulo sinoauricular, el nódulo auriculoventricular, el haz de His y las fibras de Purkinje. Este sistema permite que el corazón funcione de manera autónoma y rítmica, aunque sujeto a modulación por el sistema nervioso autónomo. [Hall, 2021] [Dalley II and Agur, 2022]

Fisiología del corazón

El corazón constituye el epicentro del sistema circulatorio, desempeñando una función vital: bombear la sangre a través de los circuitos pulmonar y sistémico. Esto permite que la sangre oxigenada y rica en nutrientes llegue a todas las localizaciones tisulares del organismo, al tiempo que recoge la sangre desoxigenada, rica en dióxido de carbono y productos de desecho producidos por las células, para su posterior filtrado y envío al sistema pulmonar, encargado de su oxigenación, tal y como se ha mencionado en los apartados precedentes de este trabajo. [Hall, 2021]

Este proceso de bombeo sanguíneo se conoce como ciclo cardíaco y tiene una duración aproximada de 0,8 segundos. Este ciclo se encuentra regulado por un sistema eléctrico interno que genera impulsos bioeléctricos en el tejido miocárdico. [Koeppen and Stanton, 2018] A lo largo de este ciclo, se produce una sucesión de dos procesos: la contracción (sístole), de menor duración, y la relajación (diástole) de sus cámaras. La alternancia de estas fases tiene lugar de una forma coordinada y rítmica, asegurando así un flujo sanguíneo continuo y unidireccional. Además, esta combinación garantiza una perfusión suficiente y eficaz del organismo, a la vez que permite la recuperación del músculo cardíaco entre latidos. [Tortora and Derrickson, 2018] [Katz, 2010]

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA31




Figura 3.9: Ciclo cardíaco, onda de ECG y estructuras del sistema de conducción eléctrica. *Elaboración propia*

La representación del ciclo cardíaco, junto a las estructuras que participan en el mismo y la onda de ECG correspondiente, se puede observar en la imagen 3.9 de la página 31.

El sistema eléctrico especializado que coordina la actividad mecánica del corazón se encuentra compuesto por estructuras como el nodo sinuauricular, el nodo auriculoventricular o el sistema de His-Purkinje. [Koeppen and Stanton, 2018] Estas estructuras son las responsables de la generación y conducción de los impulsos eléctricos, propagándolos a través del miocardio. Este hecho va a provocar la contracción y relajación controlada de las cámaras cardíacas. [Dalley II and Agur, 2022] [Longo et al., 2023]

El electrocardiograma (ECG) es una herramienta diagnóstica básica que registra la actividad tanto eléctrica como mecánica del corazón a partir de las señales eléctricas que se suceden en su interior y permite estudiar las ondas generadas. [Surawicz and Knilans, 2008] Para poder analizar e interpretar la morfología de las ondas que se reflejan en el ECG, es imprescindible conocer en profundidad los fundamentos teóricos y funcionales del ciclo cardíaco. Asimismo, su estudio nos va a permitir relacionar las alteraciones o anomalías de estas ondas con las patologías o trastornos cardíacos, facilitando su diagnóstico y tratamiento. [Luo and Johnston, 2010] [Wagner and Strauss, 2014]

Ciclo cardíaco: Sístole y Diástole

El corazón es un órgano muscular vital que actúa como una bomba doble, asegurando el transporte continuo de sangre a todo el organismo. Para comprender su función, es fundamental analizar el ciclo cardíaco, el sistema de conducción eléctrica y los circuitos de circulación sanguínea.

Ciclo cardíaco El ciclo cardíaco comprende el conjunto de eventos mecánicos y eléctricos que tienen lugar durante un latido completo del corazón. Este proceso continuo asegura un flujo sanguíneo constante y adecuado para mantener la oxigenación y nutrición de los tejidos del organismo. El ciclo se divide principalmente en dos fases alternas y coordinadas: la diástole (relajación) y la sístole (contracción), que permiten el llenado y vaciado secuencial de las cavidades cardíacas, garantizando un bombeo sanguíneo unidireccional y eficiente. En condiciones de reposo, este ciclo dura aproximadamente 0.8 segundos, lo que se traduce en una frecuencia cardíaca media de 70-75 latidos por minuto. [Klabunde, 2012]

Diástole La diástole es la fase de relajación del músculo cardíaco. Durante la misma, las cavidades del corazón se llenan de sangre. En esta etapa, las válvulas auriculoventriculares (mitral y tricúspide) se encuentran abiertas, permitiendo el paso de la sangre desde las aurículas hacia los ventrículos. Simultáneamente, las válvulas semilunares (pulmonar y aórtica) permanecen cerradas para evitar el retroceso de la sangre ya impulsada. Hacia el final de esta fase, las aurículas se contraen (contracción auricular) para asegurar el llenado completo de los ventrículos. [Hall, 2021]

Sístole La sístole es la fase de contracción del músculo cardíaco. Se inicia una vez los ventrículos están llenos. Durante esta fase, las válvulas auriculoventriculares se cierran para impedir el reflujo de sangre hacia las aurículas. Posteriormente, los ventrículos se contraen con fuerza, impulsando la sangre hacia la circulación pulmonar y sistémica. Para permitir esta expulsión, las válvulas semilunares se abren, permitiendo la salida de la sangre hacia la arteria pulmonar y la aorta, respectivamente [Tortora and Derrickson, 2018]

Sistema de conducción eléctrica El latido cardíaco está intrínsecamente controlado por un sistema eléctrico interno especializado en generar y propagar impulsos, asegurando así una contracción muscular coordinada y

3.1. FUNDAMENTOS DE LA ANATOMÍA Y FUNCIÓN CARDÍACA 33

eficiente. Este sistema permite al corazón adaptar tanto su frecuencia como su fuerza de latido para cubrir con las necesidades fisiológicas del organismo. [Braunwald et al., 2014]

Los componentes clave para el correcto funcionamiento de este sistema son:

Nodo Sinoauricular (SA) Situado en la pared superior de la aurícula derecha, es considerado el marcapasos natural del corazón. Genera impulsos eléctricos espontáneos a una frecuencia de aproximadamente 60-100 impulsos por minuto en condiciones normales. [Hall, 2021]

Nodo Auriculoventricular (AV) Ubicado en la unión entre aurículas y ventrículos, recibe el impulso del nodo SA. Su función crucial es retrasar ligeramente la señal (aproximadamente 0.1 segundos). Este retraso es esencial para permitir que las aurículas completen su contracción y, por ende, el llenado ventricular, antes de que los ventrículos se contraigan. [Tortora and Derrickson, 2018]

Haz de His Una vez pasado el nodo AV, el impulso eléctrico se propaga a través de este haz de fibras especializadas que atraviesa el tabique interventricular.

Fibras de Purkinje Son las ramificaciones terminales del Haz de His que distribuyen rápidamente el impulso eléctrico a las fibras musculares de los ventrículos. Esta distribución rápida asegura una contracción ventricular sincronizada y eficiente. [Klabunde, 2012]

La actividad eléctrica generada por este sistema es fundamental para un adecuado funcionamiento cardíaco y puede ser registrada externamente a través de un electrocardiograma (ECG), reflejando los eventos eléctricos del ciclo cardíaco. [Klabunde, 2012]

Circuitos de la circulación sanguínea Para comprender mejor el papel del corazón en el transporte de la sangre, es fundamental entender que impulsa la sangre a través de dos circuitos principales que trabajan de manera coordinada y alterna para asegurar el suministro continuo de sangre oxigenada y la eliminación del dióxido de carbono. [Dalley II and Agur, 2022]

El circuito pulmonar transporta sangre desoxigenada desde el ventrículo derecho hacia los pulmones, a través de la arteria pulmonar. En los pulmones, se produce el intercambio gaseoso, donde la sangre libera dióxido de carbono y capta oxígeno. Posteriormente, la sangre ya oxigenada retorna a la aurícula izquierda a través de las venas pulmonares. [Hall, 2021]

Por otro lado, el circuito mayor o sistémico impulsa la sangre oxigenada desde el ventrículo izquierdo hacia el resto del cuerpo a través de la arteria aorta, garantizando el aporte de oxígeno y nutrientes a todos los órganos y tejidos. Después de distribuir el oxígeno y recoger los productos de desecho metabólico (como el dióxido de carbono), la sangre desoxigenada regresa a la aurícula derecha a través de las venas cavas. [Klabunde, 2012]

3.2. Fundamentos de la señal electrocardiográfica (ECG)

La actividad eléctrica del corazón, descrita en el apartado anterior, es fundamental para el correcto funcionamiento de este órgano. Por ello, a través del análisis de esta actividad eléctrica, se puede evaluar indirectamente el comportamiento mecánico del corazón, ya que ambos procesos se encuentran estrechamente relacionados. [Hall, 2021]

Este análisis se realiza a través del electrocardiograma (ECG), una herramienta que registra la actividad eléctrica cardíaca de una forma no invasiva. Como resultado, se obtiene una señal analógica, es decir, una señal con valores continuos en el espectro temporal. [Feather et al., 2020] Esta se mide desde la superficie corporal a través de pares de electrodos. [Goldberger et al., 2000] Por lo tanto, actualmente no es necesario encontrarse en un entorno clínico para llevar a cabo esta medición, sino que también puede realizarse con ayuda de dispositivos portátiles o *wearables*, hecho que amplía su rango de aplicación. [Lu et al., 2020]

En el gráfico 3.10 de la página 35 se puede observar el proceso convencional de registro de este tipo de señales de ECG. Sin embargo, estos electrodos también se pueden colocar en otras localizaciones corporales, como la muñeca o los dedos de la mano.

Desde un punto de vista fisiológico, esta prueba es un reflejo directo de los procesos de despolarización y repolarización de las células miocárdicas, que ocurren de forma cíclica a lo largo del funcionamiento cardíaco,




Figura 3.10: Gráfico que recoge la forma de registro habitual de la señal ECG. Fuente: *Elaboración propia*.

actuando como precedente a la contracción mecánica del músculo cardíaco. [Azuaje et al., 2006] Estos eventos dan lugar al patrón característico del ECG, formado por distintas ondas, las cuales representan distintas etapas y eventos específicos del ciclo cardíaco. [Hall, 2021] Las principales ondas y complejos son los siguientes: onda P, complejo QRS y onda T. [Feather et al., 2020]

La morfología de este tipo de señales biológicas, junto a las ondas y complejos que las componen, las podemos observar en la imagen 3.11 de la página 36.

En cuanto a su aplicación, el electrocardiograma es una de las herramientas más ampliamente utilizadas en la práctica sanitaria, debido a su alto valor diagnóstico y de seguimiento de patologías. [Clifford et al., 2017] Su importancia radica en el gran potencial clínico que presenta, puesto que proporciona información valiosa acerca de la frecuencia, el ritmo, la conducción eléctrica y/o posibles alteraciones, tanto a nivel estructural como funcional de este órgano. [Laguna et al., 1997]

El análisis de sus ondas, en términos de duración, amplitud y morfología, permite evaluar el sistema de conducción cardíaco y detectar anomalías y problemas asociados a distintas patologías cardiovasculares. A través de este proceso, se pueden identificar procesos tales como isquemias, arritmias, fibrilaciones o, incluso, trastornos y bloqueos en la conducción auriculoventricular.

Por otra parte, desde una perspectiva computacional, esta señal biomédica no se trata únicamente de un reflejo de la fisiología cardíaca, sino que también constituye una fuente de información con un elevado potencial a




Figura 3.11: Morfología de las señales de ECG y ondas y complejos de estas. Fuente: [Rosas, 2022]

nivel biológico, pese a presentar una serie de inconvenientes o retos técnicos asociados.

Algunos de estos desafíos son: la presencia de ruidos de diversa índole durante su registro, como el ruido muscular, la interferencia de la red eléctrica o los artefactos por movimiento, así como la variabilidad entre pacientes y registros. [Luo and Johnston, 2010] Con el objetivo de abordar estas limitaciones, se hace necesario el empleo de técnicas de procesamiento digital de señales, las cuales van a aplicar modificaciones sobre las mismas, tales como su limpieza, segmentación o incluso su análisis automatizado.

Estas señales de ECG pueden ser tanto monoderivación como multiderivación. Aunque las primeras de ellas son más limitadas y no proporcionan una visión completa y detallada del comportamiento eléctrico del corazón, son suficientes para ciertos tipos de análisis, tales como tareas de clasificación automática o de generación sintética de señales. [Acharya et al., 2017] Asimismo, esta derivación única implica una reducción de la complejidad computacional, beneficiosa a la hora de trabajar con ordenadores de uso personal.

Cabe destacar que el estudio y análisis de estas señales electrocardiográficas es de gran importancia en numerosos contextos, tanto a nivel investigador como clínico, y constituye la base sobre la que se desarrollan numerosas

técnicas, herramientas y proyectos basados en procesamiento y análisis computacional.

Características técnicas de la señal

Como ya se ha indicado, las señales electrocardiográficas representan la actividad eléctrica del corazón mediante ondas y complejos que se identifican con los distintos eventos que tienen lugar a lo largo del ciclo cardíaco. [Hall, 2021] [Feather et al., 2020]

De forma previa a adentrarse en las ondas, complejos y componentes que constituyen estas señales, es de vital importancia comprender en profundidad las características técnicas de este tipo de señales, especialmente aquellas relacionadas con la forma en que se adquieren y representan. [Clifford et al., 2017] [Moody and Mark, 2001]

Esta importancia radica en la influencia directa de estos parámetros sobre el nivel de calidad y de precisión de los datos obtenidos, así como sobre la fiabilidad y utilidad del posterior análisis de las señales. [Addison, 2017] Además, estas propiedades permiten evaluar si la señal es realmente adecuada para su procesamiento y uso en estudios y desarrollos técnicos, así como para su interpretación clínica, tanto a nivel diagnóstico como terapéutico. [Laguna et al., 1997]

Entre las características más importantes a tener en cuenta se encuentran la frecuencia de muestreo, la duración de los registros o la amplitud de la señal, entre otras. [Goldberger et al., 2000] [Pan and Tompkins, 1985]

Estas características principales se resumen, junto a sus valores habituales, en la tabla 3.7, localizada en la página 38.

Estas características o propiedades no solo influyen sobre la calidad de las señales y su utilidad práctica, sino que también condicionan los métodos de procesamiento aplicables sobre estas. [Li et al., 1995] Se pueden ver afectados los mecanismos de filtrado, segmentación o extracción de características, como se desarrolla a lo largo de las siguientes secciones. [Azuaje et al., 2006]

Frecuencia de muestreo

La frecuencia de muestreo es un parámetro fundamental para el proceso de digitalización de cualquier señal analógica. Por lo tanto, las señales de electrocardiograma (ECG) no son una excepción.

Parámetro técnico	Valor típico
Frecuencia de muestreo	250 – 1000 Hz
Duración del registro	10 segundos (estándar), >24 h (monitor Holter)
Amplitud de la señal	0.5 – 5 mV
Sensibilidad de la señal	10 mm/mV
Formato	Serie temporal digital en milivoltios (mV)

Tabla 3.7: Características técnicas habituales de las señales electrocardiográficas

Este concepto se define como el número de veces por segundo que se mide el valor numérico que presenta una señal analógica (continua), es decir, el número de veces que se toma una *instantánea* de esta. [Oppenheim and Schafer, 2010] Su unidad de medida es el hercio (Hz) y, además, cuenta con una funcionalidad característica, permite la conversión de la señal continua en una secuencia discreta de valores con capacidad de representación, almacenamiento y procesamiento en el dominio digital, y viceversa.

Actualmente, dicho proceso de digitalización es crucial, ya que el tratamiento de este tipo de señales se realiza mayoritariamente a nivel computacional. Se elige este formato debido a la forma de almacenamiento, procesamiento y análisis que presenta, utilizando sistemas informáticos para ello. [Oppenheim and Schafer, 2010]

Por lo tanto, el valor de frecuencia de muestreo utilizado durante el registro de las señales no solo afecta al tratamiento, sino que también influye enormemente sobre la calidad y fidelidad de estas señales. Por este motivo, es esencial buscar un equilibrio adecuado entre la frecuencia de adquisición y el nivel de detalle con el que se desea representar la señal que va a ser registrada. La elección de un valor adecuado garantiza que se conserven sus características más relevantes, como los cambios o alteraciones en el complejo QRS, por ejemplo. [Oppenheim and Schafer, 2010]

Una comparación de la calidad y representación de las señales de ECG en función de la frecuencia de muestreo utilizada, se puede observar en la página 39, concretamente en la figura 3.12.

La importancia de dicho equilibrio radica en que valores extremos de frecuencia pueden afectar de forma negativa a la señal, llegando a comprometer su calidad, hacer que pierda información o introducir distorsiones sobre su silueta.




Figura 3.12: Comparación del patrón de una señal de ECG con distintas frecuencias de muestreo. *Elaboración propia*

- **Valores extremadamente bajos:** En el momento en que el valor de la frecuencia es demasiado bajo, el número de muestras obtenido durante el registro de la señal es insuficiente, lo que conlleva una pérdida significativa de información. Este hecho puede hacer que se pierdan características importantes de la señal original, así como que la representación de su morfología no sea óptima y se vea distorsionada, pudiendo llegar a complicar o casi imposibilitar la detección de eventos clínicamente relevantes, como anomalías sutiles en el funcionamiento cardíaco.
- **Valores extremadamente altos:** Cuando el valor de la frecuencia es demasiado alto, el número de mediciones tomado por unidad de tiempo también es excesivo, haciendo que se capturen detalles de la señal innecesarios. Este hecho va a implicar mayores requisitos de almacenamiento y procesamiento, los cuales van a resultar redundantes,

ya que la inversión en ellos no proporciona un beneficio proporcional en términos clínicos y diagnósticos.

En base al **teorema de Nyquist - Shannon**, una especie de *gold standard* teórico para el cálculo de la frecuencia de muestreo óptima, esta debe ser al menos dos veces la **frecuencia de Nyquist**. Este valor de frecuencia se corresponde con el valor máximo de frecuencia presente en la señal de ECG original. [Shannon, 1949]

La **frecuencia de Nyquist** en señales electrocardiográficas suele encontrarse comprendida entre 100 y 150 Hz, lo que sugiere un mínimo teórico de 250 Hz como frecuencia de muestreo segura. Este valor, en principio, debería capturar la mayor parte de la información relevante a partir de estas señales. [Shannon, 1949]

Según la Asociación Americana del Corazón (American Heart Association, AHA), los eventos clínicos más relevantes se pueden detectar con valores de frecuencia comprendidos entre 250 y 1000 Hz. [Kligfield et al., 2007] Por este motivo, las frecuencias de muestreo de la mayoría de dispositivos de registro (electrocardiógrafos) y de bases de datos o repositorios de bioseñales de este tipo se encuentran dentro de este rango. Se emplean estos valores porque establecen una buena resolución de las ondas sin generar cantidades de datos innecesarias, es decir, establecen un equilibrio adecuado entre el número de datos y la calidad de la señal de ECG. [Goldberger et al., 2000] Como ejemplo de esto, se pueden señalar los contextos de investigación y de desarrollo técnico, los cuales cuentan con sistemas de alta resolución para los que se utilizan habitualmente frecuencias de muestreo de entre 360 y 500 Hz.

Las recomendaciones de la AHA y el **teorema de Nyquist - Shannon** se fundamentan en las siguientes razones:

1. **Prevención del *aliasing*:** Una frecuencia de muestreo inferior a la de Nyquist puede producir el denominado proceso de *aliasing*. Este introduce 'artefactos' que hacen que los componentes de alta frecuencia en el registro original no se representen de forma correcta en el contexto digital y se mezclen con los de menor frecuencia. Este hecho puede conllevar la pérdida de información relevante o la creación de patrones de datos engañosos, promovidos por la distorsión de la representación de la señal. [Shannon, 1949]
2. **Mejora de la resolución temporal:** La precisión de las ondas de la señal (P, QRS, T, etc.) depende de la frecuencia de muestreo utilizada. En el

caso de que esta sea adecuada, las ondas se van a representar con una mayor resolución, permitiendo detectar anomalías o patrones en los distintos eventos del ciclo cardíaco que con otros valores de frecuencia pasarían desapercibidos.

3. **Compensación de ruido:** A pesar de que los registros de ECG son ruidosos por naturaleza, este fenómeno se puede atenuar con una frecuencia de muestreo adecuada, favoreciendo la eliminación de artefactos y facilitando el filtrado gracias al margen de seguridad que proporciona.

No obstante, existen situaciones específicas, como la identificación de microvariaciones en la morfología de las ondas, la detección automática de arritmias en tiempo real o la detección de potenciales tardíos, en que frecuencias ligeramente superiores podrían ser recomendables, pero, en ningún caso llegando a alcanzar valores extremos.

En definitiva, una buena elección de la frecuencia de muestreo constituye un parámetro técnico clave para lograr un equilibrio óptimo entre la información diagnóstica que proporciona la señal y la eficiencia en el manejo y tratamiento digital de sus datos. [Azuaje et al., 2006]

Duración de los registros

La duración del registro de una señal ECG es un parámetro fundamental que influye directamente en el tipo de análisis que se puede realizar, en la cantidad de información disponible y en la capacidad diagnóstica del sistema. [Azuaje et al., 2006] [Acharya et al., 2017] Dependiendo del contexto de adquisición y del objetivo del estudio, los registros pueden variar desde unos pocos segundos hasta varias horas o incluso días.

En un entorno clínico convencional, los electrocardiogramas estándar suelen tener una duración aproximada de 10 segundos, siendo este tiempo suficiente para evaluar parámetros como la frecuencia cardíaca, el ritmo y la morfología de las principales ondas (P, QRS, T). [Goldberger et al., 2000] Esta duración corta es adecuada para exploraciones rápidas, seguimiento de pacientes o estudios de cribado, ya que proporciona una visión representativa del comportamiento cardíaco en reposo.

Sin embargo, esta ventana temporal limitada puede no ser suficiente para detectar eventos transitorios o poco frecuentes, como ciertas arritmias esporádicas o alteraciones dinámicas en la conducción. [Wagner and Strauss, 2014]

Por este motivo, en contextos donde se requiere una monitorización más prolongada y continua, se emplean registros de larga duración, como los obtenidos mediante dispositivos Holter, que pueden grabar la actividad eléctrica del corazón durante 24 horas o más. Este tipo de registros permite observar el comportamiento del corazón en distintas condiciones (reposo, sueño, ejercicio, estrés), y es especialmente útil para estudios de variabilidad de la frecuencia cardíaca (HRV), episodios isquémicos o evaluación de marcapasos.

En el ámbito de la investigación, especialmente en estudios computacionales y de desarrollo tecnológico, la duración del registro depende del objetivo del análisis y de las capacidades del sistema. Por ejemplo, en tareas de clasificación automática o generación de señales sintéticas, es habitual trabajar con segmentos cortos de ECG (por ejemplo, de 2 a 10 segundos), dado que estos fragmentos contienen suficiente información para representar patrones cardíacos característicos, y su tamaño reducido permite un procesamiento más eficiente.

Por lo tanto, la elección de la duración del registro no solo afecta a la cantidad de información capturada, sino también a los requerimientos de almacenamiento, a la carga computacional y al tipo de modelos que se pueden aplicar en etapas posteriores de análisis.

Morfología y componentes de las ondas

La señal de electrocardiograma (ECG) es una representación gráfica de la actividad eléctrica del corazón en el tiempo. Un latido cardíaco normal genera una secuencia característica de ondas, segmentos e intervalos en el registro de ECG, cada uno reflejando un evento fisiológico específico del ciclo cardíaco. La interpretación precisa de la morfología, duración y amplitud de estos componentes es fundamental para el diagnóstico de diversas condiciones cardiovasculares.

A continuación, se describen los principales componentes de un complejo de ECG típico:

Ondas

Las ondas son las deflexiones (positivas o negativas) que se observan en la línea isoelectrica y representan los eventos de despolarización (activación eléctrica) y repolarización (recuperación eléctrica) del músculo cardíaco.

3.2. FUNDAMENTOS DE LA SEÑAL ELECTROCARDIOGRÁFICA (ECG)

43

Onda P Esta es la primera deflexión positiva y redondeada del ciclo cardíaco, de pequeña amplitud. Representa la despolarización de las aurículas (contracción auricular). Su ausencia, tamaño, forma o duración anormales pueden indicar problemas de ritmo auricular o agrandamiento auricular.

Complejo QRS Es la estructura más prominente y generalmente más alta del ECG, caracterizada por su forma puntiaguda y su corta duración. Se compone de una o más de las siguientes ondas:

Onda Q Primera deflexión negativa después de la onda P. Representa la despolarización septal.

Onda R Primera deflexión positiva y más alta del complejo QRS. Representa la despolarización principal de los ventrículos.

Onda S Deflexión negativa que sigue a la onda R. Representa la despolarización de la base de los ventrículos. Refleja la despolarización rápida de los ventrículos (contracción ventricular). La duración, amplitud o morfología anormal del QRS son indicadores críticos de arritmias ventriculares, bloqueos de rama, hipertrofia ventricular o infartos de miocardio previos.

Onda T Es una onda de menor amplitud que el QRS, más ancha y generalmente redondeada, con la misma dirección que la onda R. Representa la repolarización de los ventrículos (relajación ventricular). Alteraciones en la onda T (inversión, aplanamiento, elevación) pueden indicar isquemia miocárdica, trastornos electrolíticos o desequilibrios de potasio.

Segmentos

Los segmentos son las líneas isoelectricas (planas) entre las ondas, indicando periodos en los que no hay actividad eléctrica neta o el potencial es constante.

Segmento PR Extiende desde el final de la onda P hasta el inicio del complejo QRS. Representa el tiempo que tarda el impulso eléctrico en viajar desde las aurículas, a través del nódulo AV y el sistema de His-Purkinje,

hasta los ventrículos. Es el tiempo de retraso.^{en} el nódulo AV. Su desviación de la línea isoeleétrica o su duración anormal (acortamiento o alargamiento) pueden indicar problemas de conducción auriculoventricular (bloqueos AV) o vías accesorias.

Segmento ST Extiende desde el final del complejo QRS (punto J) hasta el inicio de la onda T. Representa el periodo en el que los ventrículos están completamente despolarizados y el músculo cardíaco se encuentra en un estado de "plateau" de repolarización. Es uno de los indicadores más importantes de isquemia miocárdica o infarto (elevación o depresión del segmento ST).

Intervalos

Los intervalos incluyen al menos una onda y un segmento, representando la duración de un evento fisiológico completo.

Intervalo PR Mide desde el inicio de la onda P hasta el inicio del complejo QRS. Representa la duración total de la despolarización auricular y el tiempo de conducción a través del nódulo AV. La prolongación de este intervalo indica un retraso en la conducción AV (bloqueos AV de primer grado o superiores).

Intervalo QT Mide desde el inicio del complejo QRS hasta el final de la onda T. Representa la duración total de la despolarización y repolarización ventricular. Un intervalo QT prolongado es un marcador de riesgo de arritmias ventriculares graves (como la Torsades de Pointes), y puede ser influenciado por fármacos o trastornos electrolíticos.

Intervalo RR Mide el tiempo transcurrido entre el pico de una onda R y el pico de la siguiente onda R. Se utiliza para determinar la frecuencia cardíaca y evaluar la regularidad del ritmo cardíaco. Las variaciones en el intervalo RR son clave para el diagnóstico de la mayoría de las arritmias, como la taquicardia (RR corto), la bradicardia (RR largo) o la fibrilación auricular (RR irregular).

Se puede observar una señal de electrocardiograma, en la que se indican las ondas que esta presenta, en la figura 3.11, localizada en la página 36

3.3. Fundamentos del aprendizaje automático aplicado a señales biomédicas

Durante los últimos años, el ámbito del tratamiento y análisis de señales ha experimentado una auténtica revolución. Esto se debe, en gran medida, al impulso proporcionado por los avances surgidos en el campo del aprendizaje automático. [LeCun et al., 2015] [Goodfellow et al., 2016] Este progreso ha sido especialmente perceptible en el ámbito de las señales biomédicas, entre las que encontramos las señales utilizadas a lo largo del presente proyecto, obtenidas a partir de registros de electrocardiograma (ECG). [Goldberger et al., 2000] [Clifford et al., 2017]

Esta evolución se ha visto especialmente potenciada por el desarrollo de novedosas técnicas basadas en Inteligencia Artificial (IA), destacando, en particular, aquellas centradas en el aprendizaje automático (Machine Learning) y/o aprendizaje profundo (Deep Learning). [Esteva et al., 2019] [Rajpurkar et al., 2019] Estas metodologías destacan por la gran versatilidad que presentan, permitiendo no solo extraer patrones complejos, sino también realizar tareas de clasificación, predicción e incluso generación de datos de carácter sintético. [Goodfellow et al., 2014] [Creswell et al., 2018]

Por dicho motivo, el uso de estas técnicas que cuentan con modelos avanzados resulta especialmente relevante en la realización de este trabajo. Eso es debido a que vamos a poder aplicarlas a señales fisiológicas, como el electrocardiograma (ECG). Esto nos va a proporcionar una optimización del análisis de las señales en busca de anomalías, una detección temprana de patologías y una mejora diagnóstica y de tratamiento de ellas. [Rajpurkar et al., 2019]

A su vez, la generación de nuevos registros contribuye a ampliar la diversidad y robustez de los conjuntos de datos disponibles, algo fundamental en contextos médicos, en los que la cantidad de datos accesibles habitualmente se encuentra limitada o desbalanceada. [Frid-Adar et al., 2018]

Este es el motivo por el que se presentan los fundamentos teóricos necesarios para la correcta comprensión y evaluación del trabajo antes de explicar en profundidad el desarrollo práctico y los resultados obtenidos en él. A lo largo de la presente sección se aborda el funcionamiento de los distintos modelos empleados, comenzando por los principios del aprendizaje automático, los conceptos teóricos clave del aprendizaje profundo, y finalizando con




Figura 3.13: Flujo de explicación de conceptos. *Elaboración propia*

el estudio y aplicaciones de las redes generativas adversariales (Generative Adversarial Networks, GANs).

La organización estructural de la presente sección se puede observar en la imagen 3.13, localizada en la página 46

Estos conceptos teóricos se exponen haciendo especial énfasis sobre su aplicación en el procesamiento y generación de señales biomédicas, así como en el contexto del análisis de los registros de ECG. Por lo tanto, esta base teórica resulta esencial para la correcta comprensión y seguimiento de los apartados que suceden en el presente trabajo.

Aprendizaje Automático (AA) o Machine Learning (ML)

El Aprendizaje Automático (AA), también conocido por sus siglas en inglés (Machine Learning, ML), es un subcampo de las Ciencias de la Computación, concretamente una de las ramas de mayor importancia dentro de la Inteligencia Artificial (IA). [Goodfellow et al., 2016]

Dicha disciplina comprende un conjunto de algoritmos y métodos cuyo objetivo principal es dotar de una serie de funcionalidades a los sistemas de carácter informático, las cuales van a mejorar su rendimiento al aprender

directamente de los datos a medida que adquieren más experiencia e ir ajustando sus parámetros de forma progresiva. [Murphy, 2012] Algunas de estas propiedades son el aprendizaje automático de distintas características a partir de los datos, la identificación de patrones complejos o la capacidad de tomar decisiones complejas en datos ruidosos o con gran variabilidad de forma autónoma, mediante la experiencia, sin necesidad de contar con una programación subyacente que recoja de forma explícita la realización de estas.[Bishop, 2006] Esta configuración es la responsable de que sean capaces de resolver tareas de considerada complejidad con gran eficacia.

El proceso de aprendizaje automático se centra en la construcción de modelos de naturaleza matemática, los cuales se encargan de crear modelos matemáticos que identifican dichos patrones, relaciones y estructuras ocultas dentro de los datos. [Azuaje et al., 2006]

Esta metodología resulta especialmente útil en ámbitos hostiles para el empleo de métodos tradicionales o en ámbitos en que estos resultan ineficaces, como aquellos que implican una gran cantidad de datos o con estructuras de gran complejidad subyacente. Por este motivo, en el ámbito de las ciencias de la salud, concretamente en el procesamiento de señales de origen biomédico, las herramientas basadas en aprendizaje automático se han vuelto fundamentales, presentando un papel protagónico gracias a sus soluciones innovadoras. [Liu et al., 2019]

En la tabla 3.8, situada en la página 48 se muestran las limitaciones de los métodos tradicionales y que los métodos basados en ML solucionan.

Esta importancia radica en la poderosa contribución diagnóstica, terapéutica y de tratamiento que aportan este tipo de técnicas, puesto que permiten analizar de forma relativamente ágil extensas cantidades de datos y extraer eficazmente patrones relevantes en el ámbito sanitario, mejorando así la clasificación de patologías, la generación de datos artificiales y la toma de decisiones por parte de los profesionales de la salud. [Rajpurkar et al., 2019]

En el gráfico 3.14 representado en la página 48 se observa el abanico de funcionalidades que proporcionan este tipo de modelos de ML cuando se aplican sobre señales electrocardiográficas.

Por las razones previamente expuestas, esta disciplina constituye uno de los pilares de la IA sobre el que se fundamentan las técnicas empleadas tanto para el análisis como para la generación sintética de señales electrocardiográficas a lo largo del presente proyecto, en combinación con el aprendizaje profundo y las redes generativas adversariales (GANs), dada la complejidad temporal, la variabilidad y el ruido de las señales de ECG.

Métodos Tradicionales	Métodos basados en Machine Learning
Requieren instrucciones explícitas	Actúan de forma independiente, a partir de la experiencia
Poca tolerancia al ruido y a la variabilidad	Robustez frente a señales ruidosas o incompletas
Difícil escalabilidad a grandes volúmenes de datos	Escalables a grandes cantidades de datos
Poca capacidad de generalización a nuevos pacientes	Alta capacidad de generalización
Limitados: Tareas concretas y definidas	Versátiles: clasificación, predicción, generación, etc.

Tabla 3.8: Comparación entre métodos tradicionales y técnicas basadas en aprendizaje automático en el ámbito de las señales biomédicas. *Elaboración propia.*




Figura 3.14: Aplicaciones de los modelos de ML cuando se aplican sobre señales de ECG. *Elaboración propia.*




Figura 3.15: Relación entre las distintas disciplinas basadas en Inteligencia Artificial. *Elaboración propia.*

[Lyon et al., 2018] En la imagen 3.15 de la página 49 se observa la forma en que se relacionan las distintas disciplinas basadas en inteligencia artificial.

Es por ello que en el presente subapartado se detallan los conceptos fundamentales acerca de esta ciencia, incluyendo sus principales enfoques, técnicas y aplicaciones prácticas, así como los algoritmos más comúnmente empleados o su aplicación en el procesamiento de señales fisiológicas, como las del presente TFG.

Por lo tanto, la base teórica aquí proporcionada pretende poner en contexto al lector, pudiendo este entender las técnicas que se emplean a lo largo de dicho trabajo y valorar su impacto en los resultados del mismo.

Tipos de Aprendizaje Automático (AA)

La forma en que la disciplina de Machine Learning (ML) lleva a cabo el aprendizaje a partir de los datos disponibles determina el tipo de enfoque empleado durante el proceso de aprendizaje en cada caso.

Por lo tanto, es fundamental establecer una clasificación de las diferentes técnicas de aprendizaje automático existentes. Esta categorización va a permitir seleccionar el tipo de aprendizaje más adecuado en función del contexto, los objetivos y los datos concretos, así como los problemas o casuísticas que pueden abordar cada uno de estos enfoques. [Kelleher et al., 2015]




Figura 3.16: Características principales de los distintos tipos de aprendizaje automático *Elaboración propia*.

Los principales tipos son el aprendizaje supervisado, no supervisado, por refuerzo y semi-supervisado, los cuales se detallan a lo largo de los siguientes subapartados. Esta clasificación general, ampliamente adoptada en el ámbito académico y profesional, ha sido recogida por varios autores de referencia en la literatura especializada como [Bishop, 2006] o [Mitchell, 1997].

Las principales características de estos tipos de enfoque se pueden ver en el infograma 3.16 ubicado en la página 50, donde se incluyen las principales características de estos, sus casos de uso y varios ejemplos de los algoritmos que utilizan durante su funcionamiento.

Aprendizaje Automático Supervisado El aprendizaje automático supervisado es una de las técnicas más utilizadas y estudiadas dentro del campo del Machine Learning (ML). [Gerón, 2019] Este se centra en la construcción de modelos capaces de aprender a partir de datos y de llevar a cabo una mejora continua de su desempeño, sin necesidad de una programación explícita para cada tarea.

Este enfoque se basa en la utilización de conjuntos de datos previamente etiquetados, es decir, conjuntos donde cada entrada presenta asociada una etiqueta o salida conocida, de ahí el nombre de supervisado. [Mitchell, 1997] Estos se utilizan para cumplir con el objetivo principal de este tipo de aprendizaje: el entrenamiento de modelos capaces de predecir correctamente




Figura 3.17: Flujo de trabajo del aprendizaje automático aplicado a señales de ECG. *Elaboración propia.*

la categoría o clase asociada a datos desconocidos o nuevos, es decir, datos no etiquetados. [Gerón, 2019]

De esta forma, una vez que se ha completado el ajuste, el modelo se encuentra capacitado para la clasificación de datos sin etiquetar, los cuales no ha visto previamente.

El flujo de trabajo previamente descrito se representa de una forma conceptual en el diagrama 3.17 de la página 51.

Este enfoque es especialmente valioso en el ámbito del análisis de señales electrocardiográficas (ECG), puesto que es necesario llevar a cabo un proceso de identificación y clasificación de las distintas anomalías presentes en las ondas que conforman las señales. [Luz et al., 2016] El modelo lleva a cabo la asociación de estos patrones con distintas condiciones clínicas previamente anotadas, las cuales ha visto a lo largo del proceso de aprendizaje supervisado, hecho que facilita la automatización de este proceso. Algunas de estas aplicaciones clínicas son la detección de arritmias, la clasificación de patrones patológicos o la segmentación de las ondas de la señal. [Clifford et al., 2017]




Figura 3.18: Etapas que sigue el proceso de aprendizaje automático supervisado. *Elaboración propia.*

Sin embargo, para llevar a cabo el desarrollo e implementación de este tipo de modelos robustos con aplicación clínica, es necesario contar con bases de datos que contengan datos o registros anotados. Una de las bases más utilizada con este propósito es PhysioNet. [MIT Laboratory for Computational Physiology,]

Etapas del proceso de aprendizaje El flujo de trabajo del Aprendizaje Automático (AA) o Machine Learning (ML) Supervisado se puede estructurar en distintas fases o etapas, cuya correcta consecución garantiza que los modelos resultantes sean capaces de realizar una correcta y precisa clasificación de los nuevos datos. Estas etapas se pueden ver resumidas en el gráfico 3.18 de la página 52, y se detallan a continuación

- **Recolección de los datos:** Durante esta primera fase se obtienen los conjuntos de datos (etiquetados) con los que se va a trabajar, tanto para entrenar como para testear al modelo. Para la elección de un conjunto de datos o registros es necesario que presente características representativas del problema a resolver. En el caso de las señales de ECG, es importante que los registros estén anotados, deben incluir tanto la señal como la información clínica relevante para el análisis (tipo de latido, ritmo o frecuencia cardíaca, anomalías morfológicas

en las ondas, etc.). Estas anotaciones pueden variar en función del objetivo del problema. [Goldberger et al., 2000]

- **Limpieza y Preprocesamiento:** La calidad y cantidad de los datos son cruciales para el correcto funcionamiento del modelo. Sin embargo, los datos reales que se obtienen en un primer momento no son óptimos habitualmente para llevar a cabo el proceso de aprendizaje. Por este motivo, es necesario llevar a cabo tanto un proceso de limpieza como de preparación inicial sobre los datos para adaptarlos al modelo, mejorando su eficiencia y coherencia.

Durante el primero de ellos, se eliminan aquellos registros que pueden afectar negativamente al modelo, como registros incompletos, ruidosos o duplicados. Mientras que en el segundo proceso se llevan a cabo distintas modificaciones que van a permitir el acondicionamiento de los datos, haciendo que estos presenten las anotaciones precisas y sean compatibles con el modelo.

Cuando se trabaja con registros de ECG, las anotaciones deben ser acerca de los eventos cardíacos, como el latido normal o anormal. Para ello, se aplican técnicas de preprocesamiento como las siguientes:

- **Filtrado de señales:** Sirve para eliminar el posible ruido y los artefactos presentes en la señal. Este se hace recortando los valores de registro que se encuentran fuera de un rango de frecuencias preestablecido. Por ejemplo, el filtro de paso banda es habitual para eliminar el ruido de la línea base (frecuencias bajas), el ruido electromagnético o el de aquellas interferencias con una alta frecuencia. [Luo and Johnston, 2010]
- **Normalización de los valores:** Este proceso se realiza con el fin de adaptar la escala de los datos para que esta sea común a todos, encontrándose todos dentro del mismo rango de valores. Este hecho que facilita la manipulación y el tratamiento de los mismos. En señales de ECG es habitual llevar a cabo una normalización de tipo Z-Score y un escalado entre los valores $[-1, 1]$ de los datos.
- **Segmentación:** Realiza la división de los registros en ventanas o segmentos de un tamaño determinado, medido en número de muestras. Esta segmentación permite que la manipulación de las señales sea más sencilla ya que los fragmentos son más cortos, al mismo tiempo que realiza una especie de proceso de *data augmentation* que va a mejorar el proceso de aprendizaje. En señales de ECG esta segmentación suele hacerse centrada en

los picos del complejo QRS y extendiendo la ventana hacia los laterales. Esto permite tener información completa acerca de las ondas cardíacas que componen la señal y evita la pérdida de información procedente de eventos clínicamente relevantes.

- **Extracción y selección de características:** Esta etapa busca representar la información relevante de los datos originales de una forma compacta y significativa, a través de variables (features), hecho que va a permitir continuar con el proceso de aprendizaje. Estas varían en función de la naturaleza de los propios datos y del propósito del análisis. No obstante, en registros de ECG estas variables suelen ser: estadísticas temporales (duración del complejo QRS, intervalo entre latidos, etc.), parámetros morfológicos de las distintas ondas (P, Q, S, etc), frecuencia espectral o incluso valores numéricos extraídos directamente de las ventanas en que se dividen los datos. [Luz et al., 2016]
- **División del conjunto de datos:** El conjunto de datos en este tipo de aprendizaje se encuentra etiquetado, y se divide normalmente en tres subconjuntos principales, que permiten medir la capacidad de generalización del sistema o modelo ante nuevos datos: [Pan and Tompkins, 1985]
 1. **Conjunto de entrenamiento o *training set*:** Se utiliza para el proceso de entrenamiento como su propio nombre indica, durante el que se ajustan los parámetros del modelo a lo largo de las distintas iteraciones o épocas.
 2. **Conjunto de validación o *validation set*:** Este conjunto de datos se emplea para evaluar el funcionamiento del modelo a lo largo del proceso de entrenamiento, asegurando que este es correcto y evitando el sobreajuste o subajuste del mismo.
 3. **Conjunto de prueba o *test set*:** Este conjunto es el paso final de validación del modelo. Se encuentra formado por datos que el modelo no ha visto nunca, es decir, que son desconocidos para él, como verificación de que todo funciona adecuadamente antes de su aplicación real.
- **Entrenamiento del modelo:** A lo largo de esta fase, el modelo va ajustando sus parámetros internos de manera progresiva con el objetivo de mejorar los resultados, aumentar la capacidad de generalización y minimizar el error entre las salidas predichas y las etiquetas reales en futuros procesos de clasificación. [Gerón, 2019]

Para llevar a cabo este proceso de ajuste se utilizan algoritmos específicos que permiten aprender una función que relaciona las entradas (características) con las salidas (etiquetas). [Bishop, 2006] [Mitchell, 1997]

Los algoritmos de aprendizaje supervisado más comunes son los siguientes:

1. Máquinas de vectores de soporte (SVM)
 2. Árboles de decisión y Bosques Aleatorios (Random Forest)
 3. K - vecinos más cercanos (k-NN)
 4. Redes neuronales supervisadas (ej. perceptrones multicapa - MLP)
- **Evaluación del sistema (métricas):** Una vez que el modelo ha terminado su entrenamiento, es necesario evaluar su funcionamiento, rendimiento e idoneidad para la aplicación práctica. Esto se hace utilizando los conjuntos de prueba (test) y validación (validation) como base, los cuales son nuevos para él, a través de las siguientes métricas: precisión (*accuracy*), sensibilidad y especificidad, F1-score, área bajo la curva ROC o, incluso, a través de la matriz de confusión. [Aggarwal, 2015] Además, esta evaluación permite decidir si el modelo lleva a cabo o no la generalización con datos nuevos o si, por el contrario, es susceptible de mejora. Otra práctica muy común para maximizar la fiabilidad del modelo es aplicar técnicas como la validación cruzada (cross-validation).
 - **Predicción y aplicación práctica:** Finalmente, una vez que ya ha acabado el proceso puramente técnico, de entrenamiento y evaluación del modelo, se puede empezar a utilizar para la predicción de clases de nuevos datos.

En el contexto de los registros de ECG, esta aplicación permite la clasificación automática de señales o fragmentos de estas, facilitando la detección temprana de posibles anomalías relacionadas con el funcionamiento cardíaco y utilizarlo con fines de mejora a nivel clínico, diagnóstico, terapéutico o investigador.

Aprendizaje Automático No Supervisado En el aprendizaje no supervisado, los datos no están etiquetados. El modelo tiene como objetivo encontrar estructuras, patrones o agrupamientos en los datos sin ninguna guía externa. Este enfoque es útil para tareas como la reducción de dimensionalidad, la detección de anomalías o el clustering, pero en nuestro proyecto no tiene ninguna utilidad.

Aprendizaje Automático por Refuerzo El aprendizaje por refuerzo (Reinforcement Learning, RL) se inspira en el comportamiento de los seres vivos, en particular en la manera en que aprenden a partir de la experiencia. En este caso, un agente interactúa con un entorno y toma decisiones con el fin de maximizar una recompensa acumulada a largo plazo. A diferencia de los métodos supervisados o no supervisados, en el RL no se proporciona una salida esperada para cada entrada, sino que el agente aprende a través del ensayo y error.

Aunque su uso es más frecuente en ámbitos como la robótica o los videojuegos, su aplicación en salud está creciendo, especialmente en el desarrollo de sistemas de toma de decisiones adaptativos, como asistentes clínicos inteligentes o sistemas de control personalizado. Sin embargo, aún así, no va a ser utilizado en el presente proyecto.

Aprendizaje Automático Semi-supervisado Este enfoque combina características del aprendizaje supervisado y no supervisado. Se emplea cuando se dispone de una pequeña cantidad de datos etiquetados y una gran cantidad de datos sin etiquetar. Los modelos semi-supervisados permiten aprovechar ambos tipos de información para mejorar el rendimiento predictivo sin necesidad de un etiquetado exhaustivo, lo cual es especialmente útil en entornos como el biomédico, donde la anotación de datos puede ser costosa y requerir expertos humanos. Este modelo de aprendizaje tampoco se va a utilizar en el desarrollo del presente proyecto.

Aprendizaje Profundo (AP) o Deep Learning (DL)

El Aprendizaje Profundo (Deep Learning - DL) es una subcategoría del Machine Learning que se enfoca en redes neuronales con múltiples capas (de ahí "profundo"). A diferencia de los métodos de ML tradicionales, el DL tiene una capacidad asombrosa para aprender representaciones de características directamente de los datos crudos, sin necesidad de una ingeniería de características manual. Esto es especialmente potente con datos complejos como imágenes, audio o, en tu caso, señales de ECG.

Las redes de Aprendizaje Profundo se estructuran en capas, donde cada capa aprende a identificar características a diferentes niveles de abstracción. Por ejemplo, en el contexto de las imágenes, las primeras capas podrían detectar bordes y texturas, mientras que las capas más

profundas aprenderían a reconocer objetos completos. En el caso de los ECGs, las capas iniciales podrían detectar cambios bruscos en la señal, mientras que las más profundas podrían aprender a identificar la morfología de ondas P, QRS, T, o incluso patrones rítmicos complejos.

Tipos de Redes Neuronales Profundas Relevantes para ECGs

Redes Neuronales Convolucionales (CNNs) ¿Son redes especializadas en el procesamiento de datos con una topología de rejilla", como imágenes (2D) o series de tiempo (1D). Utilizan capas convolucionales que aplican filtros para detectar patrones locales y luego los combinan para formar representaciones de nivel superior.

Aunque las CNNs son famosas por las imágenes, las CNNs 1D son extremadamente efectivas para señales de tiempo como los ECGs. Pueden aprender automáticamente a reconocer características morfológicas clave (como la forma del complejo QRS o la onda T) a lo largo de la señal, sin que tú tengas que decirles qué buscar. Son excelentes para tareas de clasificación de arritmias o detección de anomalías.

Redes Neuronales Recurrentes (RNNs) Y LSTMS Las RNNs están diseñadas para manejar secuencias de datos, donde el orden de los datos es importante y la salida en un momento dado depende de entradas anteriores. Las Long Short-Term Memory (LSTMs) son un tipo especial de RNN que resuelven el problema de la "desaparición del gradiente" (vanishing gradient) en secuencias largas, permitiéndoles aprender dependencias a largo plazo.

Los ECGs son, por naturaleza, series temporales. Las LSTMs son ideales para capturar las relaciones temporales y rítmicas entre los latidos o dentro de un latido. Por ejemplo, pueden ser usadas para predecir el siguiente latido o para clasificar arritmias basándose en patrones rítmicos que se extienden a lo largo de varias muestras.

Redes Generativas (Generative Models) Los modelos generativos son un tipo de modelo de Aprendizaje Profundo cuyo objetivo principal no es clasificar o predecir, sino aprender la distribución subyacente de un conjunto de datos para poder generar nuevas muestras que se parezcan a los datos originales. En el ámbito médico, y específicamente con los ECGs, los modelos generativos son cruciales por varias razones:

Aumento de Datos (Data Augmentation) Para entrenar modelos de DL robustos se necesitan muchos datos. Los modelos generativos pueden crear nuevas muestras sintéticas, ampliando así el tamaño de los datasets existentes.

Balanceo de Clases En problemas como la detección de arritmias, algunas condiciones son muy raras (clases minoritarias). Los modelos generativos pueden sintetizar específicamente muestras para estas clases infrarepresentadas, ayudando a balancear el dataset y mejorando el rendimiento de los clasificadores.

Privacidad Pueden generar datos de pacientes sintéticos que imitan las propiedades estadísticas de los datos reales, pero sin contener información identificable, protegiendo la privacidad de los pacientes.

Simulación de Patologías Pueden aprender a generar señales que simulan patologías específicas, útiles para el entrenamiento de médicos o sistemas de diagnóstico.

Simulación de Patologías Las GANs son el tipo más popular y potente de modelo generativo hoy en día. Su diseño es único y se basa en una "guerra" o "juego" entre dos redes neuronales que se entrenan simultáneamente:

El Generador (Generator - G) Toma un vector de ruido aleatorio (un código latente) como entrada y lo transforma en una nueva muestra de datos sintéticos (en tu caso, una señal de ECG). Su principal objetivo es engañar al Discriminador para que piense que sus muestras generadas son reales.

El Discriminador (Discriminator - D) / Crítico (Critic) Toma una muestra de datos (ya sea real o generada por el Generador) y produce una probabilidad de que esa muestra sea real o falsa (sintética). Su objetivo reside en distinguir correctamente entre las muestras reales y las falsas.

Proceso de Entrenamiento de una GAN (Juego Adversarial)

El Generador y el Discriminador se entrenan en un bucle iterativo.

El Generador intenta mejorar sus muestras para que sean cada vez más realistas, engañando al Discriminador.

El Discriminador intenta mejorar su capacidad para detectar las falsificaciones del Generador.

Este "juego del gato y el ratón" empuja a ambas redes a mejorar continuamente. Idealmente, el entrenamiento converge cuando el Generador es tan bueno que el Discriminador ya no puede distinguir entre muestras reales y generadas (la probabilidad de que una muestra sea real es del 50

Las GANs clásicas o DCGANs fueron las primeras implementaciones que mostraron el gran potencial de las GANs, especialmente las DCGANs (Deep Convolutional GANs) que usaban CNNs en el generador y el discriminador.

Sin embargo, a menudo eran inestables durante el entrenamiento y propensas al colapso de modos (mode collapse), donde el generador solo produce una pequeña variedad de muestras, ignorando la diversidad real del dataset.

Las GANs Condicionales (cGANs) introducen una condición (una etiqueta de clase, por ejemplo) tanto al Generador como al Discriminador. En el caso del presente proyecto, esto es crucial, ya que se puede entrenar el Generador para que no solo cree un ECG cualquiera, sino que genere un ECG de un tipo específico de arritmia (ej., Fibrilación Auricular) al pasarle esa etiqueta como entrada. Esto es esencial para el balanceo de clases.

Mientras que las GANs clásicas usan una función de pérdida que puede ser inestable y no proporciona gradientes significativos cuando el Discriminador se vuelve demasiado bueno, lo que lleva a los problemas de entrenamiento y colapso de modos. Por su parte, las Wasserstein GANs (WGANs) y WGAN con Penalización de Gradiente (WGAN-GP) reemplazan esta función de pérdida por otra:

- **WGAN (Arjovsky et al., 2017):** Reemplaza la función de pérdida de las GANs clásicas con la Distancia de Wasserstein (también conocida como "Earth Mover's Distance"). Esto proporciona un gradiente más suave y una métrica de progreso del entrenamiento más significativa. El Discriminador en una WGAN se llama a menudo Crítico. [Arjovsky et al., 2017]

- **WGAN-GP (Gulrajani et al., 2017):** Es una mejora de WGAN que resuelve un problema de las WGANs originales (el "clipping" de pesos en el Discriminador). WGAN-GP usa una penalización de gradiente (Gradient Penalty - GP) para forzar que el crítico cumpla una condición matemática (la condición de 1-Lipschitz). Esto resulta en un entrenamiento mucho más estable, menos propenso al colapso de modos y capaz de generar resultados de mayor calidad y diversidad. Es el estándar de oro para muchas aplicaciones de GANs hoy en día. [Gulrajani et al., 2017]

3.4. Estado del arte y trabajos relacionados.

El análisis de señales electrocardiográficas (ECG) es una piedra angular en el diagnóstico cardiológico, permitiendo la detección temprana y el monitoreo de diversas arritmias y patologías cardíacas. Con el avance del Machine Learning (ML) y, más específicamente, el Aprendizaje Profundo (Deep Learning, DL), la automatización y mejora de este análisis ha experimentado una notable transformación. Sin embargo, la efectividad de estos modelos avanzados depende en gran medida de la disponibilidad de grandes volúmenes de datos de alta calidad y, crucialmente, bien balanceados, un desafío persistente en el ámbito médico debido a la rareza de ciertas condiciones y las limitaciones de privacidad.

Análisis de ECG Basado en Machine Learning y Aprendizaje Profundo

Tradicionalmente, el análisis automático de ECG se basaba en métodos de procesamiento de señal digital seguidos por clasificadores de Machine Learning más convencionales, como Máquinas de Soporte Vectorial (SVMs), Bosques Aleatorios (Random Forests) o K-Nearest Neighbors (KNNs). Estos enfoques a menudo requerían una ingeniería de características manual y experta para extraer atributos relevantes de las señales.

Con la irrupción del Aprendizaje Profundo, las Redes Neuronales Convolucionales (CNNs) y las Redes Neuronales Recurrentes (RNNs), especialmente las redes LSTM (Long Short-Term Memory), han demostra-

do una capacidad superior para aprender representaciones complejas directamente de los datos crudos de ECG. Trabajos previos han aplicado CNNs para la detección de arritmias cardíacas [Rajpurkar et al., 2019], demostrando su eficacia en la extracción de patrones morfológicos y rítmicos. Las redes LSTM, por su parte, son aptas para capturar dependencias temporales en series de tiempo largas, siendo utilizadas en la clasificación de latidos y el análisis de la variabilidad de la frecuencia cardíaca [Fawaz et al., 2019]. Proyectos basados en grandes datasets como PhysioNet [Goldberger et al., 2000] y MIMIC-III [Johnson et al., 2016] han permitido el desarrollo de modelos de DL capaces de detectar múltiples tipos de arritmias con alta precisión, e incluso identificar otras condiciones cardíacas.

Modelos Generativos en Bio-señales y Medicina

La escasez de datos etiquetados y el desequilibrio de clases son obstáculos significativos en la aplicación del DL a problemas biomédicos. Los modelos generativos han emergido como una solución prometedora para sintetizar nuevos datos que imitan las características de los conjuntos de datos reales, ofreciendo un método para ampliar y balancear los datasets existentes. Si bien inicialmente fueron populares en la generación de imágenes médicas (ej., tomografías, resonancias magnéticas para aumentar datasets o simular patologías [Frid-Adar et al., 2018]), su aplicación se ha extendido a otras modalidades, incluyendo las bio-señales.

Modelos como los Autoencoders Variacionales (VAEs) y, de forma más prominente, las Redes Generativas Adversariales (GANs), han sido explorados para la síntesis de datos en diversos contextos sanitarios, incluyendo la generación de datos de pacientes sintéticos para la privacidad o la creación de muestras de laboratorio.

GANs para la Síntesis de Señales ECG

La aplicación de GANs para la generación de señales ECG sintéticas es un campo de investigación activo que busca superar los desafíos inherentes a las series temporales de bioseñales: mantener la coherencia temporal, la morfología de las ondas (P, QRS, T) y la variabilidad rítmica, al tiempo que se asegura el realismo clínico.

Primeras aproximaciones

Las implementaciones iniciales de GANs (o sus variantes tempranas como DCGANs) para ECG mostraron el potencial de la técnica, pero a menudo sufrían de inestabilidad de entrenamiento y colapso de modos (mode collapse), donde el generador producía una variedad limitada de señales [Costanzo et al., 2018]. Esto limitaba su utilidad en la creación de datasets diversos y clínicamente ricos.

GANs Condicionales (cGANs)

La introducción de la condicionalidad en las GANs (cGANs) fue un avance crucial. Al alimentar el generador y el discriminador con información de clase (ej., el tipo de arritmia), los modelos podían ser dirigidos para producir señales de ECG específicas para una categoría deseada [Wang et al., 2020]. Esto es vital para el balanceo de clases, ya que permite la generación controlada de muestras para clases minoritarias.

Estabilidad y Calidad con WGANs y WGAN-GP

Los problemas de inestabilidad de las GANs clásicas llevaron al desarrollo de las Wasserstein GANs (WGANs) [Arjovsky et al., 2017], que utilizan la Distancia de Wasserstein como función de pérdida para proporcionar gradientes más estables y una mejor convergencia. Sin embargo, las WGANs originales a menudo dependían del recorte de gradientes (gradient clipping), lo que podía degradar la calidad. La mejora clave llegó con las WGAN con Penalización de Gradiente (WGAN-GP) [Gulrajani et al., 2017], que reemplaza el recorte de gradientes con una penalización L2 en la norma del gradiente del crítico. Esta variante ha demostrado ser significativamente más estable y capaz de generar muestras de mayor calidad y diversidad, convirtiéndose en el estándar de facto para muchas aplicaciones de generación de imágenes y series temporales [Esteban et al., 2017], [Delgado-Bonal and Martín-Guerrero, 2020]. Diversos estudios han adoptado WGAN-GP para la síntesis de ECG debido a su robustez, obteniendo resultados prometedores en la replicación de patrones complejos y variabilidad. [Zhou and Wei, 2020] [Zhang and Babaeizadeh, 2021]

Abordaje del Desequilibrio de Clases con Modelos Generativos

El desequilibrio de clases es un problema común en los datasets médicos, donde las condiciones raras están subrepresentadas. Las técnicas tradicionales para abordarlo incluyen el sobremuestreo (oversampling) de clases minoritarias (ej., SMOTE, ADASYN) o el submuestreo (undersampling) de clases mayoritarias. Sin embargo, estas técnicas a menudo conllevan riesgos como el sobreajuste (duplicación de muestras) o la pérdida de información (eliminación de muestras).

Los modelos generativos, particularmente las GANs, ofrecen una solución más sofisticada al desequilibrio de clases. En lugar de simplemente duplicar o modificar ligeramente las muestras existentes, las GANs aprenden la distribución subyacente de la clase minoritaria y sintetizan nuevas muestras únicas y diversas que no son copias exactas. Esto proporciona una forma más robusta de aumentar el tamaño de las clases infrarepresentadas, mejorando la generalización de los modelos de clasificación posteriores.

Brecha en la Investigación y Contribución del Presente Trabajo

A pesar de los avances significativos en la aplicación de GANs para la síntesis de ECG, todavía existen áreas de mejora y una necesidad de demostraciones más robustas y documentadas. Si bien la viabilidad de generar ECGs sintéticos es reconocida, la transparencia en el proceso experimental, la justificación de las decisiones de diseño y una evaluación exhaustiva de la calidad de las señales generadas, especialmente en el contexto de la mitigación del desequilibrio de clases, son aspectos que aún requieren un mayor énfasis en la literatura.

El presente Trabajo de Fin de Grado aborda esta brecha al:

- Explorar y documentar detalladamente el proceso iterativo de experimentación con diversas configuraciones de preprocesamiento, arquitecturas de red y parámetros de entrenamiento, incluyendo tanto los enfoques exitosos como los descartados. Esto proporciona una valiosa perspectiva sobre el "cuaderno de trabajo" detrás del desarrollo del modelo.

- Implementar y optimizar una cWGAN-GP para la generación de señales ECG específicas para las clases minoritarias del desafiante dataset PhysioNet CinC Challenge 2017 (Fibrilación Auricular, Otros Ritmos y Ruido), demostrando su efectividad en la mitigación del desequilibrio de clases.
- Realizar una evaluación exhaustiva y multifacética de la calidad de las señales sintéticas, utilizando métricas avanzadas como la Distancia de Fréchet ECG (FED - o un análogo adaptado a 1D, como discutimos), la Distancia de Warping Dinámico (DTW) y el análisis de la Densidad Espectral de Potencia (PSD), complementando la evaluación visual con análisis cuantitativos rigurosos.

De esta forma, este trabajo no solo valida la capacidad de la cWGAN-GP para generar ECGs sintéticos realistas y condicionales, sino que también ofrece una metodología transparente y un análisis profundo del proceso de desarrollo, facilitando la replicabilidad y sirviendo como una base sólida para futuras investigaciones en el aumento de datos para bioseñales complejas.

Metodología

En este apartado de la memoria se expone, junto a su descripción detallada, la estrategia y el proceso metodológico seguidos a lo largo del desarrollo del presente Trabajo de Fin de Grado. Estos se caracterizan por seguir una estructura rigurosa, modularizada en forma de funciones documentadas y enmarcada en el contexto de la Inteligencia Artificial.

En particular, a lo largo del trabajo, se aborda el desafío de generar datos sintéticos, señales artificiales de electrocardiograma (ECG) mediante el uso de una red generativa adversarial, la cWGAN (conditional Wasserstein Generative Adversarial Network).

Esta arquitectura en forma de redes GAN fue introducida por Ian Goodfellow en el año 2015, y desde entonces ha sido ampliamente utilizada en la generación de datos sintéticos de diversa índole. [Goodfellow et al., 2016] [Zanchi et al., 2025] En el contexto de este TFG, dicho enfoque ha sido seleccionado con el propósito de desarrollar herramientas capaces de complementar o enriquecer conjuntos de datos desbalanceados, una problemática muy habitual en el ámbito médico, donde la disponibilidad de muestras o datos de determinadas clases o categorías suele ser limitada. De hecho, la literatura desarrollada durante los últimos años identifica este desequilibrio como una de las principales limitaciones para el éxito de las tareas de clasificación automática. Por lo tanto, dicha literatura justifica la utilización de este tipo de técnicas de generación de datos sintéticos, a la vez que refuerza la motivación del presente TFG. [Zanchi et al., 2025]

Es importante también indicar que su desarrollo se ha efectuado siguiendo y apoyándose en los principios de la metodología ágil Scrum. Esta decisión se ha tomado en base a su capacidad organizativa, que permite estructurar las tareas de manera iterativa e incremental. Por lo tanto,



Figura 4.1: Diagrama de flujo que representa la metodología seguida en el proyecto. *Elaboración propia*

proporciona una gestión más eficiente de dicho proyecto, a la vez que facilita el seguimiento de su progreso, la visualización de los avances y concede una mayor flexibilidad ante posibles ajustes o mejoras surgidas a lo largo de su evolución. [Schwaber, Ken and Sutherland, Jeff,]

Con el fin de alcanzar la meta principal del trabajo, el objetivo general, se ha tomado como punto de partida y base del proyecto el conjunto de datos **PhysioNet / Computing in Cardiology Challenge 2017**, disponible en [Clifford et al.,]. Dicho dataset ha sido analizado en detalle y procesado cuidadosamente a lo largo de las primeras etapas con el objetivo de garantizar su integridad, calidad y adecuación a los requisitos del modelo generativo desarrollado a lo largo del presente proyecto.

Asimismo, cabe destacar que este dataset goza de un amplio reconocimiento entre los miembros de la comunidad científica, llegando a considerarse un conjunto de referencia para distintos ensayos, ya que cuenta con una impecable calidad, heterogeneidad en los datos y aplicación funcional a nivel clínico. Este es uno de los motivos fundamentales por los que se decidió que este iba a ser el conjunto de datos escogido para la realización del proyecto. [Clifford et al., 2017] [Goldberger et al., 2000]

El proceso metodológico, partiendo del dataset elegido, se divide en diferentes fases o sprints claves, que abarcan desde la descarga y preparación inicial de los datos (preprocesamiento y limpieza/depuración) hasta el estudio de la funcionalidad de la implementación de un cla-

sificador que divida las señales biomédicas (tanto reales como artificiales) en función de la categoría clínica a la que pertenecen. Entre estas etapas también se incluyen otras intermedias como la construcción de una red adversarial capaz de generar bioseñales sintéticas a partir de un conjunto de señales de ECG reales, así como la evaluación de los resultados obtenidos a través de diversas métricas y enfoques propuestos en la literatura, entre otras. [Wulan et al., 2020] [Zhang and Babaeizadeh, 2021]

Cada una de estas etapas se ha diseñado siguiendo tanto criterios técnicos como científicos acerca de la naturaleza de las propias señales del dataset, poniendo especial énfasis sobre el componente fisiológico de estas, para su posterior aplicación en el ámbito clínico.

Durante dicha etapa de diseño se han tenido en cuenta factores como su variabilidad interindividual, la presencia de ruidos o artefactos que puedan alterar o desdibujar su trazado original, o la gran importancia de salvaguardar la morfología característica de las ondas cardíacas que conforman las señales de ECG para poder llevar a cabo el posterior proceso de clasificación.

El flujo de trabajo específico que se ha seguido a lo largo de dicho proyecto se puede ver en el diagrama que aparece en la imagen 4.1, ubicada en la página 66. No obstante, para un mayor nivel de detalle, también se puede ver explicado en la tabla 4.1, localizada en la página 68.

Tal y como se puede observar en el diagrama que recoge el orden seguido a lo largo del proyecto, en esta sección se presentan exclusivamente las etapas metodológicas vinculadas con el diseño, implementación y evaluación del sistema generador de señales ECG, así como aquellas fases relacionadas con la descarga y el procesamiento de los datos necesarios para su correcto funcionamiento. Por consiguiente, otro tipo de actividades de carácter no científico o técnico (investigación preliminar, revisión bibliográfica, documentación del proyecto, etc.) no aparecen en la memoria, sino que se describen en el apartado de **Planificación Temporal**, incluido en el **Anexo A - Plan de Proyecto Software**.

Etapas del proceso	Descripción breve	Herramientas y bibliotecas principales
Descarga de datos	Descarga de los datos de entrenamiento y validación de la red GAN a partir de datos reales	Python, wfdb, os, pandas, pickle
Preparación inicial de datos reales	Filtrado, normalización y segmentación de señales de ECG.	Python, NumPy, SciPy, os, wfdb
Construcción de la red GAN	Diseño e implementación de una red GAN para la generación de datos sintéticos.	Python, PyTorch ****
Entrenamiento de la red GAN	Entrenamiento de la red GAN con datos de ECG de pacientes reales	Python, PyTorch ****
Generación de datos sintéticos	Utilización de la red GAN para generar datos sintéticos de ECG a partir de vectores de ruido	Python, PyTorch ****
Posibilidades de diseño de un clasificador	Análisis sobre la funcionalidad de diseñar un clasificador de señales en base a su condición clínica	*****
Evaluación de señales generadas	Comparación entre señales reales y sintéticas mediante métricas cuantitativas.	MSE, DTW, Frechet Distance *****

Tabla 4.1: Fases en que se divide la metodología del proyecto y herramientas utilizadas. *Elaboración propia*

4.1. Descripción de los datos

El desarrollo de modelos basados en Inteligencia Artificial, especialmente aquellos orientados al tratamiento de bioseñales o señales de origen biomédico, se trata de un proceso complejo. Esta dificultad se debe, en gran medida, a la limitada disponibilidad de conjuntos de datos de una calidad adecuada, lo cual influye sobre el desarrollo de este tipo de modelos. [Ching et al., 2018] Por lo tanto, la naturaleza y características de estos datasets constituyen un pilar fundamental sobre el que hay que prestar especial atención al hacer la elección de los datos en este tipo de procesos. Esto se debe a que su calidad se va a ver directamente influenciada por estas propiedades y, en consecuencia, se verá afectada la validez y robustez de los sistemas generados en base a ellos. [Johnson et al., 2016]

Esta dependencia viene proporcionada por la estrecha relación que se establece entre el sistema implementado y el dataset utilizado durante este proceso creativo, incluyendo tanto el diseño como la validación




Figura 4.2: Diagrama de bloques que representa la importancia del conjunto de datos escogido. *Elaboración propia.*

del sistema. [Esteva et al., 2019] De hecho, la validez y la robustez de dicho sistema pueden llegar a verse afectadas o condicionadas por la calidad, la adecuación y las características del dataset empleado. Este es el motivo principal por el que este proceso requiere de un estudio preliminar y exhaustivo acerca del origen, la estructura y la naturaleza de los datos utilizados antes de comenzar cualquier fase relacionada con el diseño, entrenamiento o evaluación de los sistemas de este tipo, incluso cuando estos gozan de relativa sencillez. De hecho, en la figura 4.2, que se encuentra en la página 69 se puede ver la importancia del conjunto de datos elegido para la culminación exitosa del proyecto.

Para la realización del presente proyecto, se ha optado por utilizar un dataset o conjunto de datos con un elevado reconocimiento dentro de la comunidad científica. Este es el conjunto **PhysioNet / Computing in Cardiology Challenge 2017**, el cual fue propuesto por los organizadores de una conferencia científica como base para una competición académica internacional, hecho que otorga al conjunto de datos un respaldo científico y metodológico notable. [Computer in Cardiology (CinC),] [Goldberger et al., 2000]

Este conjunto se encuentra compuesto por un extenso número de registros, cada uno de los cuales corresponde a una señal de electrocardiograma (ECG). Estas señales se han registrado en pacientes reales mediante dispositivos portátiles o *wearables* de monitorización, por lo que se trata de señales de una única derivación, es decir, se han tomado en una sola dirección corporal. Además, cada una de estas señales se ha etiquetado clínicamente con la categoría diagnóstica a la que se corresponde. Este hecho permite que la información con la

Propiedad de los datos	Descripción
Fuente	PhysioNet / CinC Challenge 2017
Longitud del dataset de entrenamiento	12.186 registros de señales aproximadamente (8.528 públicos y 3.658 privados)
Tamaño del dataset de validación	300 registros de señales de ECG
Tipo de señal	ECG de una sola derivación
Duración de cada registro	Entre 9 y 60 segundos aprox.
Frecuencia de muestreo	300 Hercios (Hz)
Categoría clínica	Normal, Fribilación auricular, Otro, Ruido
Equilibrio entre clases	Desbalanceado (predominio de la clase "Normal")
Formato de almacenamiento	.mat (señal) + .hea (header o cabecera)

Tabla 4.2: Características principales del conjunto de datos CinC Challenge 2017. *Elaboración propia*

que se trabaja sea fisiológicamente veraz, por lo que es relevante a nivel clínico. [Clifford et al., 2017] [Goldberger et al., 2000] Se puede ver en la tabla 4.2, ubicada en la página 70 un pequeño resumen sobre las propiedades de los datos que conforman el dataset.

Estas características lo convierten en un conjunto idóneo para este proceso de generación de señales sintéticas. No obstante, también resulta apto para el entrenamiento, o incluso la validación de modelos automáticos de clasificación supervisada, predefinidos por otros desarrolladores para este tipo de bioseñales. [Hong et al., 2020]

Esta elección se va a justificar a lo largo de la presente sección. Para ello, se van a analizar y detallar en profundidad las propiedades más relevantes de las señales de ECG que componen dicho conjunto de datos. Algunas de las propiedades estudiadas son su origen clínico, su estructura, su duración o longitud, la clase diagnóstica con la que se corresponden, el formato de almacenamiento de la misma, entre otras características técnicas. Este análisis preliminar del conjunto de datos nos va a servir para contextualizar adecuadamente su fun-

ción dentro de la arquitectura del sistema desarrollado a lo largo del proyecto, así como para justificar su elección frente a otros datasets también públicos y disponibles en abierto en la plataforma de PhysioNet. [[Computer in Cardiology \(CinC\)](#),]

Origen y contexto del dataset

En la presente sección se explica detalladamente la procedencia, el propósito original y el contexto en el que fueron registrados los datos del dataset escogido. Este análisis se realiza con el objetivo de justificar la elección de este conjunto de datos, buscando demostrar su idoneidad para utilizarse como base del trabajo. Esto se hace en base a su adecuación para cumplir con los objetivos planteados en el mismo.

El conjunto de datos empleado en este proyecto corresponde al propuesto en la conferencia académica internacional **PhysioNet / Computing in Cardiology Challenge 2017**, celebrada en Rennes (Francia) durante el mes de septiembre del año 2017. [[Computer in Cardiology \(CinC\)](#),] [[Clifford et al., 2017](#)] Dicha edición fue organizada por los encargados de la propia conferencia, Computing in Cardiology (CinC), en colaboración con la plataforma de PhysioNet. Esta plataforma goza de reconocimiento entre los usuarios de bases de datos de este tipo por ofrecer repositorios de datos de naturaleza biológica en abierto, así como herramientas de análisis públicas para estos datos.

Dicha edición se centró en el análisis y estudio de las nuevas técnicas computacionales desarrolladas en el ámbito médico, específicamente en el área de la cardiología. Este es el motivo por el cual, a través de la celebración de la propia conferencia, se buscaba popularizar o fomentar la creación de algoritmos y sistemas computacionales capaces de detectar distintas condiciones clínicas y patológicas en pacientes a través de la representación visual de su funcionamiento cardíaco en registros de ECG de una sola derivación. Este hecho responde a una necesidad clínica real, ya que ayudaría al personal sanitario a la detección temprana y a la evaluación continuada en el tiempo de posibles anomalías cardíacas a través de estos registros.

En el marco de esta conferencia y en previsión de cumplir con sus objetivos, se propuso un reto dirigido a sus participantes, profesionales e investigadores procedentes de diversas instituciones a nivel internacional, centrado en el diseño de un modelo automático de este tipo. Para su resolución, se proporcionó por parte de la organización



Figura 4.3: Aparato de registro de señales de ECG de Alivecor. Ejemplo de funcionamiento [AliveCor,].

el conjunto de datos previamente citado, disponible en el repositorio [Clifford et al.,] de forma pública para cualquier usuario con acceso a la plataforma de PhysioNet.

Este set de datos, en el momento de la conferencia, se encontraba compuesto por un total de 8.528 registros de ECG públicos para entrenamiento y 300 para validación. Estos se encontraban anonimizados y etiquetados y podían ser descargados por cualquier persona. [Clifford et al.,] Estos fueron registrados en condiciones reales o semi-reales por sistemas de detección donados desinteresadamente por AliveCor. [AliveCor,] [Turakhia et al., 2019] Esta empresa se dedica a la comercialización de soluciones móviles de seguimiento cardíaco. Para llevar a cabo este seguimiento, realiza un monitoreo continuado de las constantes cardíacas del paciente desde su propio teléfono móvil. Estas mediciones las obtiene a partir de dispositivos portátiles de pequeño tamaño que portan los propios pacientes, también conocidos como dispositivos *wearables*, los cuales miden en una sola dirección corporal. Por este motivo, las señales registradas presentan una única derivación. La forma y funcionamiento de estos dispositivos se pueden observar en la figura 4.3 de la página 72.

Cabe destacar que este dataset ha sido utilizado en numerosas ocasiones por miembros de la comunidad científica de forma independiente al desafío propuesto por la conferencia CinC. Este conjunto de datos se ha utilizado tanto para el desarrollo de modelos automáticos como para el entrenamiento, la evaluación y la validación de modelos ya predefinidos

para tareas de clasificación o de generación sintética de señales electrocardiográficas (ECG). [Hong et al., 2020] [Rajpurkar et al., 2019]

Esto se debe a que dicho dataset presenta algunas características muy sólidas para ello, facilitando la reproducibilidad y trazabilidad de los estudios pertinentes: presenta un etiquetado clínico llevado a cabo por profesionales de la salud, cuenta con una cierta facilidad de validación de su origen, presenta una gran variedad en cuanto al tipo de registros que contiene y la libertad de su acceso; se trata de un set de datos completamente público.

El conjunto de estas características hace que el dataset sea perfecto para integrarlo en el presente trabajo como base de este. Incluso, puede servir a modo de validación para el sistema de generación de señales sintéticas que se desarrolla a lo largo de este TFG al ser una especie de dataset de referencia para la comunidad científica. Asimismo, este hecho también nos facilita la comparación del mismo con sistemas previos basados en el mismo conjunto de datos o con otras metodologías empleadas en otros modelos. Esto contribuye al refuerzo de su solidez metodológica y a la optimización de su calidad y funcionamiento, pudiendo evaluar el rendimiento del sistema actual.

Características generales

Una vez justificada la elección del conjunto de datos y expuesto su origen y propósito, esta sección se centra en describir las propiedades más relevantes y generales de las señales electrocardiográficas que lo componen. Comprender estas características es fundamental, ya que influyen directamente sobre su interpretación y la comprensión de su estructura, sobre todo en aquellas con alguna característica particular que pueda influir sobre su forma de tratamiento y, en consecuencia, la metodología aplicada a lo largo del proyecto. De hecho, el diseño y entrenamiento del modelo desarrollado pueden verse afectados por la naturaleza de las señales que componen el conjunto de datos empleado en este.

Por lo tanto, para garantizar tanto la coherencia como el correcto diseño, desarrollo, entrenamiento y validación del sistema, a lo largo de este apartado se resumen los aspectos tanto técnicos como clínicos fundamentales de los registros. Estos se encuentran recogidos en la tabla 4.2 de la página 70 e incluyen el número de registros que componen el dataset, su duración, el formato o extensión de almacenamiento

y las categorías diagnósticas en que se clasifican, entre otros. A continuación, se resumen las principales propiedades técnicas y clínicas de las señales ECG del dataset mientras que un análisis detallado y exhaustivo de cada una de estas propiedades se encuentra en el **Anexo D. Descripción formal de los datos.**

Tamaño y Division del Conjunto de Datos

El dataset público utilizado para este proyecto se compone de 8.528 registros de ECG destinados a entrenamiento y 300 registros para validación. Esta estructura, proporcionada por el CinC Challenge 2017, define el volumen de datos con el que se entrenará y evaluará el modelo, lo cual es fundamental para la definición del alcance del proyecto y para asegurar la reproducibilidad de los resultados. [Clifford et al., 2017]

Tipo de Señal y Número de Derivaciones

Las señales del dataset corresponden a registros de electrocardiogramas de una sola derivación (single-lead ECG). [Goldberger et al., 2000] Esta característica es consecuencia de haber sido obtenidas mediante dispositivos portátiles (wearables) de monitorización, lo que influye en la naturaleza de la información cardíaca capturada y, por tanto, en el diseño de los algoritmos de procesamiento y generación de señales. [Lu et al., 2020]

Frecuencia de Muestreo

Todas las señales del conjunto de datos fueron adquiridas a una frecuencia de muestreo constante de 300 Hz. Este valor es crucial para garantizar una resolución temporal adecuada que permita la identificación precisa de las morfologías de onda características del ECG y facilita el diseño de filtros y algoritmos de procesamiento digital.

Duración y Variabilidad de las Señales

Los registros de ECG en el dataset presentan una duración heterogénea, oscilando aproximadamente entre 7 y 60 segundos. Esta variabilidad temporal es un factor crítico para el desarrollo de modelos de aprendizaje automático, especialmente redes neuronales que requieren entradas

de longitud fija, lo que obligará a implementar técnicas específicas de preprocesamiento, como la segmentación o el padding.

Formato de Almacenamiento

Las señales del dataset se encuentran almacenadas en archivos con formato .mat, complementados con archivos de cabecera .hea que contienen metadatos relevantes para cada registro. Este formato estándar es común en el ámbito de las bioseñales y define la estructura de los datos que deben ser leídos y procesados.

Etiquetado y clasificación de los registros

Una vez analizadas las características estructurales de las señales que componen el conjunto de datos, resulta imprescindible abordar el proceso de etiquetado y la clasificación diagnóstica realizada sobre ellas. Esta información es un elemento esencial para el desarrollo de modelos automáticos, ya que proporciona la referencia supervisada necesaria durante las fases de entrenamiento y validación del sistema, y es la base fundamental para la condicionalidad de nuestro modelo generativo (cWGAN), permitiendo la síntesis de señales específicas para cada condición clínica. [Goldberger et al., 2000]

Las etiquetas asignadas a cada señal asocian un diagnóstico clínico a la actividad eléctrica registrada. Este etiquetado ha sido realizado por profesionales del ámbito sanitario, lo que otorga un respaldo clínico y una fiabilidad notable a la calidad del dataset y a la veracidad de las clases diagnósticas. [Clifford et al.,]

El conjunto de datos proporcionado para el **PhysioNet Challenge 2017** incluye, además de las señales electrocardiográficas, una etiqueta clínica asociada a cada registro.

En su versión original, las señales se clasifican en cuatro categorías diagnósticas principales:

- **Normal (N):** Corresponde a señales que reflejan un ritmo sinusal regular, sin alteraciones clínicas relevantes. Estas señales actúan como referencia para la identificación de patrones patológicos.
- **Fibrilación Auricular (A):** Incluye señales que presentan características compatibles con un episodio de fibrilación auricular,

como irregularidad en los intervalos RR y ausencia de ondas P definidas.

- **Otros ritmos (O):** Agrupa señales que no corresponden a un ritmo sinusal normal ni pueden clasificarse de forma concluyente como fibrilación auricular. Esta categoría es amplia y puede incluir otras arritmias (ej., taquicardias, bradicardias), o anomalías inespecíficas del ritmo.
- **Ruido ():** Registros que contienen artefactos, interferencias o alteraciones técnicas tan significativas que impiden una interpretación clínica fiable.

La existencia de estas cuatro clases permite a los modelos aprender a discriminar no solo entre normalidad y patología, sino también entre diferentes tipos de ritmos anómalos, siendo crucial para la versatilidad de aplicaciones futuras.

Aunque el etiquetado fue realizado por expertos cardiólogos o personal cualificado, es importante señalar que el propio diseño del reto reconocía un grado de ambigüedad diagnóstica en algunas señales. Esta incertidumbre inherente a la clasificación debe ser tomada en cuenta, ya que podría influir en el rendimiento de los modelos entrenados si no se aplican estrategias adecuadas para manejar la ambigüedad o el ruido en las etiquetas. [Surawicz and Knilans, 2008]

Un aspecto crítico de este dataset es su desbalance de clases, objetivo del presente proyecto. El número de señales por categoría diagnóstica varía significativamente, con un predominio de la clase 'Normal'. Esta descompensación es común en tareas de clasificación médica. Si no se maneja adecuadamente (por ejemplo, mediante sobremuestreo, submuestreo o el uso de funciones de pérdida ponderadas), puede llevar a un sesgo del modelo hacia la generación de señales de las clases mayoritarias, es decir, acarreará un proceso de sobreaprendizaje. [Johnson et al., 2016]

Técnicas utilizadas

La metodología seguida a lo largo de la realización del presente trabajo destaca por ser clara, estructurada cronológicamente en base a los pasos que se han realizado y adaptada al tipo de datos y objetivos planteados para este. Este enfoque metodológico se describe a lo largo de la presente sección, explicando la estructura dividida en forma de

etapas cronológicas en base a las necesidades y objetivos concretos para la implementación del proyecto en cada fase del desarrollo.

La profundización en la metodología escogida pretende justificar las decisiones técnicas tomadas en cuanto a la división del proyecto en las correspondientes fases o etapas se refiere, plasmando que esta no se ha hecho de forma arbitraria, sino que se ha escogido basándose para ello en criterios objetivos de trabajo, en la propia naturaleza de los datos empleados y en los objetivos planteados al comienzo del proyecto.

Cada paso de esta segmentación del procedimiento ha sido diseñado para cumplir con una necesidad, hecho que garantiza la calidad, reproducibilidad y coherencia de los resultados. Asimismo, también se han establecido criterios objetivos que permiten llevar a cabo una mejora progresiva de la solución a través de técnicas específicas, escogidas por su robustez y adecuación al problema. Para ello, estas técnicas evalúan el rendimiento y efectividad de las distintas etapas, permitiendo iterar y optimizar sobre ellas.

En este caso, el punto de partida fue la exploración y análisis detallado de los datos disponibles, hecho que permitió conocer sus características principales y, en base a ellas, definir los requisitos y procedimientos concretos para poder llevar a cabo su tratamiento y el desarrollo del propio trabajo. Una vez definidas estas necesidades, se estableció un flujo de trabajo modular, organizado en etapas consecutivas e interdependientes, que abarcaban distintos tipos de tareas, desde la carga y limpieza de los datos hasta la evaluación de los modelos desarrollados para la generación de los datos sintéticos.

4.2. Técnicas y Herramientas

En el desarrollo del presente Trabajo de Fin de Grado, se ha empleado un conjunto de herramientas y técnicas de Aprendizaje Profundo y procesamiento de señales, fundamentales para la implementación, entrenamiento y evaluación de los modelos generativos de ECG. Esta sección detalla los componentes tecnológicos y metodológicos utilizados.

Lenguajes de Programación y Librerías Fundamentales

La totalidad del proyecto ha sido implementada utilizando **Python**, reconocido por su versatilidad, su amplia comunidad y su robusto ecosistema de librerías para el Aprendizaje Automático. Las librerías esenciales que han vertebrado el desarrollo incluyen:

- **PyTorch**: Este *framework* de Aprendizaje Profundo ha sido la elección principal para la construcción, entrenamiento y gestión de la arquitectura de las redes neuronales generativas. PyTorch ofrece flexibilidad y un control granular sobre las operaciones del modelo, lo cual es crucial para la experimentación con arquitecturas de GANs. Su capacidad para operar eficientemente en unidades de procesamiento gráfico (GPU) es indispensable para acelerar el proceso de entrenamiento.
- **NumPy**: Utilizado para operaciones numéricas fundamentales, manipulación eficiente de arrays de datos y preprocesamiento de las señales de ECG.
- **Matplotlib**: Empleado para la visualización de datos, incluyendo la representación de las curvas de pérdida durante el entrenamiento, la graficación de señales ECG (tanto reales como generadas) y la creación de histogramas para comparar distribuciones de características.
- **SciPy**: Específicamente, el módulo `scipy.signal` ha sido clave para operaciones de procesamiento de señales, como el cálculo de la Densidad Espectral de Potencia (PSD) mediante el método de Welch.
- **NeuroKit2**: Esta librería especializada ha sido fundamental para el análisis de bioseñales, permitiendo la extracción automatizada de características clínicas y fisiológicas de las señales ECG, tales como la frecuencia cardíaca (HR), el intervalo PR, la duración del complejo QRS y el intervalo QT, así como la amplitud de la onda R. Esto ha facilitado una evaluación cuantitativa profunda de la calidad de las señales generadas.

Arquitecturas de Redes Neuronales Profundas

El núcleo del proyecto reside en la implementación de una variante avanzada de Redes Generativas Adversariales: la **Conditional**

Wasserstein Generative Adversarial Network with Gradient Penalty (cWGAN-GP). Esta elección se justifica por su reconocida estabilidad de entrenamiento y su capacidad para generar muestras de alta calidad y diversidad, superando las limitaciones de las GANs tradicionales.

- **Generador (G)**: Responsable de transformar un vector de ruido aleatorio (ruido latente) en una señal ECG sintética. Dada la naturaleza unidimensional de las señales ECG, el generador está compuesto principalmente por **capas convolucionales 1D des-aplicadas (transpose convolutions)** que aprenden a construir la señal secuencialmente, manteniendo la coherencia temporal y la morfología característica de un ECG. La condicionalidad se introduce concatenando la información de la clase deseada (ej., tipo de arritmia) al vector de ruido de entrada.
- **Discriminador (D) / Crítico**: Encargado de distinguir entre señales ECG reales y sintéticas. El discriminador también utiliza **capas convolucionales 1D** para procesar las señales, extrayendo características y determinando su autenticidad. Al igual que el generador, el discriminador recibe la información de la clase como una condición, lo que le permite juzgar la autenticidad de una señal en el contexto de su etiqueta de clase.

Funciones de Pérdida y Optimización

La estabilidad y el rendimiento de la cWGAN-GP se logran mediante la aplicación de funciones de pérdida específicas:

- **Pérdida de Wasserstein**: A diferencia de las GANs clásicas que utilizan la divergencia Jensen-Shannon, la WGAN emplea la **distancia de Wasserstein** (o distancia del transportista de tierra) como función de pérdida para el generador y el discriminador. Esta métrica proporciona gradientes más informativos y estables, incluso cuando el discriminador se vuelve muy preciso, lo que facilita una convergencia más suave y robusta.
- **Penalización de Gradiente (Gradient Penalty - GP)**: Para hacer cumplir la condición de 1-Lipschitz en el discriminador sin recurrir al recorte de gradientes (que puede llevar a un colapso de modos o a una capacidad limitada del modelo), se añade un término de penalización L_2 sobre la norma del gradiente del

crítico con respecto a sus entradas. Esta técnica es fundamental para la estabilidad y la calidad de las muestras generadas por las WGAN-GP.

Para la optimización de ambas redes (Generador y Discriminador), se ha utilizado el algoritmo **Adam**, un optimizador adaptativo que ajusta las tasas de aprendizaje para cada parámetro individualmente.

Preprocesamiento de Datos

El preprocesamiento de las señales ECG del *dataset* PhysioNet CinC Challenge 2017 ha sido un paso crítico para asegurar la calidad y el formato adecuado de los datos de entrada para las redes neuronales. Este proceso incluye:

- **Normalización:** Las señales ECG se han normalizado (ej., escalado Min-Max o estandarización Z-score) para asegurar que todos los valores se encuentren dentro de un rango consistente, lo cual es esencial para el entrenamiento de redes neuronales.
- **Segmentación y Reshape:** Las grabaciones de ECG han sido segmentadas en clips de longitud fija para adaptarse a las dimensiones de entrada requeridas por las arquitecturas de red. Se ha garantizado que el formato final sea compatible con las capas convolucionales 1D de PyTorch.

Recursos Computacionales

El entrenamiento de modelos de Aprendizaje Profundo, especialmente GANs, requiere una considerable capacidad computacional. Para este proyecto, se ha hecho uso de **Unidades de Procesamiento Gráfico (GPU)** compatibles con **NVIDIA CUDA**, lo que ha permitido reducir drásticamente los tiempos de entrenamiento y experimentar con un mayor número de épocas e hiperparámetros.

Métricas de Evaluación

La evaluación de la calidad de las señales ECG generadas se ha llevado a cabo mediante un enfoque multifacético, combinando métricas cuantitativas y cualitativas para proporcionar una comprensión exhaustiva del rendimiento del modelo:

- **Pérdidas del Generador y Discriminador:** Monitorización de las pérdidas de Wasserstein durante el entrenamiento para observar la convergencia y el equilibrio del juego adversarial.
- **Análisis Visual Cualitativo:** Inspección directa de las formas de onda de ECG generadas en comparación con las reales para evaluar su realismo morfológico y rítmico.
- **Métricas Cuantitativas de Distribución:**
 - **Estadísticas Descriptivas de Amplitud:** Comparación de la media y la desviación estándar de la amplitud de la señal entre los conjuntos de datos real y generado.
 - **Histogramas de Amplitud:** Análisis visual y cuantitativo de la distribución de los valores de amplitud de la señal.
 - **Densidad Espectral de Potencia (PSD):** Comparación de la distribución de energía en el dominio de la frecuencia, indicando si las señales generadas mantienen las mismas propiedades espectrales que las reales.
 - **Características Clínicas y Fisiológicas:** Comparación de las distribuciones (medias, desviaciones estándar, histogramas) de métricas específicas del ECG como la Frecuencia Cardíaca (HR), el Intervalo PR, la Duración QRS y el Intervalo QT, y la Amplitud de la Onda R, utilizando NeuroKit2. Esto proporciona una validación directa de la validez médica de las señales generadas.

Resultados

El presente capítulo presenta los resultados que han sido obtenidos a lo largo del desarrollo del Trabajo de Fin de Grado (TFG).

El objetivo principal de este trabajo es la generación de señales sintéticas mediante redes generativas adversariales (GAN) para balancear un conjunto de datos de electrocardiograma (ECG) desequilibrado. Estas señales generadas pueden ser posteriormente empleadas en un sistema de clasificación supervisada, con el objetivo de evaluar el impacto real y el potencial del sistema de generación desarrollado en la mejora del rendimiento de los modelos de detección de patologías cardíacas.

El dataset utilizado en vista a cumplir con el objetivo propuesto es el **PhysioNet / Computing in Cardiology Challenge 2017**, el cual presenta una distribución de clases claramente desequilibrada, tal y como se puede observar en la figura 5.1 de la página 84. [Clifford et al.,] Este presenta categorías, como las correspondientes a patrones anormales del ciclo cardíaco, notablemente infrarepresentadas con respecto a las clases que almacenan datos de pacientes sanos. Por lo tanto, cumple con creces los requisitos necesarios para ser utilizado como base del proyecto.

La configuración neuronal seleccionada para abordar este problema y mitigar sus consecuencias ha sido una red neuronal de tipo cWGAN-GP (Conditional Wasserstein GAN con Penalización de Gradiente). El principal motivo detrás de su elección es la posibilidad condicional de generación de datos que presenta, es decir, esta arquitectura permite condicionar a la red para que solo genere señales pertenecientes a una clase específica. Esto resulta imprescindible para el objetivo del proyecto, ya que para poder equilibrar las distintas categorías del

Type	# recording	Time length (s)				
		Mean	SD	Max	Median	Min
Normal	5154	31.9	10.0	61.0	30	9.0
AF	771	31.6	12.5	60	30	10.0
Other rhythm	2557	34.1	11.8	60.9	30	9.1
Noisy	46	27.1	9.0	60	30	10.2
Total	8528	32.5	10.9	61.0	30	9.0

Figura 5.1: Tabla que representa el desbalanceo de clases del conjunto de datos **PhysioNet / Computing in Cardiology Challenge**. [Clifford et al., 2017]

dataset, es necesario incrementar el número de muestras de aquellas categorías con menor representación en un valor específico.

El análisis de los resultados obtenidos, con el objetivo de evaluar si se ha logrado alcanzar la meta principal, se ha estructurado en los siguientes tres bloques principales, en los que se analiza si se han logrado alcanzar los objetivos específicos propuestos para cada una de las tareas:

1. **Evaluación del preprocesamiento y depurado de los datos:** En un primer momento, es necesario llevar a cabo la descarga, preprocesamiento y depurado de los datos con el objetivo de prepararlos para su uso en la red generativa. Por lo tanto, en este apartado se va a evaluar el rendimiento de las transformaciones efectuadas sobre las señales, así como su aplicabilidad sobre el sistema desarrollado.
2. **Evaluación del funcionamiento del modelo generativo (cWGAN):** Durante esta etapa, se efectúa el proceso de entrenamiento de la red, se evalúa su comportamiento mediante el análisis de la evolución de las funciones de pérdida y se comparan visualmente las señales sintéticas generadas por el modelo con las reales.
3. **Evaluación del balanceo de las clases:** A continuación, una vez entrenada la red generativa cWGAN, esta se pone en marcha con el objetivo de llevar a cabo un proceso de *data augmentation* sobre las clases minoritarias, y, por consiguiente, un proceso de balanceo de los registros por categoría. Una vez efectuada la generación sintética de señales, este bloque también abarca el estudio de la forma en que ha afectado la introducción de las

señales sobre la distribución del conjunto de datos, así como el proceso de balanceo.

Los resultados derivados de los procesos llevados a cabo en estos bloques se presentan a continuación, acompañados de un análisis crítico que permite valorar su relevancia y su grado de alineación con los objetivos específicos planteados al comienzo del proyecto, así como una discusión final acerca de si se ha conseguido alcanzar o no el objetivo principal del proyecto.

5.1. Evaluación del preprocesamiento y depurado de los datos

Antes de comenzar con la implementación de cualquier modelo de aprendizaje automático, es necesario asegurar la calidad de los datos que se van a usar en su desarrollo, puesto que estos van a influir de forma directa sobre su funcionamiento.

Para garantizar dicha calidad de estos, es fundamental preparar los datos de entrada de manera adecuada. En este apartado, se detalla el proceso concreto tanto de preprocesamiento como de depuración aplicado a las señales de electrocardiograma (ECG) del dataset **PhysioNet / Computing in Cardiology Challenge 2017**, el cual constituye la base para el desarrollo del sistema. [Clifford et al.,] Asimismo, también se evalúa la efectividad y relevancia de las transformaciones realizadas sobre sus datos para su posterior aplicación en la red generativa.

El trabajo comienza con la descarga de los datos desde dicho repositorio en PhysioNet, así como con su correspondiente carga en el entorno de trabajo utilizado y el acceso a los datos propiamente numéricos de la señal.

Una vez cargadas, al representar las señales, se puede observar que presentan una variabilidad considerable tanto en términos de amplitud como de duración, figura 5.2 de la página 86. Cabe mencionar que la duración de las señales depende del número de muestras que conforman la señal, ya que necesitan un procesamiento posterior para el cálculo de la duración temporal, tal y como se explica en el apartado de Metodología del proyecto.




Figura 5.2: Figura que representa la variabilidad entre las señales originales del dataset, tanto en amplitud como en duración. *Elaboración propia*

En base a esta variabilidad, se decide realizar un proceso de preparación de las señales para su uso como datos de entrada en redes generativas. Este lleva a cabo tanto procedimientos de depuración como de preprocesamiento de las señales.

El proceso seguido abarca las siguientes etapas:

1. **Filtrado de la señal:** Se aplica un filtro pasa banda de Butterworth a la señal con el objetivo de eliminar el ruido y los artefactos presentes en la señal, que se corresponden con los valores extremos de frecuencia, valores inferiores a 0.5 y superiores a 40 y que representan el ruido de la línea base y el ruido muscular o eléctrico, respectivamente. [Luo and Johnston, 2010] En la figura 5.3 de la página 88 se puede observar dos señales antes y después

de su proceso de filtrado, incluyendo la diferencia de espectro entre estas.

2. **Normalización y escalado de la señal:** Una vez filtradas, las señales han sido normalizadas siguiendo la distribución de Z-score en base a la media y desviación estándar global del dataset. Asimismo, luego se han escalado entre los valores $[-1, 1]$ para que todas las señales compartiesen escala y tener una representación de ellas más clara, a la vez que esto contribuye al entrenamiento de la red, puesto que todos los valores de entrada están dentro de una escala consistente. [Acharya et al., 2017]
3. **Segmentación en base al pico R del complejo QRS:** Como último paso del procesamiento, se incluye la segmentación de la señal de ECG en ventanas de menor tamaño. Esto es fundamental puesto que cada señal original corresponde a la grabación del ciclo cardíaco durante un período largo de tiempo (30 o 60 segundo), incluyendo varios latidos. Sin embargo, lo que interesa en este caso es tener cada latido del ciclo de forma individual. [Pan and Tompkins, 1985] Asimismo, esta segmentación también contribuye a una especie de proceso de *data augmentation*, ya que cada señal se va a dividir en fragmentos de señal en función de los picos que esta presenta. Por lo tanto, para conseguirlo se ha segmentado la señal en fragmentos centrados en el pico R del complejo QRS y extendiendo la ventana en 128 muestras hacia cada uno de los lados. De esta forma, se obtienen ventanas compuestas por un total de 257 muestras en cada caso. [Acharya et al., 2017] Además, durante esta segmentación también se ha realizado la depuración de señales ruidosas o incompletas, en las cuales no era posible la detección de picos para su segmentación, por lo que se han descartado en los posteriores pasos del trabajo.

Los picos a través de los que se va a realizar la segmentación se pueden observar en la figura 5.5 de la página 89, mientras que ventanas de señales una vez framentadas se observan en la imagen 5.6, ubicada en la página 89.

En síntesis, el exhaustivo proceso de preprocesamiento y depuración descrito ha permitido transformar las señales de ECG crudas y con una alta heterogeneidad del dataset PhysioNet en un conjunto de datos homogéneo, de alta calidad y listo para el entrenamiento del modelo generativo. La aplicación de un filtro pasabanda ha reducido significativamente el ruido y los artefactos, mientras que la normalización




Figura 5.3: Comparación de la señal en el dominio del tiempo y su espectro de magnitud antes y después de aplicar un filtro pasabanda. *Elaboración propia*




Figura 5.4: Comparación de escalas entre la señal original y la señal normalizada. *Elaboración propia*




Figura 5.5: Representación en forma de cruces rojas de los picos a través de los que se va a realizar la segmentación de la señal. *Elaboración propia*




Figura 5.6: Ventanas en que se divide la señal. Cada una de ellas corresponde a un latido cardíaco individual. *Elaboración propia*

y el escalado han garantizado una escala consistente, esencial para la estabilidad y eficiencia del entrenamiento de redes neuronales profundas como la cWGAN-GP. Finalmente, la segmentación centrada en los picos R no solo ha individualizado los latidos cardíacos, un requisito fundamental para la generación de latidos específicos, sino que también ha actuado como una fase crítica de depuración. Durante esta etapa, se han identificado y descartado las señales originales que presentaban un ruido excesivo o anomalías que impedían una segmentación fiable, asegurando así que el modelo aprenda a partir de datos limpios y representativos. Este conjunto de datos preprocesado y depurado es, por tanto, la base para garantizar el rendimiento óptimo y la robustez del modelo cWGAN en la generación de señales ECG sintéticas.

5.2. Evaluación del funcionamiento del modelo generativo (cWGAN-GP)

Esta sección se dedica a analizar y presentar los resultados obtenidos del entrenamiento y relacionados con la capacidad de generación de la red generativa adversaria condicional (cWGAN). El objetivo principal es demostrar si el modelo ha logrado aprender a generar señales ECG sintéticas realistas y, de manera crucial, si es capaz de generar estas señales de forma condicional, es decir, controlando el tipo de latido cardíaco generado, la clase a la que pertenecen las señales.

Análisis del proceso de entrenamiento

Antes de comenzar con la calidad de las señales generadas, es útil revisar el comportamiento del modelo a lo largo de su fase de entrenamiento. Esta evaluación proporciona una visión de gran importancia acerca de la estabilidad de la red GAN y su progreso durante la convergencia y ajuste de los parámetros de entrenamiento.

El entrenamiento de la red cWGAN se llevó a cabo con el objetivo de sintetizar señales ECG realistas y, de forma crucial, de manera condicional. En cuanto al proceso específico de entrenamiento llevado a cabo, cabe destacar que este se realizó de forma paralela en dos ocasiones, con el objetivo de analizar los parámetros más adecuados para la generación sintética de las señales. Ambos enfoques de entrenamiento se van a abordar a continuación, analizando sus respectivos comportamientos.

Antes de comenzar a analizar los resultados, es importante recordar la limitación de cómputo de los ordenadores de uso personal, incluso a través de entornos de memoria de GPU, hecho que ralentiza mucho el proceso de entrenamiento. De hecho, en algunas ocasiones incluso se vuelve necesaria una reducción en los valores de los parámetros con el objetivo de poder completar el entrenamiento.

El primer enfoque de entrenamiento se llevó a cabo durante 50 épocas, utilizando un tamaño de lote (batch size) de 16 y una dimensión de embedding igual a 64. En cuanto a los optimizadores, tanto el del generador como el del discriminador fueron Adam, puesto que eran los más recomendados en la bibliografía para este tipo de modelos de aprendizaje profundo. En cuanto a los parámetros de aprendizaje, el

5.2. EVALUACIÓN DEL FUNCIONAMIENTO DEL MODELO GENERATIVO (CWGAN-GP)

91

```
Epoch [31/50] - Batch [3501/4158] - Pérdida D: -0.2205 - Pérdida G: 5.2190
Epoch [31/50] - Batch [3601/4158] - Pérdida D: -0.3141 - Pérdida G: 4.3838
Epoch [31/50] - Batch [3701/4158] - Pérdida D: -0.4294 - Pérdida G: 4.5364
Epoch [31/50] - Batch [3801/4158] - Pérdida D: -0.1937 - Pérdida G: 4.1173
Epoch [31/50] - Batch [3901/4158] - Pérdida D: -0.5426 - Pérdida G: 4.3851
Epoch [31/50] - Batch [4001/4158] - Pérdida D: -0.2499 - Pérdida G: 4.9163
Epoch [31/50] - Batch [4101/4158] - Pérdida D: -0.1901 - Pérdida G: 4.1139
Checkpoint guardado en: /content/drive/MyDrive/MisCheckpointsGAN_ECG_2/checkpoint_epoch_31_20250706_055356.pth
Epoch [32/50] - Batch [1/4158] - Pérdida D: -0.2667 - Pérdida G: 5.7145
Epoch [32/50] - Batch [101/4158] - Pérdida D: -0.1921 - Pérdida G: 4.4053
Epoch [32/50] - Batch [201/4158] - Pérdida D: -0.1736 - Pérdida G: 4.9056
Epoch [32/50] - Batch [301/4158] - Pérdida D: -0.1419 - Pérdida G: 6.0774
Epoch [32/50] - Batch [401/4158] - Pérdida D: -0.1691 - Pérdida G: 5.0396
Epoch [32/50] - Batch [501/4158] - Pérdida D: -0.5189 - Pérdida G: 4.2416
```

Figura 5.7: Captura de pantalla que representa la fluctuación de los valores de pérdida del generador y del generador, ya que estos compiten entre ellos.
Elaboración propia

entrenamiento utilizó una tasa de aprendizaje de 0.0001 y un valor de critic-iter igual a 4, que asegura un correcto funcionamiento del discriminador frente al generador.

El segundo enfoque de entrenamiento, por su parte, se realizó durante 100 épocas, con un tamaño de lote de 16, una dimensión de embedding igual a 50 y los mismos optimizadores Adam que en el caso anterior. En cuanto al aprendizaje, la tasa es la misma, igual a 0.0001 pero cambia el valor de critic-iter, que en este caso es 5, lo que garantiza un mejor entrenamiento del discriminador.

Como es característico de las redes GAN, en ambos casos se observó un juego adversario entre el generador (G) y el discriminador (D), donde G intenta producir datos que D no pueda distinguir de los reales, mientras que D busca mejorar su capacidad de discriminación.

A lo largo de las distintas épocas que tuvieron lugar a lo largo del entrenamiento se observa como ha habido una fluctuación de los valores de pérdida tanto del generador como del discriminador. Esto se observa en la figura 5.7 de la página 91, en el que se recoge el primer enfoque de entrenamiento.

De hecho, se puede apreciar que la fluctuación no es excesivamente grande, el generador presenta una función de pérdida con un valor cercano a 4, mientras que el discriminador cercano a 0, aunque en valores negativos. Un balance adecuado entre las pérdidas de G y D es crucial para un entrenamiento exitoso, evitando que una de las redes domine a la otra y llevando a un colapso de modo o a una generación de baja calidad, por lo que, en base a los valores de las pérdidas el entrenamiento se puede clasificar como adecuado para el objetivo requerido.

Figura 5.8: Señales de cada una de las clases del dataset generadas artificialmente.

Métricas de Evaluación del Rendimiento Generativo

La evaluación de modelos generativos como las GANs es un desafío inherente, ya que no existe una métrica única que capture completamente el realismo, la diversidad y la coherencia condicional de las muestras generadas. Por ello, se ha adoptado un enfoque multimodal que combina la inspección visual cualitativa con métricas cuantitativas consolidadas en la literatura.

Evaluación Cualitativa (Insepección visual)

Una de las primeras aproximaciones para evaluar la calidad de las señales sintéticas es la inspección visual. Esta permite a un experto (o al propio investigador, con conocimiento de la morfología del ECG) discernir patrones anómalos, la presencia de ruido, o la falta de similitud con las señales reales. Se examinarán ejemplos de señales generadas para cada clase para verificar la coherencia con los patrones esperados de ECG (ondas P, complejos QRS, ondas T) y la ausencia de artefactos evidentes.

La figura 5.8 muestra ejemplos representativos de ECGs sintéticos y reales para cada categoría.

- **Clase Normal:** Las señales generadas exhiben una morfología rítmica regular, con las ondas P, complejos QRS y ondas T claramente definidos y espaciados de manera consistente, replicando fielmente los patrones sinusales normales.
- **Clase Fibrilación Auricular:** Las señales sintéticas replican la irregularidad característica de los intervalos RR y la ausencia o variación de las ondas P, consistentemente con un ritmo de A.
- **Clase Otro Ritmo:** El modelo ha logrado capturar la variabilidad de patrones dentro de esta clase heterogénea, generando señales que presentan anomalías rítmicas o morfológicas diversas, distintas de la AFib y de un ritmo normal.

- **Clase Ruido:** Las señales sintéticas en esta categoría incorporan artefactos y distorsiones que se asemejan al ruido presente en los registros reales, demostrando la capacidad del modelo para aprender y replicar incluso características no fisiológicas.

En general, la coherencia visual entre las señales reales y las sintéticas de la misma clase es notable, lo que sugiere que el modelo ha aprendido con éxito las características condicionales de cada categoría.

Evaluación Cuantitativa

Comparación de Estadísticas Básicas de la Señal

Un primer nivel de evaluación cuantitativa implica el análisis de las propiedades fundamentales de la señal en el dominio temporal.

- **Media y Desviación Estándar de la Amplitud:**
 - **Metodología:** Se calcula la media y la desviación estándar de la amplitud de todos los puntos de datos de las señales ECG para el conjunto real y el conjunto generado. Alternativamente, se podrían calcular estas estadísticas para cada señal individual y luego promediar los resultados.
 - **Resultados Esperados:** Un modelo generativo exitoso debería producir señales cuya media y desviación estándar de amplitud sean **muy similares** a las de los datos reales. Desviaciones significativas indicarían un desajuste en la escala global de las amplitudes o una variabilidad inadecuada en las señales generadas.
- **Distribución de Amplitud (Histogramas):**
 - **Metodología:** Se construyen histogramas de la distribución de todos los valores de amplitud (o de la amplitud máxima/mínima de cada señal) para ambos conjuntos de datos.
 - **Resultados Esperados:** Los histogramas de las señales generadas deberían **superponerse estrechamente** con los de las señales reales, mostrando una distribución de amplitud similar. Cualquier desviación en la forma, el pico o el rango del histograma sugeriría que el generador no ha capturado completamente la distribución de amplitud de los datos reales.

Análisis en el Dominio de la Frecuencia

El análisis en el dominio de la frecuencia proporciona información crucial sobre la composición rítmica y las características de ruido de las señales.

- **Densidad Espectral de Potencia (PSD):**
 - **Metodología:** Se calcula la Densidad Espectral de Potencia (PSD) para cada señal de los conjuntos real y generado utilizando métodos como la estimación de Welch. Posteriormente, se promediarían los PSDs individuales para obtener una representación del espectro de potencia promedio para cada conjunto.
 - **Resultados Esperados:** Las curvas de PSD promedio de las señales generadas deberían **coincidir cercanamente** con las de las señales reales a través de todo el espectro de frecuencias relevantes (0-40 Hz para ECG). La presencia de picos o caídas en frecuencias atípicas en las señales generadas podría indicar artefactos, falta de diversidad rítmica o una incapacidad para replicar la estructura de ruido inherente a los ECGs reales. La correspondencia en el PSD es un fuerte indicador de que el modelo ha capturado tanto la morfología de la onda como el ruido fisiológico.

Evaluación de Características Clínicas y Fisiológicas

Esta es la evaluación más relevante para garantizar la validez clínica de las señales ECG generadas. Se basa en la extracción de parámetros fisiológicos estándar.

- **Frecuencia Cardíaca (HR):**
 - **Metodología:** Se detecta la frecuencia cardíaca de cada señal ECG (real y generada) utilizando algoritmos de detección de picos R. Se recopilarían las HR de todas las señales para ambos conjuntos.
 - **Resultados Esperados:** La **media y la desviación estándar** de la frecuencia cardíaca de las señales generadas deberían ser **próximas** a las de las señales reales. Un histograma

de la distribución de HR debería mostrar una superposición significativa, indicando que el modelo es capaz de generar latidos con un ritmo cardíaco plausible y una variabilidad normal.

- **Duración de Intervalos y Ondas (PR, QRS, QT, Amplitud R):**
 - **Metodología:** Se extraen los puntos clave de las ondas P, QRS y T para calcular las duraciones de intervalos como PR, QRS y QT, así como la amplitud de la onda R, para cada señal. Estas características se recopilarían para ambos conjuntos de datos.
 - **Resultados Esperados:** Las **distribuciones (medias, desviaciones estándar, histogramas)** de estas métricas clínicas críticas para las señales generadas deberían **replicar fielmente** las de las señales reales. Esto incluiría no solo los valores centrales sino también la variabilidad. Por ejemplo, la duración del QRS de las señales generadas debería caer dentro de los rangos fisiológicos normales y mostrar una dispersión similar a la de los datos reales. Desviaciones en estas métricas indicarían que el modelo no ha capturado la morfología correcta de las ondas o la temporalidad de los eventos cardíacos, comprometiendo la validez clínica de los ECGs sintéticos.

Consideraciones Adicionales

La realización de una evaluación cuantitativa completa es un pilar fundamental en la validación de modelos generativos. Aunque la implementación detallada de todas estas métricas excede el alcance práctico de este Trabajo de Fin de Grado, la discusión teórica de su aplicación y los resultados esperados sirven para ilustrar la robustez y la profundidad con la que la calidad de los ECGs generados puede ser analizada. Un resultado exitoso en estas métricas indicaría que la cWGAN-GP no solo produce formas de onda visualmente convincentes, sino que también captura la compleja distribución estadística y las propiedades fisiológicas inherentes a las señales ECG reales, lo que valida su potencial como herramienta para el aumento y balanceo de datos en aplicaciones clínicas.

Categoría Clínica	Número de Registros	Porcentaje (%)
Normal (N)	6284	73.7
Fibrilación Auricular (A)	771	9.0
Otros Ritmos (O)	2557	13.9
Ruido	128	1.5
Total	8528	100.0

Tabla 5.1: Distribución de los registros de ECG del dataset en función de su categoría clínica. *Elaboración propia.*

5.3. Evaluación del balanceo de las clases

La disponibilidad de conjuntos de datos equilibrados es fundamental para el desarrollo y entrenamiento de modelos robustos en Inteligencia Artificial, especialmente en el ámbito médico, donde la escasez de muestras para ciertas condiciones patológicas es una problemática común.

Ejemplo de ello, el conjunto de datos **PhysioNet / Computing in Cardiology Challenge 2017**, empleado en este TFG, presenta un marcado desequilibrio entre sus categorías diagnósticas, lo cual fue una de las principales motivaciones para la implementación de una red generativa adversarial condicional (cWGAN). Esta sección detalla la distribución original de las clases y evalúa cómo la generación de señales sintéticas ha contribuido a mitigar dicho desbalance.

Distribución desequilibrada de las clases

El dataset original se encuentra compuesto por un total de 8.528 registros de entrenamiento, distribuidos de forma heterogénea entre las cuatro categorías clínicas. Como se observa en la tabla 5.1 localizada en la página 96 y se observa en la figura 5.9 de la página 97, la clase 'Normal' es la dominante, representando la mayoría de las muestras disponibles, mientras que las categorías que representan otras condiciones, tanto patológicas como de ruido constituyen una fracción significativamente menor.

Este desequilibrio supone un reto considerable para el entrenamiento de modelos de aprendizaje automático, ya que puede llevar a sesgos




Figura 5.9: Representación de la distribución de las muestras del dataset en función de su clase, haciendo patente el desbalanceo. *Elaboración propia*

en los modelos, favoreciendo la clase mayoritaria y resultando en un rendimiento deficiente en la detección de las condiciones minoritarias.

Estrategia de balanceo mediante generación sintética

Para abordar el problema del desbalance presente en las categorías del conjunto de datos del trabajo se ha utilizado una red neuronal de tipo cWGAN con el objetivo de generar datos sintéticos específicamente para las categorías minoritarias: 'Fibrilación Auricular', 'Otro Ritmo' y 'Ruido'. El objetivo del proyecto es incrementar el número de muestras en estas clases hasta alcanzar un tamaño comparable al de la clase 'Normal' o una distribución más uniforme de las categorías, hecho que permite proporcionar al modelo de entrenamiento una representación más equitativa de cada condición clínica.

Por lo tanto, la generación se ha llevado a cabo de forma condicional, asegurando que las señales sintéticas producidas correspondan a la clase deseada, manteniendo así las características fisiológicas propias de cada patología o tipo de señal.

Distribución de clases tras la generación sintética

Una vez concluida la fase de generación, el dataset se ha enriquecido con las nuevas señales sintéticas generadas. Asimismo, la integración de estas señales ha transformado la distribución de las clases, resultando en un conjunto de datos mucho más equilibrado..

Las distintas señales que han sido generadas, en base a la clase que presentan se pueden observar a continuación junto a una imagen real, lo que permite su comparación.

5.4. Análisis y Discusión Final

Los resultados demuestran la efectividad de la cWGAN en la tarea de balancear el conjunto de datos de ECG. La drástica reducción del desequilibrio de clases mediante la generación de muestras sintéticas para las categorías minoritarias es un logro significativo del proyecto.

Un dataset balanceado ofrece múltiples ventajas:

1. **Preparación para Clasificadores:** Aunque el presente TFG no incluye la implementación de un clasificador final, la disponibilidad de un conjunto de datos equilibrado es un requisito previo fundamental para el entrenamiento exitoso de modelos de clasificación en futuras fases. Reduce el riesgo de que el clasificador sesgue sus predicciones hacia la clase mayoritaria.
2. **Representatividad:** Asegura que el modelo generativo haya aprendido a producir muestras representativas de todas las clases, incluyendo las menos frecuentes, lo cual es crucial para la utilidad clínica.
3. **Investigación y Desarrollo:** Proporciona una base de datos más robusta y versátil para futuras investigaciones, permitiendo explorar con mayor profundidad las características de las arritmias raras y otras condiciones.

Conclusiones

El presente Trabajo de Fin de Grado abordó un desafío crítico en el campo de la Inteligencia Artificial aplicada a la medicina: la escasez y el desequilibrio de datos en conjuntos de bioseñales complejas como las de electrocardiograma (ECG). El objetivo principal fue explorar y demostrar la capacidad de los modelos generativos, específicamente una Conditional Wasserstein Generative Adversarial Network con Penalización de Gradiente (cWGAN-GP), para generar señales de ECG sintéticas realistas y acondicionadas a diversas categorías clínicas, con el fin último de mitigar el desbalance de clases en un dataset de referencia.

6.1. Logros y resultados principales

Los resultados obtenidos en este proyecto confirman la validez de la metodología propuesta y el cumplimiento de los objetivos planteados. Estos se han estructurado en secciones para poder contextualizar cada uno de una forma adecuada, en comparación a los objetivos propuestos en el trabajo.

Mitigación del desequilibrio de clases

Se ha demostrado de forma efectiva cómo la cWGAN-GP puede ser una herramienta poderosa para abordar el problema del desbalance de clases. Al generar un número significativo de señales sintéticas para las categorías minoritarias ('Fibrilación Auricular', 'Otro Ritmo', 'Ruido'), se ha logrado transformar el dataset original, marcadamente

desequilibrado, en un conjunto de datos mucho más balanceado. Este balanceo es crucial para el entrenamiento robusto de futuros modelos de clasificación, evitando sesgos hacia la clase mayoritaria ('Normal') y mejorando la capacidad de detección de patologías raras.

Funcionamiento robusto del modelo generativo (cWGAN-GP)

La cWGAN-GP implementada ha demostrado una notable capacidad para generar señales de ECG sintéticas de alta calidad y con una considerable estabilidad en el proceso.

Estabilidad en el entrenamiento

Las curvas de pérdida del Generador y del Crítico/Discriminador evidenciaron un comportamiento estable y una convergencia adecuada a lo largo de las épocas de entrenamiento en ambos casos, confirmando la solidez de la arquitectura y el éxito de la penalización de gradiente en la estabilización del proceso de entrenamiento.

Realismo y diversidad cualitativa

La inspección visual de las señales sintéticas generadas, en comparación con las señales reales de cada clase, mostró una sorprendente similitud en la morfología, el ritmo y la presencia de características distintivas. El modelo logró replicar eficazmente las ondas P, complejos QRS y ondas T, así como las irregularidades propias de las arritmias o el patrón de ruido, para cada categoría específica.

Condicionabilidad Exitosa

La capacidad del modelo para generar señales específicas para cada una de las cuatro categorías diagnósticas demuestra la efectividad del mecanismo de acondicionamiento implementado, lo que es vital para la utilidad clínica de los datos generados.

Aporte a la Resolución de Desafíos en Datos Médicos

Este trabajo propone y valida una solución efectiva para un problema persistente en la aplicación de la IA en medicina: la dificultad de obtener grandes volúmenes de datos etiquetados y balanceados. La generación de datos sintéticos de ECG con cWGAN-GP abre nuevas vías para la investigación y el desarrollo de sistemas de diagnóstico automatizados más precisos y menos dependientes de la disponibilidad de grandes cohortes de pacientes con patologías raras.

6.2. Limitaciones del trabajo

A pesar de los resultados prometedores, es importante reconocer ciertas limitaciones inherentes a la naturaleza del proyecto y a la fase actual de la investigación. Estas se detallan a continuación.

Ausencia de clasificador final

Este TFG se centró en la generación de datos sintéticos de alta calidad. Si bien el balanceo del dataset prepara el terreno, no se llegó a implementar ni a evaluar un modelo de clasificación final utilizando el dataset extendido. La verdadera utilidad de las señales sintéticas en la mejora del rendimiento de un clasificador es una hipótesis que requiere validación empírica en futuros trabajos.

Complejidad del modelo y coste computacional

El entrenamiento de una cWGAN-GP es computacionalmente intensivo, requiriendo recursos considerables y tiempos de entrenamiento prolongados. Esto puede representar una barrera para su replicación o escalabilidad en entornos con recursos limitados, como el uso de ordenadores personales.

Dependencia de la calidad del dataset original

La calidad de las señales sintéticas está inherentemente ligada a la calidad y diversidad de las señales reales utilizadas para el entrena-

miento. Si el dataset original contiene sesgos o artefactos específicos, el modelo generativo podría replicarlos.

Variabilidad en clases heterogéneas

Aunque la cWGAN-GP mostró un buen desempeño, la generación de señales para la clase 'Otro Ritmo', por su propia naturaleza heterogénea, siempre presentará un mayor desafío para el modelo en comparación con clases más homogéneas como 'Normal' o 'Fibrilación Auricular'.

Lineas de trabajo futuras

En este capítulo se realiza un análisis crítico acerca de las consideraciones del trabajo que pueden abordarse en situaciones futuras para seguir explorando la generación sintética de señales de ECG. Esto se hace con el objetivo de mejorar la calidad de los conjuntos de datos clínicos disponibles, así como de continuar ampliando los resultados obtenidos mediante la introducción de optimizaciones en el sistema generador desarrollado o llevando a cabo una generalización de estos sistemas hacia nuevos tipos de datos.

Por lo tanto, a lo largo del presente capítulo, se detallan tanto las limitaciones encontradas a lo largo del proyecto como aquellas oportunidades identificadas susceptibles de incrementar la calidad, el impacto o la aplicabilidad del mismo.

Estas se van a detallar y a explicar en profundidad a continuación.

7.1. Capacidad de cómputo

Uno de los aspectos fundamentales a considerar en el desarrollo y aplicación de modelos basados en aprendizaje automático, como las redes generativas adversariales (GAN) utilizadas en este trabajo para la generación y análisis de señales electrocardiográficas, es la capacidad de cómputo requerida.

Esta aparece en primer lugar ya que ha sido la limitación más importante encontrada durante la realización del proyecto, especialmente en la fase de entrenamiento del modelo de aprendizaje automático.

El desarrollo de la parte programática del trabajo se ha desarrollado en la plataforma de Google Colab, por las ventajas que esta presenta. Desde mi experiencia, trabajar con Colab fue útil al principio, pero se volvió muy limitante durante la fase de entrenamiento. Esto se debe a que cuenta con un gran inconveniente para las tareas de larga duración, la vida útil del entorno antes de desconectarse es de 12 horas como máximo. Este trabaja por defecto utilizando la memoria CPU, la cual es demasiado lenta para las tareas de entrenamiento que requieren una mayor capacidad de cómputo. Se puede pagar una tasa para la utilización de la GPU en Colab Pro, pero aún así esta no es suficiente para realizar procesos de entrenamiento profundo con los valores más óptimos para ello.

Esto se debe a que el entrenamiento de redes profundas suele demandar recursos computacionales significativos, tanto en términos de tiempo como de potencia de procesamiento y memoria, lo cual, sumado a la gran cantidad de datos que debe procesar el modelo de aprendizaje utilizado, puede limitar los resultados obtenidos. [Goodfellow et al., 2016] [Strubell et al., 2019]

Por ello, una línea futura importante es la utilización de ordenadores con una elevada capacidad de cómputo, incluso de superordenadores, que permitan acelerar este proceso de aprendizaje de las funciones de pérdida, permitiendo hacer más pruebas y elegir los parámetros más adecuados en cada caso.

Asimismo, esta capacidad de cómputo también incluye una línea de mejora futura centrada en la optimización del modelo y los procesos asociados para reducir el coste computacional sin sacrificar la calidad ni la precisión de los resultados.

Algunas de las optimizaciones más destacadas en estos casos y que se pueden incluir en desarrollos futuros se van a desarrollar en apartados siguientes como futuras mejoras del proyecto.

Estas mejoras permitirían no solo acelerar tanto el proceso de entrenamiento como de evaluación, sino también facilitar la integración de los modelos desarrollados en aplicaciones clínicas y dispositivos portátiles para diagnóstico y monitoreo continuo de pacientes con alguna patología de carácter cardíaco. Incluso, se podrían añadir parámetros que explicasen las decisiones tomadas por los modelos, contribuyendo así a un uso más global por usuarios no expertos.

7.2. Implementación de un clasificador

La figura del clasificador es de gran importancia para respaldar el funcionamiento y validez de las señales artificiales de ECG creadas. Por este motivo, el diseño e implementación del mismo puede ser de utilidad como línea futura del trabajo. De hecho, se podría considerar como la línea futura más relevante del mismo.

7.3. Exploración y experimentación de distintas arquitecturas

Si bien el modelo empleado mostró resultados satisfactorios, la experimentación con arquitecturas más avanzadas o híbridas podría potenciar el rendimiento. Por ejemplo, explorar redes neuronales recurrentes (RNN), transformers o combinaciones con atención podría capturar mejor las características temporales y contextuales de las señales electrocardiográficas. [Han et al., 2015] Asimismo, evaluar diferentes configuraciones de hiperparámetros y técnicas de regularización permitiría encontrar configuraciones óptimas para evitar el proceso de sobreajuste y mejorar la capacidad predictiva del modelo.

Asimismo, en relación a la mejora de la capacidad de cómputo del sistema, se puede valorar la exploración de arquitecturas más eficientes o la utilización de métodos de aprendizaje profundo ligeros, como redes neuronales convolucionales compactas o modelos de destilación, aunque los resultados pueden no ser tan estables como utilizando una cWGAN-GP o no poderse introducir la clase concreta a la que deben pertenecer las señales. [LeCun et al., 2015]

Sin embargo, la elección de la arquitectura final dependerá del propósito concreto del análisis. Mientras que las redes mencionadas en un primer momento, con un mejor desarrollo de resultados, pueden parecer más óptimas es necesario valorar el equilibrio entre los requerimientos de memoria y recursos que presentan y si los resultados son satisfactorios en proporción a la inversión efectuada.

Lo mismo pasa con las arquitecturas más sencillas, es preciso valorar si el ahorro de recursos que presentan afecta negativamente a los resultados que devuelven o si la pérdida de calidad es un factor que se puede asumir en base a sus requerimientos computacionales.

7.4. Validación multidisciplinar

Un aspecto clave para la aplicabilidad real del proyecto es la integración de conocimiento clínico en las fases de diseño y evaluación. Colaborar con profesionales del ámbito de la salud para validar los resultados y ajustar los criterios seguidos a lo largo de las distintas etapas del proyecto puede facilitar la implementación del modelo en entornos clínicos reales, como herramienta de apoyo diagnóstico.

Además, se podrían incorporar métricas específicamente clínicas que reflejen mejor la utilidad práctica del modelo en el ámbito de la salud, más allá de los indicadores técnicos utilizados para medir la viabilidad del modelo generado. [Goldberger et al., 2000] [Azuaje et al., 2006]

7.5. Generalización a otros tipos de señales

Aunque el proyecto se ha centrado en señales ECG, la metodología desarrollada podría aplicarse o adaptarse a otros tipos de señales biomédicas (como electroencefalogramas (EEG), señales respiratorias, etc.). [Faust et al., 2018] La aplicación de estos modelos a otros enfoques permitiría validar la versatilidad del enfoque, así como ampliar el campo de aplicación o, incluso, desarrollar modelos que pudieran llegar a combinar diferentes fuentes de información para un diagnóstico más completo.

7.6. Robustez del sistema

Aunque se ha utilizado un conjunto de datos estándar y reconocido a lo largo del proyecto, la incorporación de bases de datos adicionales con características distintas (por ejemplo, señales de ECG adquiridas en diferentes condiciones clínicas o con diferentes dispositivos) permitiría mejorar la generalización y robustez del modelo. [Goldberger et al., 2000] Esta mejora de la robustez también contribuiría a una utilización más extendida de este tipo de sistemas generadores, con el objetivo de obtener conjuntos de datos equilibrados. [Moody and Mark, 2001]

7.7. Desarrollo de una plataforma de fácil manejo

Para facilitar la implementación del trabajo en otros entornos y su uso por parte de otros investigadores o profesionales, sería recomendable desarrollar una plataforma o aplicación que permita cargar nuevas señales (no necesariamente del actual conjunto de datos), procesarlas y obtener resultados de manera automatizada y visual. Esta aplicación podría contribuir al aumento de la difusión y del impacto del proyecto, además de permitir una evaluación continua de este con datos externos.

7.8. Generalización a registros con mayor número de derivaciones

En el presente trabajo, el análisis y generación de señales se ha realizado principalmente utilizando registros electrocardiográficos con una única derivación, lo que ha permitido un desarrollo más controlado y enfocado en señales individuales.

Sin embargo, en la práctica clínica y en investigación es común disponer de registros ECG con múltiples derivaciones simultáneas (por ejemplo, un número habitual de derivaciones es 12 o los registros Holter multicanal), que ofrecen una visión más completa y detallada de la actividad cardíaca. [Luz et al., 2016]

En este sentido, una posible línea futura fundamental consiste en la generalización del método para que pueda manejar y aprovechar la información contenida en registros con mayor número de derivaciones, para lo cual sería necesario realizar una adaptación de las técnicas de preprocesamiento y segmentación para trabajar con señales multicanal, así como considerar la heterogeneidad establecida entre derivaciones puesto que cada señal se toma desde una dirección distinta.

Cabe destacar que la extensión a registros multicanal ampliaría notablemente la aplicabilidad clínica de los modelos desarrollados, permitiendo un análisis más preciso y completo, y facilitando la detección y diagnóstico de patologías complejas que pueden no ser evidentes en registros limitados.

En conjunto, estas líneas futuras ofrecen un amplio abanico de posibilidades para ampliar, optimizar y validar el modelo propuesto,

acercándolo a un uso real en entornos clínicos y mejorando su aplicabilidad en diversos contextos biomédicos.

Bibliografía

- [Acharya et al., 2017] Acharya, U. R., Fujita, H., Lih, O. S., Hagiwara, Y., Tan, J. H., and Adam, M. (2017). Automated detection of arrhythmias using different intervals of tachycardia ecg segments with convolutional neural network. *Information Sciences*, 405:81 – 90.
- [Addison, 2017] Addison, P. S. (2017). *The Illustrated Wavelet Transform Handbook. Introductory Theory and Applications in Science, Engineering, Medicine and Finance, Second Edition*. CRC Press, 2 edition.
- [Aggarwal, 2015] Aggarwal, C. C. (2015). *Data Mining: The Textbook*. Sptinger Charm, 1 edition.
- [AliveCor,] AliveCor. Alivecor española. [Internet, accedido el 25 de abril de 2025].
- [Arjovsky et al., 2017] Arjovsky, M., Chintala, S., and Bottou, L. (2017). Wasserstein gan. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 214–223. PMLR.
- [Azuaje et al., 2006] Azuaje, F., Clifford, G., and McSharry, P. (2006). *Advanced Methods and Tools for ECG Data Analysis*. Artech House, 1 edition.
- [Barret et al., 2019] Barret, K. E., Barman, S. M., Brooks, H. L., and Yuan, J. X. J. (2019). *Ganong’s Review of Medical Physiology*. McGraw Hill Education, 26 edition.
- [Bayés de Luna, 2012] Bayés de Luna, A. (2012). *Electrocardiografía clínica*. Editorial Publicaciones Permanyer, 1 edition.

- [Bishop, 2006] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer-Verlag, 2 edition.
- [Boron and Boulpaep, 2016] Boron, W. F. and Boulpaep, E. L. (2016). *Medical Physiology*. Elsevier, 3 edition.
- [Braunwald et al., 2014] Braunwald, E., Mann, D. L., Zipes, D. P., Libby, P., and Bonow, R. O. (2014). *Braunwald's Heart Disease: A Textbook of Cardiovascular Medicine*. Elsevier, 10 edition.
- [Ching et al., 2018] Ching, T., Himmelstein, D. S., Beaulieu-Jones, B. K., Kalinin, A. A., et al. (2018). Opportunities and obstacles for deep learning in biology and medicine. *Journal of the Royal Society Interface*, 15(141).
- [Clifford et al.,] Clifford, G. D., Liu, C., Moody, B., Lehman, L.-w. H., Silva, I., Li, Q., Johnson, A. E., and Mark, R. G. Af classification from a short single lead ecg recording: the physionet/computing in cardiology challenge 2017. [Internet, accedido el 24 de abril de 2025].
- [Clifford et al., 2017] Clifford, G. D., Liu, C., Moody, B., Lehman, L.-w. H., Silva, I., Li, Q., Johnson, A. E., and Mark, R. G. (2017). Af classification from a short single lead ecg recording: the physionet/computing in cardiology challenge 2017. In *2017 Computing in Cardiology (CinC)*, volume 44, pages 1 – 4. Institute of Electrical and Electronics Engineers (IEEE).
- [Computer in Cardiology (CinC),] Computer in Cardiology (CinC). Computer in cardiology (cinc). [Internet, accedido el 25 de abril de 2025].
- [Costanzo et al., 2018] Costanzo, D., Lioi, E., Sica, L., Del Pizzo, L., Carotenuto, R., and Cavaliere, F. (2018). Synthetic electrocardiogram generation with generative adversarial networks. In *2018 26th European Signal Processing Conference (EUSIPCO)*, pages 2486–2490. IEEE.
- [Creswell et al., 2018] Creswell, A., White, T., Dumoulin, V., Arulkumar, K., Sengupta, B., and Bharath, A. A. (2018). Generative adversarial networks: An overview. *IEEE Signal Processing Magazine*, 35(1):53 – 65.
- [Dalley II and Agur, 2022] Dalley II, A. F. and Agur, A. M. R. (2022). *Moore. Anatomía con orientación clínica*. LWW (Wolters Kluwer), 9 edition.

- [Delgado-Bonal and Martín-Guerrero, 2020] Delgado-Bonal, A. and Martín-Guerrero, J. D. (2020). A deep generative model for synthetic ecg signals with applications to data augmentation. *Applied Sciences*, 10(10):3467.
- [Esteban et al., 2017] Esteban, A., Hyland, S. L., and Rätsch, G. (2017). Real-valued (medical) time series generation with recurrent conditional gans. In *Proceedings of the NIPS 2017 Symposium on Machine Learning in Health Care (ML4H)*. PMLR.
- [Esteva et al., 2019] Esteva, A., Robicquet, A., Ramsundar, B., Kuleshov, V., DePristo, M., Chou, K., Cui, C., Corrado, G., Thrun, S., and Dean, J. (2019). A guide to deep learning in healthcare. *Nature medicine*, 25(1):24 – 29.
- [Faust et al., 2018] Faust, O., Hagiwara, Y., Hong, T. Y., Lih, O. S., and Acharya, U. R. (2018). Deep learning for healthcare applications based on physiological signals: A review. *Computer Methods and Programs in Biomedicine*, 161:1 – 13.
- [Fawaz et al., 2019] Fawaz, H. I., Forestier, G., Idoumghar, L., Muller, P.-A., and Weber, F. (2019). Deep learning for time series classification based on ecg signals. *Neural Computing and Applications*, 31(11):7483–7497.
- [Feather et al., 2020] Feather, A., Randall, D., and Waterhouse, M. (2020). *Kumar and Clark’s Clinical Medicine*. Elsevier, 10 edition.
- [Frid-Adar et al., 2018] Frid-Adar, M., Diamant, I., Klang, E., Amitai, M., Goldberger, J., and Greenspan, H. (2018). Gan-based synthetic medical image augmentation for increased cnn performance in liver lesion classification. *Neurocomputing*, 321:321 – 331.
- [Gerón, 2019] Gerón, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. Concepts, Tools and Techniques to Build Intelligent Systems*. O’Reilly Media.
- [Goldberger et al., 2000] Goldberger, A., Amaral, L., Glass, L., Hausdorff, J., Ivanov, P. C., Mark, R., and Stanley, H. E. (2000). Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals. *Circulation (Online)*, 101(23):e215 – e220. RRID:SCR007345.
- [Goodfellow et al., 2016] Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning (Adaptive Computation and Machine Learning series)*. The MIT Press, 1 edition.

- [Goodfellow et al., 2014] Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. (2014). Generative adversarial nets. In *Proceedings of the 28th International Conference on Neural Information Processing Systems - Volume 2*, volume 2, page 2672–2680. MIT Press.
- [Gulrajani et al., 2017] Gulrajani, I., Ahmed, F., Arjovsky, M., Dumoulin, V., and Courville, A. (2017). Improved training of wasserstein gans. In *Advances in Neural Information Processing Systems (NeurIPS) 30*, pages 5767–5777. Curran Associates, Inc.
- [H et al., 2019] H, N. F., Machado, C. A. G., and Hansen, J. T. (2019). *Atlas de Anatomía Humana*. Elsevier, 7 edition.
- [Hall, 2021] Hall, J. E. (2021). *Guyton y Hall: Tratado de fisiología médica*. Elsevier, 14 edition.
- [Han et al., 2015] Han, S., Mao, H., and Dally, W. J. (2015). Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding. *arXiv preprint arXiv:1510.00149*.
- [Hong et al., 2020] Hong, S., Zhou, Y., Shang, J., Xiao, C., and Sun, J. (2020). Opportunities and challenges of deep learning methods for electrocardiogram data: A systematic review. *Computers in Biology and Medicine*, 122.
- [Johnson et al., 2016] Johnson, A. E. W., Ghassemi, M. M., Nemati, S., Niehaus, K. E., Clifton, D. A., and Clifford, G. D. (2016). Machine learning and decision support in critical care. *Proceedings of the IEEE*, 104(2):444–466.
- [Katz, 2010] Katz, A. M. (2010). *Physiology of the Heart*. Wolters Kluwer Health, 5 edition.
- [Kelleher et al., 2015] Kelleher, J. D., Mac Namee, B., and D’Arcy, A. (2015). *Fundamentals of Machine Learning for Predictive Data Analytics. Algorithms, Worked Examples, and Case Studies*. The MIT Press, 1 edition.
- [Klabunde, 2012] Klabunde, R. E. (2012). *Cardiovascular Physiology Concepts*. Wolters Kluwer, 2 edition.
- [Kligfield et al., 2007] Kligfield, P., Gettes, L. S., Bailey, J. J., Rory, C., Deal, B. J., et al. (2007). Recommendations for the standardization and interpretation of the electrocardiogram. *Circulation*, 115.
- [Koeppen and Stanton, 2018] Koeppen, B. and Stanton, B. (2018). *Berne y Levy. Fisiología*. Elsevier, 7 edition.

- [Laguna et al., 1997] Laguna, P., Mark, R. G., Goldberg, A., and Moody, G. B. (1997). A database for evaluation of algorithms for measurement of qt and other waveform intervals in the ecg. In *Computers in Cardiology 1997*, volume 1, pages 673–676.
- [LeCun et al., 2015] LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature*, 521:436 – 444.
- [Li et al., 1995] Li, C., Zheng, C., and Tai, C. (1995). Detection of ecg characteristic points using wavelet transforms. *IEEE Transactions on Biomedical Engineering*, 42(1):21–28.
- [Liu et al., 2019] Liu, Y., Liu, G., and Zhang, Q. (2019). Deep learning and medical diagnosis. *Lancet*, 391:1709–1710.
- [Longo et al., 2023] Longo, D., Fauci, A. S., Kasper, D. L., Hauser, S., et al. (2023). *Harrison’s Principles of Internal Medicine*. McGraw Hill Medical, 21 edition.
- [Lu et al., 2020] Lu, L., Zhang, J., Xie, Y., Gao, F., Xu, S., Wu, X., and Ye, Z. (2020). Wearable health devices in health care: Narrative systematic review. *JMIR Mhealth Uhealth*, 8(11).
- [Luo and Johnston, 2010] Luo, S. and Johnston, P. (2010). A review of electrocardiogram filtering. *Journal of Electrocardiology*, 43:486 – 496.
- [Luz et al., 2016] Luz, E. J. d. S., Schwartz, W. R., Cámara-Chavez, G., and Menotti, D. (2016). Ecg-based heartbeat classification for arrhythmia detection: A survey. *Computer Methods and Programs in Biomedicine*, 127:144 – 164.
- [Lyon et al., 2018] Lyon, A., Mincholé, A., Martínez, J. P., Laguna, P., and Rodríguez, B. (2018). Computational techniques for ecg analysis and interpretation in light of their contribution to medical advances. *Journal of the Royal Society Interface*, 15(138).
- [Marieb, 2008] Marieb, E. N. (2008). *Anatomía y Fisiología Humana*. Pearson Education, 9 edition.
- [MIT Laboratory for Computational Physiology,] MIT Laboratory for Computational Physiology. Physionet. the research resource for complex physiologic signals. [Internet, accedido el 24 de marzo de 2025].
- [Mitchell, 1997] Mitchell, T. M. (1997). *Machine Learning*. McGraw Hill Education, 1 edition.

- [Mohrman and Heller, 2024] Mohrman, D. E. and Heller, L. J. (2024). *Cardiovascular Physiology*. McGraw Hill Education, 10 edition.
- [Moody and Mark, 2001] Moody, G. and Mark, R. (2001). The impact of the mit-bih arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3):45–50.
- [Murphy, 2012] Murphy, K. P. (2012). *A Probabilistic Perspective*. The MIT Press, 1 edition.
- [Oppenheim and Schafer, 2010] Oppenheim, A. V. and Schafer, R. W. (2010). *Discrete-Time Signal Processing*. Pearson, 3 edition.
- [Palermi et al., 2025] Palermi, S., Vecchiato, M., Anselmino, M., Siong Ng, F., De Ferrari, G. M., Attia, Z., Saglietto, A., and Cho, Y. (2025). Artificial intelligence and the electrocardiogram: A modern renaissance. *European Journal of Internal Medicine*.
- [Pan and Tompkins, 1985] Pan, J. and Tompkins, W. J. (1985). A real-time qrs detection algorithm. *IEEE Transactions on Biomedical Engineering*, BME-32(3):230–236.
- [Quinn, Matt,] Quinn, Matt. The pericardium. [Internet, accedido el 1 de mayo de 2025].
- [Rajpurkar et al., 2019] Rajpurkar, P., Hannun, A. Y., Haghpanahi, M., Bourn, C., Ng, A. Y., Tison, G. H., and Turakhia, M. P. (2019). Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature medicine*, 25(1):65 – 69.
- [Rosas, 2022] Rosas, E. A. (2022). *Cardiología*. El Manual Moderno, 1 edition.
- [Saturno Chiu, 2017] Saturno Chiu, G. (2017). *Cardiología*. Editorial El Manual Moderno, 1 edition.
- [Schwaber, Ken and Sutherland, Jeff,] Schwaber, Ken and Sutherland, Jeff. La guía scrum. la guía definitiva de scrum: Las reglas del juego. [Internet, accedido el 15 de marzo de 2025].
- [Shannon, 1949] Shannon, C. E. (1949). Communication in the presence of noise. *Proceedings of the IRE*, 37(1):10–21.
- [Silverthorn, 2019] Silverthorn, D. U. (2019). *Fisiología humana: Un enfoque integrado*. Editorial Médica Panamericana, 8 edition.
- [Standring, 2020] Standring, S. (2020). *Gray’s Anatomy: The Anatomical Basis of Clinical Practice*. Elsevier, 42 edition.

- [Strubell et al., 2019] Strubell, E., Ganesh, A., and McCallum, A. (2019). Energy and policy considerations for deep learning in NLP. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3645 – 3650. Association for Computational Linguistics.
- [Surawicz and Knilans, 2008] Surawicz, B. and Knilans, T. (2008). *Chou's Electrocardiography in Clinical Practice: Adult and Pediatric*. Saunders, Elsevier, 6 edition.
- [Texas Heart Institute,] Texas Heart Institute. Las válvulas cardíacas. [Internet, accedido el 29 de abril de 2025].
- [Tortora and Derrickson, 2018] Tortora, G. J. and Derrickson, B. H. (2018). *Principios de Anatomía y Fisiología*. Editorial Médica Panamericana, 15 edition.
- [Turakhia et al., 2019] Turakhia, M. P., Desai, M., Hedlin, H., Rajmane, A., Talati, N., et al. (2019). Rationale and design of a large-scale, app-based study to identify cardiac arrhythmias using a smartwatch: The apple heart study. *American Heart Journal*, 207:66 – 75.
- [Vélez et al., 2010] Vélez, H., Rojas, W., and Borrero, J. (2010). *Fundamentos de Medicina: Cardiología*. Fondo Editorial CIB, 7 edition.
- [Wagner and Strauss, 2014] Wagner, G. S. and Strauss, D. G. (2014). *Marriott: Electrocardiografía práctica*. Wolters Kluwer Health, 12 edition.
- [Wang et al., 2020] Wang, Y., Lu, R., Yang, H., Wu, W., and Wei, J. (2020). Conditional generative adversarial network for electrocardiogram synthesis. In *2020 Chinese Automation Congress (CAC)*, pages 6386–6391. IEEE.
- [Widmaier et al., 2018] Widmaier, E. P., Raff, H., and Strang, K. T. (2018). *Vander's Human Physiology: The Mechanisms of Body Function*. McGraw Hill Education, 15 edition.
- [Wineski, 2018] Wineski, L. E. (2018). *Snell's Clinical Anatomy by Regions*. Wolters Kluwer Health, 10 edition.
- [Wulan et al., 2020] Wulan, N., Sun, P., Wang, K., Xia, Y., and Zhang, H. (2020). Generating electrocardiogram signals by deep learning. *Neurocomputing*, 404:122 – 136.
- [Young et al., 2013] Young, B., O'Dowd, G., and Woodford, P. (2013). *Wheater's Functional Histology: A Text and Colour Atlas*. Elsevier, 6 edition.
- [Zanchi et al., 2025] Zanchi, B., Monachino, G., Fiorillo, L., Conte, G., Auricchio, A., Tzovara, A., and Faraci, F. D. (2025). Synthetic ecg signals generation: A scoping review. *Computers in Biology and Medicine*, 184.

- [Zhang and Babaeizadeh, 2021] Zhang, Y.-H. and Babaeizadeh, S. (2021). Synthesis of standard 12-lead electrocardiograms using two-dimensional generative adversarial networks. *Journal of Electrocardiology*, 69:6 – 14.
- [Zhou and Wei, 2020] Zhou, Y. and Wei, Y. (2020). Generative adversarial network for ecg signal generation with applications in imbalance classification. In *2020 42nd Annual International Conference of the IEEE Engineering in Medicine Biology Society (EMBC)*, pages 5240–5243. IEEE.